

Задача 2. Метод ближайшего соседа

Нейронные сети и машинное обучение

Задания 1–3, раздел 3.13, стр. 68–69

Регрессия методом ближайшего соседа:

$$\tilde{f}(x) = \frac{\sum_{i \in N_k(x)} w_i y^{(i)}}{\sum_{i \in N_k(x)} w_i}, \quad (1)$$

$N_k(x)$ – индексы k ближайших к x элементов выборки. Числа в проверках получены скриптом `check.py` с фиксированным зерном.

Задание 1. Определить k по рис. 3.2, установить наличие весов, привести примеры порождающих функций.

Значение k . При $k = 1$ формула (1) даёт $\tilde{f}(x) = y^{(j)}$, где $x^{(j)}$ ближайший к x . Прямая разбивается на N ячеек Вороного с границами в середине между соседними $x^{(i)}$, на каждой $\tilde{f} \equiv y^{(i)}$. Значит ровно N ступеней и график проходит через все точки выборки.

При $k \geq 2$ значение на ступени – среднее не менее двух $y^{(i)}$, то есть строго между их минимумом и максимумом. Изолированная точка на графике оказаться не может.

На рис. 3.2 график проходит через изолированные точки (нижняя левая, одиночный провал в середине), следовательно $k = 1$.

Веса. При $k = 1$ сумма в (1) состоит из одного слагаемого: $\tilde{f}(x) = w_j y^{(j)} / w_j = y^{(j)}$ при любом $w_j > 0$. Взвешенный и невзвешенный варианты совпадают, по рисунку веса не определяются.

Порождающие функции. Точки отклоняются от прямой примерно на $\delta \approx 0.1 \Delta y$, значит

$$y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}, \quad |\varepsilon^{(i)}| \lesssim \delta, \quad f(x) = ax + b,$$

где $\varepsilon \sim U[-\delta, \delta]$ либо $\varepsilon \sim \mathcal{N}(0, (\delta/2)^2)$. Восстановление неоднозначно: любая f внутри полосы ширины 2δ вокруг прямой даёт статистически неотличимую выборку, например $f(x) = ax + b + \alpha \sin(2\pi \nu x)$ при $\alpha < \delta$.

Проверка: выборка из 45 точек по $y = x$ с шумом $\mathcal{N}(0, 0.06^2)$.

k	$\max_i \tilde{f}(x^{(i)}) - y^{(i)} $	число ступеней
1	0.0000	45
2	0.0953	44
3	0.1116	43
5	0.1127	41

Только при $k = 1$ отклонение нулевое и число ступеней равно числу точек.

Задание 2. Каждый из m интервалов $[a_j, b_j]$ делится на n частей независимо от остальных, ячейка задаётся набором из m номеров подынтервалов, значит ячеек n^m и

$$N = M n^m, \quad N|_{m=20} = M n^{20}, \quad N|_{m=40} = M n^{40} = \frac{N|_{m=20}^2}{M}.$$

Оценка нижняя: она достигается при равномерном заполнении сетки, при неравномерном распределении часть ячеек пуста и выборка нужна больше.

При $n = 10$, $M = 100$:




Рис. 1: Регрессия методом ближайшего соседа при $k = 1$ и $k = 5$.

m	ячеек n^m	$N = Mn^m$
12 (пример пособия)	10^{12}	10^{14}
20	10^{20}	10^{22}
40	10^{40}	10^{42}

При $m = 20$ хранение выборки требует $10^{22} \cdot 20 \cdot 8 = 1.6 \cdot 10^{24}$ байт.

Задание 3. Выборка из N элементов, равномерная в единичном гиперкубе $\mathbb{R}^m$.

а) *Точки у границы.* Точки, удалённые от границы не менее чем на ε по каждой координате, образуют куб с ребром $1 - 2\varepsilon$, поэтому

$$P(\text{точка в приграничном слое}) = 1 - (1 - 2\varepsilon)^m \xrightarrow{m \rightarrow \infty} 1 \quad \forall \varepsilon < \frac{1}{2}.$$

Тот же расчёт, что для сферы в разделе 3.10, где доля равна $1 - (1 - \varepsilon)^m$. При $\varepsilon = 0.05$: 0.878 для $m = 20$, 0.995 для $m = 50$.

Проверка: $2 \cdot 10^5$ точек.

m	ε	опыт	$1 - (1 - 2\varepsilon)^m$
5	0.01	0.0954	0.0961
5	0.05	0.4067	0.4095
20	0.01	0.3338	0.3324
20	0.05	0.8789	0.8784

б) *Длина ребра $l_m(p)$.* Доля точек в подкубе равна его объёму, значит $l^m = p$ и

$$l_m(p) = p^{1/m} \xrightarrow{m \rightarrow \infty} 1 \quad \forall p > 0.$$

$$l_5(0.01) = 0.3981, \quad l_5(0.1) = 0.6310, \quad l_{20}(0.01) = 0.7943, \quad l_{20}(0.1) = 0.8913.$$

В $\mathbb{R}^{20}$ окрестность, содержащая 1% выборки, занимает 79% диапазона каждой координаты, то есть локальной не является.

Проверка: доля точек в подкубе с ребром $p^{1/m}$ по $2 \cdot 10^5$ точкам: 0.0098 и 0.0992 при $m = 5$, 0.0100 и 0.0996 при $m = 20$ для $p = 0.01$ и $p = 0.1$.

в) *Евклидовы расстояния.* Пусть u, v независимы и равномерны в $[0, 1]^m$, $d^2 = \sum_i (u_i - v_i)^2$. Разность $w = u_i - v_i$ имеет треугольную плотность $1 - |w|$ на $[-1, 1]$, откуда

$$Mw^2 = 2 \int_0^1 w^2(1-w) dw = \frac{1}{6}, \quad Mw^4 = 2 \int_0^1 w^4(1-w) dw = \frac{1}{15}, \quad Dw^2 = \frac{1}{15} - \frac{1}{36} = \frac{7}{180},$$

и по независимости слагаемых

$$Md^2 = \frac{m}{6}, \quad Dd^2 = \frac{7m}{180}, \quad \frac{\sqrt{Dd^2}}{Md^2} = \sqrt{\frac{1.4}{m}} \xrightarrow{m \rightarrow \infty} 0.$$

Расстояния растут как $\sqrt{m/6}$, относительный разброс убывает как $\frac{1}{2}\sqrt{1.4/m}$, поэтому $(d_{\max} - d_{\min})/d_{\min} \rightarrow 0$ и ближайший сосед почти не отличается от самого далёкого.

Радиус окрестности: шар радиуса r содержит долю $K_m r^m$, где $K_m = \pi^{m/2}/\Gamma(m/2 + 1)$, значит для доли p нужен $r = (p/K_m)^{1/m}$. Наибольший вписанный в куб шар имеет $r = 1/2$ и объём $K_m/2^m = 2.46 \cdot 10^{-8}$ при $m = 20$, то есть даже он пуст.

Проверка: 2000 пар точек на размерность.

m	Md опыт	$\sqrt{Md^2}$	σ_d/Md	$(d_{\max} - d_{\min})/d_{\min}$
1	0.3256	0.4082	0.7185	$4 \cdot 10^5$
5	0.8776	0.9129	0.2834	13.91
20	1.8058	1.8257	0.1337	2.10
100	4.0777	4.0825	0.0586	0.44

Разброс совпадает с оценкой $\frac{1}{2}\sqrt{1.4/m}$: 0.132 при $m = 20$, 0.059 при $m = 100$. Доля точек во вписанном шаре: 0.787 при $m = 2$, 0.164 при $m = 5$, ноль при $m = 20$.

г) *Расстояния Чебышёва.* $\rho_\infty = \max_i |u_i - v_i|$, события $|u_i - v_i| \leq t$ независимы, $P(|w| \leq t) = 2t - t^2$, значит

$$P(\rho_\infty \leq t) = (2t - t^2)^m \xrightarrow{m \rightarrow \infty} 0 \quad \forall t < 1, \quad t_{1/2} = 1 - \sqrt{1 - 2^{-1/m}} \xrightarrow{m \rightarrow \infty} 1.$$

Максимально возможное расстояние Чебышёва равно 1, то есть типичное расстояние приближается к максимальному.

Проверка: $2 \cdot 10^5$ пар точек.

m	среднее	медиана опыт	$1 - \sqrt{1 - 2^{-1/m}}$
5	0.6301	0.6398	0.6402
20	0.8057	0.8154	0.8154
100	0.9116	0.9168	0.9169

Все четыре пункта дают одно: выборка прижимается к границе, локальная окрестность покрывает почти весь диапазон каждого признака, расстояния велики и почти одинаковы независимо от нормы.