

Задача 2. Метод ближайшего соседа

Нейронные сети и машинное обучение

Задания 1–3

1 Что нужно знать

1.1 Обозначения

$x^{(i)} \in \mathbb{R}^m$	вектор признаков, m – размерность задачи
$y^{(i)}$	отклик: метка класса или число
N	размер выборки
k	число ближайших соседей
$\rho(x, y)$	расстояние (мера близости)
$\tilde{f}$	восстановленная по выборке зависимость
$V_m(r)$	объём m -мерного шара радиуса r
Γ	гамма-функция, $\Gamma(n) = (n-1)!$ для целых n

1.2 Метод ближайшего соседа

Дана выборка $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$ и точка запроса x , для которой нужно предсказать отклик. Метод ближайшего соседа находит k элементов выборки, ближайших к x по выбранной мере близости, и усредняет их отклики:

$$\tilde{f}(x) = \frac{\sum_{i \in N_k(x)} w_i y^{(i)}}{\sum_{i \in N_k(x)} w_i}, \quad (1)$$

где $N_k(x)$ – множество индексов k ближайших элементов. В задаче классификации вместо усреднения берётся голосование, но структура та же.

Веса w_i позволяют учитывать соседей неравномерно: чем ближе $x^{(i)}$ к x , тем больше вес, например $w_i = 1/\rho(x, x^{(i)})$. При $w_i \equiv 1$ получается обычное среднее арифметическое.

Параметр k управляет гладкостью. При $k = 1$ ответ равен отклику одного ближайшего элемента, и график $\tilde{f}$ повторяет все особенности выборки, включая шум. С ростом k усреднение по большому числу соседей сглаживает кривую, но начинает размывать реальные детали зависимости.

1.3 Меры близости

Чаще всего используются нормы семейства

$$\rho_p(x, y) = \left(\sum_{j=1}^m |x_j - y_j|^p \right)^{1/p},$$

из которых нам понадобятся две крайние: евклидова $\rho_2(x, y) = \sqrt{\sum_j (x_j - y_j)^2}$ и чебышёвская $\rho_\infty(x, y) = \max_j |x_j - y_j|$, равная наибольшему расхождению по одной координате.

1.4 Объём шара и куба в $\mathbb{R}^m$

Объём m -мерного шара радиуса r пропорционален r^m :

$$V_m(r) = K_m r^m, \quad K_m = \frac{\pi^{m/2}}{\Gamma(m/2 + 1)}. \quad (2)$$

Отсюда получается ключевой для всей главы факт. Возьмём шар радиуса 1 и вырежем из него шар радиуса $1 - \varepsilon$. Доля объёма, оставшаяся в приграничном слое, равна

$$\frac{V_m(1) - V_m(1 - \varepsilon)}{V_m(1)} = \frac{K_m - K_m(1 - \varepsilon)^m}{K_m} = 1 - (1 - \varepsilon)^m. \quad (3)$$

Число $1 - \varepsilon$ меньше единицы, поэтому его m -я степень быстро стремится к нулю, а доля (3) – к единице. Уже при $m = 12$ и $\varepsilon = 0.2$ в приграничном слое лежит более 93% объёма шара. Куб устроен так же: подкуб с ребром l имеет объём l^m .

1.5 Равномерное распределение и проклятие размерности

Если точки распределены равномерно в единичном кубе, то вероятность попасть в любую область равна объёму этой области. Поэтому все утверждения про объёмы сразу переводятся в утверждения про доли точек выборки, и наоборот. Этим будем пользоваться в задании 3 постоянно.

Проклятие размерности – собирательное название для неудобных свойств многомерных пространств. Главное из них: при росте m объём (а значит и требуемый размер выборки) растёт экспоненциально, а привычная геометрическая интуиция, выработанная на плоскости, перестаёт работать.

2 Задания

Задание 1

Дано. График регрессии методом ближайшего соседа: ломаная, построенная по выборке точек, и прямая, задающая истинную зависимость. С графика видно, что ломаная кусочно-постоянна и проходит через каждую точку выборки, включая изолированные (нижняя левая точка и одиночный глубокий провал в середине), а сами точки лежат вдоль прямой, отклоняясь от неё примерно на десятую часть диапазона значений y .

Требуется. Определить, при каком k построена ломаная; выяснить, использовались ли веса; привести примеры функций, по которым такая выборка могла быть получена при заданной величине ошибки измерений.

Зачем это нужно. По графику регрессии нужно уметь восстановить параметры метода и понять, что по выборке с ошибками измерений можно восстановить, а что нельзя.

Решение.

Значение k . Разберём, как выглядит график при каждом k .

При $k = 1$ формула (1) даёт $\hat{f}(x) = y^{(j)}$, где $x^{(j)}$ – ближайший к x элемент выборки. Ось x при этом разбивается на N участков: границы проходят посередине между соседними $x^{(i)}$, и на своём участке функция постоянна и равна $y^{(i)}$. Отсюда два

наблюдаемых признака: ровно N горизонтальных ступеней и прохождение графика через все точки выборки.

При $k \geq 2$ без весов значение на каждой ступени – это среднее не менее двух откликов, то есть число между наименьшим и наибольшим из усредняемых. Поэтому если у точки оба соседа лежат заметно выше неё, график до неё не опустится. С весами $w_i = 1/\rho(x, x^{(i)})$ график при $k \geq 2$ проходит через точки выборки, так как в точке $x^{(i)}$ её вес бесконечен, но между точками он уже не постоянен.

На графике ломаная кусочно-постоянна и проходит через изолированные точки. Оба признака сразу даёт только $k = 1$.

Веса. При $k = 1$ сумма в (1) состоит из одного слагаемого:

$$\tilde{f}(x) = \frac{w_j y^{(j)}}{w_j} = y^{(j)}$$

при любом $w_j > 0$. Вес сокращается, взвешенный и невзвешенный варианты дают одну и ту же ломаную. Значит по графику определить, использовались ли веса, невозможно: на результат они не влияют.

Порождающие функции. Точки отклоняются от прямой примерно на $\delta \approx 0.1 \Delta y$, где Δy – диапазон значений. Такую выборку даёт любая зависимость вида

$$y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}, \quad |\varepsilon^{(i)}| \lesssim \delta,$$

где $f(x) = ax + b$, а ошибка измерений ε равномерна на $[-\delta, \delta]$ либо нормальна с $\sigma \approx \delta/2$.

Существенно, что восстановление неоднозначно. Любая функция, отличающаяся от прямой не более чем на δ , порождает выборки, статистически неотличимые от изображённой: например $f(x) = ax + b + \alpha \sin(2\pi\nu x)$ при $\alpha < \delta$ или многочлен невысокой степени, проходящий внутри полосы ширины 2δ вокруг прямой. По выборке при заданном уровне ошибки восстанавливается не одна функция, а весь класс функций, попадающих в эту полосу.




Рис. 1: Регрессия методом ближайшего соседа. Слева $k = 1$: ломаная проходит через все точки выборки. Справа $k = 5$: ступени стали шире, через точки ломаная больше не проходит.

Задание 2

Дано. Задача классификации конфигурации потока смеси по вектору признаков $x^{(i)} \in \mathbb{R}^{20}$. Используется классификация по регулярной сетке: диапазон допустимых значений $[a_j, b_j]$ каждой из компонент делится на n равных частей, ячейкой называется получившийся многомерный параллелепипед, и объект относится к тому классу, представителей которого в его ячейке больше. Для уверенного прогноза требуется M элементов выборки в каждой ячейке.

Требуется. Найти необходимый размер выборки N . Найти N для случая $x^{(i)} \in \mathbb{R}^{40}$. *Зачем это нужно.* Показывает, почему классификация по ячейкам сетки, которая работает при двух-трёх признаках, неприменима при десятках признаков.

Решение. Каждая из m координат делится на n частей независимо от остальных, поэтому ячейка однозначно задаётся набором из m номеров подынтервалов, по одному на координату. Наборов ровно

$$\underbrace{n \cdot n \cdot \dots \cdot n}_m = n^m.$$

Требование M элементов в каждой ячейке даёт

$$N = M n^m. \quad (4)$$

При $m = 20$ получаем $N = M n^{20}$, при $m = 40$ получаем $N = M n^{40}$. Удвоение размерности возводит требуемый размер выборки в квадрат:

$$N(2m) = M n^{2m} = \frac{(M n^m)^2}{M} = \frac{N(m)^2}{M}.$$

Оценка (4) является нижней: она отвечает идеальному случаю, когда точки распределены по ячейкам равномерно. Реальные данные распределены неравномерно, часть ячеек остаётся пустой, и на практике выборка нужна ещё больше.

Подставим правдоподобные значения $n = 10$ и $M = 100$.

m	число ячеек n^m	$N = M n^m$
12	10^{12}	10^{14}
20	10^{20}	10^{22}
40	10^{40}	10^{42}

Чтобы оценить масштаб: при $m = 20$ одно только хранение выборки потребует $10^{22} \cdot 20 \cdot 8 = 1.6 \cdot 10^{24}$ байт, если каждая компонента занимает восемь байт. Носителей такого объёма не существует, и никакой эксперимент столько измерений не даст. Процедура, вполне работоспособная при $m = 2$ или $m = 3$, становится неосуществимой уже при нескольких десятках признаков.

Задание 3

Дано. Выборка из N элементов, распределённых равномерно в единичном гиперкубе $[0, 1]^m$; по ней требуется оценить плотность распределения.

Требуется. Показать четыре свойства многомерного куба: (а) почти все точки выборки лежат у границы; (б) найти длину ребра $l_m(p)$ подкуба, содержащего долю p точек, и оценить $l_5(0.01)$, $l_5(0.1)$, $l_{20}(0.01)$, $l_{20}(0.1)$; (в) почти все евклидовы расстояния между точками велики и примерно одинаковы, а окрестность, содержащая хотя

бы немного точек, обязана иметь большой радиус; (г) расстояния Чебышёва между почти всеми точками велики.

Зачем это нужно. Объясняет, почему метод ближайшего соседа и оценка плотности по окрестности плохо работают в большой размерности: окрестности перестают быть локальными, а расстояния почти не различают точки.

а) Точки лежат у границы

Решение. Повторим для куба расчёт (3), сделанный для шара. Точка удалена от границы не менее чем на ε , если каждая её координата лежит в $[\varepsilon, 1 - \varepsilon]$. Такие точки образуют внутренний куб с ребром $1 - 2\varepsilon$ и объёмом $(1 - 2\varepsilon)^m$. При равномерном распределении вероятность попасть внутрь равна этому объёму, поэтому доля точек в приграничном слое равна

$$1 - (1 - 2\varepsilon)^m \xrightarrow{m \rightarrow \infty} 1 \quad \text{при любом фиксированном } \varepsilon < \frac{1}{2}.$$

Сходимость экспоненциальная: при $\varepsilon = 0.05$ доля равна $1 - 0.9^{20} = 0.878$ для $m = 20$ и 0.995 для $m = 50$. ■

Содержательно это означает следующее. Если считать, что ошибка измерения ограничена по каждой координате, то результаты измерений заполняют окрестность истинного значения. В большой размерности почти все они окажутся не около истинного значения, а у границы этой окрестности, то есть с ошибкой, близкой к максимально допустимой сразу по многим координатам.

б) Длина ребра подкуба

Решение. Доля точек, попавших в подкуб, равна его объёму, а объём подкуба с ребром l равен l^m . Из уравнения $l^m = p$ получаем

$$l_m(p) = p^{1/m}. \quad \blacksquare \tag{5}$$

m	p	$l_m(p) = p^{1/m}$
5	0.01	0.3981
5	0.1	0.6310
20	0.01	0.7943
20	0.1	0.8913

Прочитаем таблицу. Чтобы в $\mathbb{R}^{20}$ собрать всего один процент выборки, окрестность должна занимать 79% диапазона каждой координаты, а чтобы собрать десять процентов – 89%. Такая окрестность покрывает почти весь диапазон изменения каждого признака и локальной не является ни в каком смысле. Метод ближайшего соседа при этом перестаёт быть локальным методом: усреднение ведётся по точкам, которые близкими не являются. При $m \rightarrow \infty$ величина $p^{1/m} \rightarrow 1$ для любого фиксированного $p > 0$.

в) Евклидовы расстояния

Решение. Пусть u и v – две независимые точки, равномерные в $[0, 1]^m$, и $d^2 = \sum_{i=1}^m (u_i - v_i)^2$. Найдём среднее и дисперсию d^2 .

Разность двух независимых равномерных на $[0, 1]$ величин $w = u_i - v_i$ имеет треугольную плотность $1 - |w|$ на отрезке $[-1, 1]$. Отсюда

$$Mw^2 = 2 \int_0^1 w^2(1-w) dw = 2 \left(\frac{1}{3} - \frac{1}{4} \right) = \frac{1}{6},$$

$$Mw^4 = 2 \int_0^1 w^4(1-w) dw = 2 \left(\frac{1}{5} - \frac{1}{6} \right) = \frac{1}{15}, \quad Dw^2 = \frac{1}{15} - \frac{1}{36} = \frac{7}{180}.$$

Слагаемые независимы, поэтому средние и дисперсии складываются:

$$Md^2 = \frac{m}{6}, \quad Dd^2 = \frac{7m}{180}.$$

Относительный разброс квадрата расстояния равен

$$\frac{\sqrt{Dd^2}}{Md^2} = \frac{\sqrt{7m/180}}{m/6} = \sqrt{\frac{36 \cdot 7}{180m}} = \sqrt{\frac{1.4}{m}} \xrightarrow{m \rightarrow \infty} 0. \quad (6)$$

Итак, само расстояние растёт как $\sqrt{m/6}$, а его относительный разброс убывает как $1/\sqrt{m}$: расстояния становятся большими и почти одинаковыми, отношение $(d_{\max} - d_{\min})/d_{\min}$ стремится к нулю. Ближайший сосед почти не отличается по расстоянию от самого далёкого элемента выборки, и понятие близости обесценивается. ■

Теперь про радиус окрестности. По (2) шар радиуса r содержит долю точек $K_m r^m$, пока он лежит внутри куба, поэтому для доли p нужен радиус

$$r = \left(\frac{p}{K_m} \right)^{1/m}.$$

Величина $K_m = \pi^{m/2}/\Gamma(m/2 + 1)$ убывает быстрее любой экспоненты, так что радиус приходится брать всё больший. Предельно наглядный случай: наибольший шар, вписанный в единичный куб, имеет радиус $1/2$ и объём

$$\frac{K_m}{2^m} = \frac{\pi^{m/2}}{2^m \Gamma(m/2 + 1)} = 2.46 \cdot 10^{-8} \quad \text{при } m = 20.$$

То есть даже самый большой помещающийся в куб шар практически пуст: почти весь объём куба сосредоточен в его углах, куда шар не достаёт. Любая окрестность, содержащая заметную долю выборки, обязана выходить за пределы куба.

г) Расстояния Чебышёва

Решение. Расстояние Чебышёва $\rho_\infty = \max_{1 \leq i \leq m} |u_i - v_i|$ не превосходит t тогда и только тогда, когда по каждой координате расхождение не превосходит t . События по разным координатам независимы, а для треугольной плотности

$$P(|w| \leq t) = \int_{-t}^t (1 - |w|) dw = 2t - t^2,$$

поэтому

$$P(\rho_\infty \leq t) = (2t - t^2)^m. \quad (7)$$

Основание $2t - t^2$ меньше единицы при любом $t < 1$, значит правая часть стремится к нулю с ростом m : почти все чебышёвские расстояния превосходят t . Медиана находится из $(2t - t^2)^m = 1/2$, то есть $2t - t^2 = 2^{-1/m}$, откуда

$$t_{1/2} = 1 - \sqrt{1 - 2^{-1/m}} \xrightarrow{m \rightarrow \infty} 1.$$

Численно: 0.640 при $m = 5$, 0.815 при $m = 20$, 0.917 при $m = 100$. Максимально возможное расстояние Чебышёва в единичном кубе равно единице, то есть типичное расстояние приближается к максимальному. ■

Все четыре пункта говорят об одном и том же с разных сторон: в пространстве большой размерности выборка прижимается к границе, локальная окрестность вынуждена покрывать почти весь диапазон каждого признака, а расстояния между точками велики и почти одинаковы независимо от выбора нормы. Поэтому размерность вектора признаков нужно держать минимально достаточной, к чему и подводит метод главных компонент.