Задача 3. Метод наименьших квадратов

Нейронные сети и машинное обучение

Задания 1 и 2

1 Что нужно знать

1.1 Обозначения

$\{(x_k, y_k)\}_{k=1}^N$	выборка, $x_k = x^{(k)}$, $y_k = y^{(k)}$
$\tilde{f}(x, w)$	восстанавливаемая зависимость с параметрами w
$E(w)$	функция ошибки
M	степень многочлена в полиномиальной регрессии
$A^\top$	транспонированная матрица
$\ker A$	ядро: множество w, для которых $Aw = 0$
$\operatorname{Im} A$	образ: множество значений Aw
$\operatorname{rank} A$	ранг, $\operatorname{rank} A = \dim \operatorname{Im} A$

1.2 Задача регрессии и метод наименьших квадратов

Дана выборка $\{(x_k, y_k)\}_{k=1}^N$, где значения y_k получены с некоторой случайной ошибкой измерения. Требуется восстановить зависимость $y = f(x)$. Метод наименьших квадратов выбирает ту функцию из заданного семейства, которая даёт наименьшую сумму квадратов отклонений:

$$E(w) = \frac{1}{2} \sum_{k=1}^{N} \big(y_k - \tilde{f}(x_k, w)\big)^2 \;\longrightarrow\; \min_w . \tag{1}$$

Множитель $1/2$ поставлен только для того, чтобы он сократился при дифференцировании.

Если $\tilde{f}$ линейно зависит от параметров w (а это так и для линейной, и для полиномиальной регрессии), то $E(w)$ – квадратичная функция от w. Необходимое условие минимума – равенство нулю всех частных производных $\partial E / \partial w_j$. Оно приводит к системе линейных уравнений, которую называют *системой нормальных уравнений*.

1.3 Матрица Грама

Пусть Φ – матрица, столбцы которой – какие-то векторы из $\mathbb{R}^N$. Матрица $G = \Phi^\top \Phi$ называется *матрицей Грама* этих столбцов: её элемент G_{ij} равен скалярному произведению i-го и j-го столбцов. Нам понадобятся два её свойства.

Неотрицательная определённость. Для любого w

$$w^\top G w = w^\top \Phi^\top \Phi w = (\Phi w)^\top (\Phi w) = \|\Phi w\|^2 \geq 0.$$

Совпадение ядер. Если $Gw = 0$, то $\|\Phi w\|^2 = w^\top G w = 0$, значит $\Phi w = 0$. Обратное очевидно. Поэтому

$$\ker G = \ker \Phi, \qquad \operatorname{rank} G = \operatorname{rank} \Phi. \tag{2}$$

В частности G невырождена тогда и только тогда, когда столбцы Φ линейно независимы.

1.4 Число обусловленности

Число обусловленности $\operatorname{cond} A = \|A\| \cdot \|A^{-1}\|$ показывает, во сколько раз ошибка в правой части системы $Aw = b$ может усилиться в решении. При $\operatorname{cond} A \sim 10^{16}$ в двойной точности от решения не остаётся ни одной верной цифры: формально невырожденная матрица становится вырожденной численно.

1.5 Многочлены и матрица Вандермонда

Ненулевой многочлен степени не выше M имеет не более M корней. Отсюда следует нужное нам утверждение: если многочлен степени $\le M$ обращается в нуль более чем в M различных точках, то он тождественно нулевой.

Матрицей Вандермонда для узлов $x_1, \dots, x_N$ называется

$$V = \left(x_k^j\right)_{k=1..N,\ j=0..M} = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^M \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_N & x_N^2 & \dots & x_N^M \end{pmatrix}.$$

Умножение Vw даёт вектор значений многочлена $\sum_j w_j x^j$ в узлах $x_1, \dots, x_N$.

2 Задания

Задание 1

Дано. Линейная регрессия: восстанавливаемая зависимость имеет вид $\tilde f(x) = Ax + B$ с двумя неизвестными параметрами. Функция ошибки

$$E(A, B) = \frac{1}{2} \sum_{k=1}^{N} \bigl(y_k - Ax_k - B\bigr)^2,$$

а условие минимума $\partial E/\partial A = \partial E/\partial B = 0$ даёт систему нормальных уравнений

$$\begin{cases} \left(\sum_k x_k^2\right) A + \left(\sum_k x_k\right) B = \sum_k x_k y_k, \\ \left(\sum_k x_k\right) A + NB = \sum_k y_k. \end{cases} \tag{3}$$

Требуется. Указать, когда система (3) разрешима; объяснить, почему в этом случае решение единственно; описать выборку, для которой определитель системы равен нулю.

Зачем это нужно. Линейная регрессия – простейший случай метода наименьших квадратов. На нём видно, от чего зависит единственность решения нормальных уравнений.

Решение.

Определитель. Выпишем матрицу системы и заметим, что она является матрицей Грама:

$$G = \begin{pmatrix} \sum_k x_k^2 & \sum_k x_k \\ \sum_k x_k & N \end{pmatrix} = \Phi^{\top}\Phi, \qquad \Phi = \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{pmatrix}.$$

Действительно, скалярное произведение первого столбца на себя равно $\sum_k x_k^2$, первого на второй – $\sum_k x_k$, второго на себя – N.

Считаем определитель, обозначив $\bar{x} = \frac{1}{N}\sum_k x_k$:

$$\det G = N\sum_k x_k^2 - \Big(\sum_k x_k\Big)^2 = N\sum_k x_k^2 - N^2\bar{x}^2 = N\sum_k \big(x_k - \bar{x}\big)^2.$$

Последний переход – обычное преобразование суммы квадратов отклонений: $\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - N\bar{x}^2$.

Полученное выражение неотрицательно как сумма квадратов, и обращается в нуль только когда все слагаемые нулевые:

$$\det G = 0 \iff x_k = \bar{x} \text{ для всех } k \iff \text{все } x_k \text{ совпадают.}$$

Значит система (3) однозначно разрешима тогда и только тогда, когда среди x_k есть хотя бы два различных значения. Тот же вывод получается и из (2): столбцы Φ – это вектор $(x_1, \ldots, x_N)$ и вектор из единиц, они линейно зависимы ровно тогда, когда первый тоже постоянен.

Единственность. Единственность решения невырожденной линейной системы – факт линейной алгебры. Но здесь важнее другое: найденная точка действительно даёт минимум, а не какую-то иную стационарную точку. Функция $E(A, B)$ квадратична, и её матрица вторых производных равна как раз G. При $\det G > 0$ (а след G положителен всегда) матрица G положительно определена, значит E строго выпукла. У строго выпуклой функции стационарная точка единственна и является точкой глобального минимума.

Вырожденный случай. Равенство $\det G = 0$ означает, что все измерения выполнены при одном и том же значении $x_k \equiv x_0$: точки выборки лежат на одной вертикальной прямой. Подставим это в функцию ошибки:

$$E(A, B) = \frac{1}{2}\sum_k \big(y_k - (Ax_0 + B)\big)^2.$$

Она зависит от A и B только через одну комбинацию $t = Ax_0 + B$ и минимальна при $t = \bar{y}$ (задача о постоянной величине: минимум суммы квадратов отклонений достигается на среднем арифметическом). Решением служит вся прямая $Ax_0 + B = \bar{y}$ в плоскости параметров: бесконечно много пар (A, B), дающих одну и ту же ошибку. Содержательно это очевидно: по точкам, стоящим на одной вертикали, наклон прямой определить нельзя.

Задание 2

Дано. Полиномиальная регрессия: $\tilde{f}(x, w) = \sum_{j=0}^{M} w_j x^j$, функция ошибки $E(w)$ из (1).

Требуется. Показать, что минимизирующие $E(w)$ коэффициенты являются решениями системы

$$\sum_{j=0}^{M} a_{ij} w_j = b_i, \qquad a_{ij} = \sum_{k=1}^{N} x_k^{i+j}, \qquad b_i = \sum_{k=1}^{N} x_k^i y_k, \qquad i = 0, \ldots, M. \tag{4}$$

Выяснить, всегда ли эта система разрешима.

Зачем это нужно. Именно эта система решается в программной реализации полиномиальной регрессии, поэтому нужно знать, когда её решение существует и единственно.

Решение.

Вывод системы. Подставим $\tilde{f}$ в (1) и продифференцируем по w_i. Производная внутренней скобки по w_i равна $-x_k^i$, множитель $1/2$ сокращается с двойкой:

$$\frac{\partial E}{\partial w_i} = -\sum_{k=1}^{N}\Big(y_k - \sum_{j=0}^{M} w_j x_k^j\Big)x_k^i = 0.$$

Раскрываем скобку и переносим слагаемое с y_k вправо:

$$\sum_{k=1}^{N}\sum_{j=0}^{M} w_j x_k^j x_k^i = \sum_{k=1}^{N} x_k^i y_k.$$

Меняем порядок суммирования в левой части (сумма конечна) и выносим w_j:

$$\sum_{j=0}^{M}\Big(\underbrace{\sum_{k=1}^{N} x_k^{i+j}}_{a_{ij}}\Big)w_j = \underbrace{\sum_{k=1}^{N} x_k^i y_k}_{b_i},$$

что и есть (4). ■

Матричная форма. Заметим, что $a_{ij} = \sum_k x_k^i x_k^j$ – это скалярное произведение i-го и j-го столбцов матрицы Вандермонда V. Значит

$$A = V^\top V, \qquad b = V^\top y,$$

то есть A – матрица Грама столбцов V, а система (4) есть $Aw = b$.

Когда решение единственно. По (2) $\ker A = \ker V$, а условие $Vw = 0$ означает, что многочлен $\sum_j w_j x^j$ степени не выше M обращается в нуль во всех узлах x_k. Обозначим через r число *различных* узлов. Если $r \geq M+1$, то ненулевой многочлен степени $\leq M$ не может иметь столько корней, значит $w = 0$ и $\ker A = \{0\}$. Если же $r \leq M$, то многочлен $\prod_{\text{различные } x_s}(x - x_s)$ имеет степень $r \leq M$, не равен тождественно нулю и обращается в нуль во всех узлах, то есть даёт ненулевой элемент ядра. Итого

$$\operatorname{rank} A = \min(r,\ M+1), \qquad \det A \neq 0 \iff r \geq M+1.$$

Совместность есть всегда. Из $\ker A = \ker V$ следует $\operatorname{rank} A = \operatorname{rank} V = \operatorname{rank} V^\top$. Кроме того $\operatorname{Im} A = \operatorname{Im}(V^\top V) \subseteq \operatorname{Im} V^\top$, а подпространство, вложенное в другое и имеющее ту же размерность, совпадает с ним:

$$\operatorname{Im} A = \operatorname{Im} V^\top.$$

Правая часть системы $b = V^\top y$ по построению лежит в $\operatorname{Im} V^\top$, а значит и в $\operatorname{Im} A$. Следовательно система (4) совместна при любой выборке.

Собирая вместе, ответ на вопрос задания:

– если различных узлов не меньше $M+1$, решение существует и единственно;

– если различных узлов $r \le M$, решение по-прежнему существует, но их бесконечно много: множество решений – аффинное подпространство размерности $M+1-r$. Все эти решения задают многочлены, принимающие в узлах одни и те же значения, и дают одну и ту же ошибку E. Различаются они лишь поведением между узлами, о котором выборка ничего не говорит.

Замечание о вычислениях. Формальной невырожденности мало. Если узлы лежат в $[0,1]$ и распределены равномерно, то

$$a_{ij} = \sum_k x_k^{i+j} \approx N \int_0^1 x^{i+j}\,\mathrm{d}x = \frac{N}{i+j+1},$$

то есть A с точностью до множителя N совпадает с матрицей Гильберта – классическим примером плохо обусловленной матрицы. Её число обусловленности растёт с M экспоненциально: при $M=5$ оно порядка 10^7, при $M=10$ около $5\cdot10^{14}$, при $M=11$ больше 10^{16}, и в двойной точности матрица становится численно вырожденной, хотя формально остаётся невырожденной. Это одна из причин, по которым при больших M переходят к регуляризации или к ортогональным системам многочленов вместо степеней x^j.