Задача 3. Метод наименьших квадратов

Нейронные сети и машинное обучение

Задания 1 и 2

1 Что нужно знать

1.1 Обозначения

(x_k, y_k)	точка выборки, $k = 1, \ldots, N$; $x_k = x^{(k)}$, $y_k = y^{(k)}$
$\sum_k$; $\sum_i$, $\sum_j$	суммы по $k = 1, \ldots, N$; по $i, j = 0, \ldots, M$
x_k^i	i-я степень числа x_k, $x_k^0 = 1$
$\bar{x}$, $\bar{y}$	средние: $\bar{x} = \frac{1}{N}\sum_k x_k$, $\bar{y} = \frac{1}{N}\sum_k y_k$
$\tilde{f}(x, w)$	модель: по x и параметрам w возвращает предсказание y
d_k	отклонение точки от модели: $d_k = y_k - \tilde{f}(x_k, w)$
$E(w)$	функция ошибки: по параметрам w возвращает число
A, B	параметры прямой $\tilde{f}(x) = Ax + B$
$p_w(x)$	многочлен степени не выше M: по x возвращает $\sum_{j=0}^{M} w_j x^j$
Δ	определитель системы линейных уравнений
$t_1, \ldots, t_r$	различные числа среди $x_1, \ldots, x_N$, r – их количество
$\bar{y}_s$	среднее тех y_k, у которых $x_k = t_s$

1.2 Метод наименьших квадратов

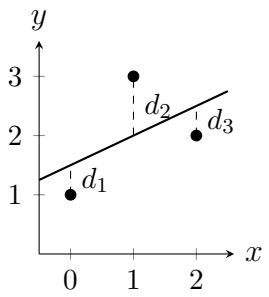
Значения y_k измерены с ошибкой, и модель проходит через точки неточно. Функция ошибки получает параметры модели и возвращает полусумму квадратов отклонений:

$$E(w) = \frac{1}{2}\sum_{k=1}^{N}\big(y_k - \tilde{f}(x_k, w)\big)^2 = \frac{1}{2}\sum_{k=1}^{N} d_k^2.$$

Метод наименьших квадратов выбирает w, на котором E минимальна. Сумма квадратов не меньше нуля и равна нулю только тогда, когда все слагаемые равны нулю.

Пример, который используется и дальше: три точки и прямая $\tilde{f}(x) = \frac{1}{2}x + \frac{3}{2}$.

k	1	2	3	$\sum_k$
x_k	0	1	2	3
y_k	1	3	2	6
x_k^2	0	1	4	5
$x_k y_k$	0	3	4	7
d_k	−0,5	1	−0,5	



Ошибка этой прямой и прямой $y = 2$ (её отклонения -1, 1, 0):

$$E\big(\tfrac{1}{2}, \tfrac{3}{2}\big) = \tfrac{1}{2}(0{,}25 + 1 + 0{,}25) = 0{,}75, \qquad E(0, 2) = \tfrac{1}{2}(1 + 1 + 0) = 1.$$

Условие минимума. Частная производная $\partial E/\partial A$ – производная по A при постоянном B. В точке минимума все частные производные равны нулю (необходимое

условие). В примере, по правилу $(u^2)' = 2u\,u'$,

$$E(A,B) = \tfrac{1}{2}\big[(1-B)^2 + (3-A-B)^2 + (2-2A-B)^2\big],$$
$$\frac{\partial E}{\partial A} = -(3-A-B) - 2(2-2A-B) = 5A + 3B - 7,$$
$$\frac{\partial E}{\partial B} = -(1-B) - (3-A-B) - (2-2A-B) = 3A + 3B - 6,$$

и условия минимума – система линейных уравнений $5A + 3B = 7$, $3A + 3B = 6$ с суммами из таблицы. Для любой выборки так же получается система (4) задания 1.

1.3 Линейные системы

Система n линейных уравнений с n неизвестными *разрешима*, если у неё есть хотя бы одно решение. *Определитель* получает квадратную таблицу чисел и возвращает число; для таблицы 2×2

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc, \qquad \begin{vmatrix} 5 & 3 \\ 3 & 3 \end{vmatrix} = 5 \cdot 3 - 3 \cdot 3 = 6.$$

Определитель системы Δ составлен из коэффициентов при неизвестных и от правых частей не зависит.

Правило Крамера. Если $\Delta \neq 0$, то решение существует и единственно: j-е неизвестное равно Δ_j/Δ, где Δ_j – определитель, в котором j-й столбец заменён столбцом правых частей. В примере $\Delta = 6$ и

$$A = \frac{1}{6}\begin{vmatrix} 7 & 3 \\ 6 & 3 \end{vmatrix} = \frac{21-18}{6} = \frac{1}{2}, \qquad B = \frac{1}{6}\begin{vmatrix} 5 & 7 \\ 3 & 6 \end{vmatrix} = \frac{30-21}{6} = \frac{3}{2}.$$

Теорема Кронекера-Капелли (нужна, когда $\Delta = 0$). Система разрешима тогда и только тогда, когда ранг таблицы коэффициентов равен рангу расширенной таблицы (с приписанным столбцом правых частей); если этот общий ранг меньше числа неизвестных, решений бесконечно много. Ранг таблицы – наибольшее число её линейно независимых строк; у таблицы из двух строк ранг 2, если строки не пропорциональны, и 1, если пропорциональны и не обе нулевые.

Однородная система – система с той же таблицей коэффициентов и нулевыми правыми частями, $z = 0$ – всегда её решение. Их решения связаны так:

- $\Delta \neq 0$ тогда и только тогда, когда однородная система имеет только решение $z = 0$;
- если w – решение системы, а z – однородной, то $w + cz$ – решение системы при любом c;
- разность двух решений системы – решение однородной.

Примеры (ранги таблицы коэффициентов и расширенной):

система	Δ	ранги	решения
$u + 2v = 3,\ \ 2u + 4v = 6$	0	1 и 1	$(3,0) + c\,(-2,1)$
$u + 2v = 3,\ \ 2u + 4v = 5$	0	1 и 2	нет
$u + 2v = 0,\ \ 2u + 4v = 0$	0	1 и 1	$c\,(-2,1)$
$u + 2v = 0,\ \ 3u + 4v = 0$	-2	2 и 2	только $(0,0)$

В первой строке второе уравнение – первое, умноженное на 2 вместе с правой частью; во второй левая часть умножена на 2, а правая нет: $2 \cdot 3 \neq 5$.

1.4 Средние

Среднее получает числа и возвращает их сумму, делённую на количество. Сумма отклонений от среднего равна нулю: $\sum_k (y_k - \bar{y}) = \sum_k y_k - N\bar{y} = 0$. В примере $\bar{x} = 1$, $\bar{y} = 2$ и $(1-2) + (3-2) + (2-2) = 0$.

Числа x_k (узлы) могут повторяться. Различные из них обозначаются $t_1, \ldots, t_r$, а $\bar{y}_s$ – среднее тех y_k, у которых $x_k = t_s$. Пример:

k	1	2	3	4
x_k	1	1	3	3
y_k	1	3	3	5

$$r = 2, \quad t_1 = 1, \quad t_2 = 3, \quad \bar{y}_1 = \frac{1+3}{2} = 2, \quad \bar{y}_2 = \frac{3+5}{2} = 4.$$

1.5 Многочлены

Многочлен степени не выше M с коэффициентами $z = (z_0, \ldots, z_M)$ получает число x и возвращает число

$$p_z(x) = z_0 + z_1 x + \cdots + z_M x^M.$$

Коэффициенты могут быть нулевыми: при $M = 3$ и $z = (-1, 0, 1, 0)$ многочлен $p_z(x) = x^2 - 1$, например, $p_z(2) = 3$. Многочлен *нулевой*, если $z = 0$; он равен нулю при всех x.

Корень многочлена p – число a с $p(a) = 0$: у $x^2 - 1 = (x-1)(x+1)$ корни 1 и -1.

Число корней. Ненулевой многочлен степени не выше M имеет не больше M различных корней. По теореме Безу корень a отделяет множитель: $p(x) = (x-a)\,q(x)$, степень q на 1 меньше; другой корень $b \neq a$ – корень q:

$$0 = p(b) = \underbrace{(b-a)}_{\neq 0}\, q(b), \qquad q(b) = 0.$$

Поэтому s различных корней дают $p(x) = (x-a_1)\cdots(x-a_s)\,q_s(x)$ с ненулевым q_s, степень p не меньше s и $s \leq M$. Значит, многочлен степени не выше M, равный нулю в $M+1$ различных точках, нулевой.

Многочлен Лагранжа получает r точек (t_s, v_s) с различными t_s и возвращает многочлен степени не выше $r-1$, проходящий через них:

$$q(x) = \sum_{s=1}^{r} v_s \prod_{u \neq s} \frac{x - t_u}{t_s - t_u}.$$

При $x = t_s$ произведение в s-м слагаемом равно 1, в остальных слагаемых есть множитель $t_s - t_s = 0$, поэтому $q(t_s) = v_s$; в каждом слагаемом $r-1$ множителей с x. При $r = 1$ произведение пустое и $q(x) = v_1$. Через точки $(1, 2)$ и $(3, 4)$:

$$q(x) = 2 \cdot \frac{x-3}{1-3} + 4 \cdot \frac{x-1}{3-1} = -(x-3) + 2(x-1) = x + 1.$$

2 Задания

Задание 1

Дано. Линейная регрессия $\tilde{f}(x) = Ax + B$, функция ошибки

$$E(A, B) = \frac{1}{2} \sum_{k=1}^{N} \big(y_k - Ax_k - B\big)^2.$$

Условия $\partial E/\partial A = 0$ и $\partial E/\partial B = 0$ дают систему

$$\begin{cases} \Big(\sum_k x_k^2\Big)A + \Big(\sum_k x_k\Big)B = \sum_k x_k y_k, \\ \Big(\sum_k x_k\Big)A + NB = \sum_k y_k. \end{cases} \tag{4}$$

Требуется. Указать, когда разрешима система (4), и объяснить, почему решение в этом случае единственно. Выяснить, какой выборке соответствует равенство нулю определителя системы.

Зачем это нужно. По системе (4) строят прямую регрессии; важно, одна ли она.

Решение. *Что нужно проверить.* При $\Delta \neq 0$ решение существует и единственно по правилу Крамера, при $\Delta = 0$ разрешимость проверяется по теореме Кронекера-Капелли. Нужно найти Δ и выяснить, когда $\Delta = 0$.

Шаг 1: определитель. Так как $\sum_k x_k = N\bar{x}$,

$$\Delta = \begin{vmatrix} \sum_k x_k^2 & \sum_k x_k \\ \sum_k x_k & N \end{vmatrix} = N\sum_k x_k^2 - N^2\bar{x}^2 = N\sum_k (x_k - \bar{x})^2,$$

где последнее равенство – раскрытие квадрата:

$$\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - 2\bar{x}\underbrace{\sum_k x_k}_{N\bar{x}} + N\bar{x}^2 = \sum_k x_k^2 - N\bar{x}^2.$$

Сумма квадратов равна нулю только при нулевых слагаемых, поэтому

$$\Delta = 0 \ \text{ при } \ x_1 = \cdots = x_N, \qquad \Delta > 0 \ \text{ иначе.}$$

Шаг 2: не все x_k равны. $\Delta > 0$, и по правилу Крамера решение единственно:

$$A = \frac{N\sum_k x_k y_k - \sum_k x_k \sum_k y_k}{\Delta}, \qquad B = \frac{\sum_k x_k^2 \sum_k y_k - \sum_k x_k \sum_k x_k y_k}{\Delta}.$$

Шаг 3: $x_1 = \cdots = x_N = x_0$. Тогда $\Delta = 0$. Подставим $\sum_k x_k = Nx_0$, $\sum_k x_k^2 = Nx_0^2$, $\sum_k y_k = N\bar{y}$, $\sum_k x_k y_k = Nx_0\bar{y}$ в расширенную таблицу системы (4):

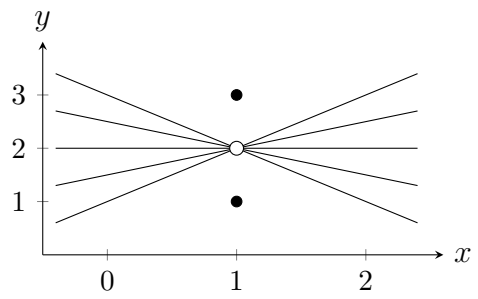
$$\left(\begin{array}{cc|c} Nx_0^2 & Nx_0 & Nx_0\bar{y} \\ Nx_0 & N & N\bar{y} \end{array}\right), \qquad \underbrace{(Nx_0^2,\ Nx_0,\ Nx_0\bar{y})}_{\text{строка 1}} = x_0 \underbrace{(Nx_0,\ N,\ N\bar{y})}_{\text{строка 2}}.$$

Строка 2 ненулевая ($N \neq 0$), поэтому ранги обеих таблиц равны $1 < 2$ (числа неизвестных): по теореме Кронекера-Капелли решений бесконечно много.

Остаётся второе уравнение:

$$Nx_0A + NB = N\bar{y},$$
$$B = \bar{y} - x_0A, \quad A \text{ любое.}$$

Это все прямые через точку $(x_0, \bar{y})$. На рисунке $x_1 = x_2 = 1$, $y_1 = 1$, $y_2 = 3$, $\bar{y} = 2$.



Ответ. Система (4) разрешима при любой выборке, $\Delta = N\sum_k (x_k - \bar{x})^2$:

не все x_k равны: $\Delta > 0$, решение единственно (правило Крамера);
$x_1 = \dots = x_N = x_0$: $\Delta = 0$, $B = \bar{y} - x_0 A$, A любое.

$\Delta = 0$ – все точки выборки на вертикальной прямой $x = x_0$ (например, $N = 1$).

Замечание: любое решение системы (4) *даёт минимум* E. Для $d_k = y_k - Ax_k - B$ уравнения (4) – это $\sum_k x_k d_k = 0$ и $\sum_k d_k = 0$, поэтому при любых a, b

$$E(A+a, B+b) = \frac{1}{2}\sum_k \big(d_k - (ax_k + b)\big)^2$$
$$= E(A,B) - a\underbrace{\sum_k x_k d_k}_{0} - b\underbrace{\sum_k d_k}_{0} + \frac{1}{2}\sum_k (ax_k + b)^2 \;\geq\; E(A,B).$$

Задание 2

Дано. Полиномиальная регрессия $\tilde{f}(x, w) = p_w(x) = \sum_{j=0}^{M} w_j x^j$, функция ошибки

$$E(w) = \frac{1}{2}\sum_{k=1}^{N} \big(y_k - p_w(x_k)\big)^2.$$

Требуется. Показать, что коэффициенты w, минимизирующие $E(w)$, являются решениями системы

$$\sum_{j=0}^{M} a_{ij} w_j = b_i, \quad i = 0, \dots, M, \qquad a_{ij} = \sum_{k=1}^{N} x_k^{i+j}, \quad b_i = \sum_{k=1}^{N} x_k^i y_k.$$

Выяснить, всегда ли эта система разрешима.

Зачем это нужно. Эту систему решает программа полиномиальной регрессии.

Решение. *Что нужно проверить.* Система – это условия минимума $\partial E/\partial w_i = 0$. По правилу Крамера решение существует и единственно при $\Delta \neq 0$, то есть когда однородная система $\sum_j a_{ij} z_j = 0$ имеет только решение $z = 0$; при $\Delta = 0$ решение предъявим.

Шаг 1: вывод системы. Так как $\partial p_w(x_k)/\partial w_i = x_k^i$,

$$\frac{\partial E}{\partial w_i} = \frac{1}{2}\sum_{k=1}^{N} 2\big(y_k - p_w(x_k)\big)\big(-x_k^i\big) = -\sum_{k=1}^{N} x_k^i \big(y_k - p_w(x_k)\big) = 0. \qquad (*)$$

Условие $(*)$ с $p_w(x_k) = \sum_j w_j x_k^j$ после перемены порядка суммирования:

$$\underbrace{\sum_{k=1}^{N} x_k^i y_k}_{b_i} = \sum_{k=1}^{N} x_k^i \sum_{j=0}^{M} w_j x_k^j = \sum_{j=0}^{M} \underbrace{\Big(\sum_{k=1}^{N} x_k^{i+j}\Big)}_{a_{ij}} w_j.$$

Преобразования обратимы: система равносильна условиям $(*)$, и минимизирующие E коэффициенты – её решения.

Шаг 2: однородная система. Её левая часть выражается через значения p_z в узлах:

$$\sum_j a_{ij} z_j = \sum_k x_k^i \underbrace{\sum_j z_j x_k^j}_{p_z(x_k)} = \sum_k x_k^i \, p_z(x_k).$$

Если $p_z(x_k) = 0$ при всех k, то z – решение. Обратно, если z – решение, умножим i-е уравнение на z_i и сложим:

$$0 = \sum_i z_i \sum_k x_k^i \, p_z(x_k) = \sum_k p_z(x_k) \underbrace{\sum_i z_i x_k^i}_{p_z(x_k)} = \sum_k p_z(x_k)^2,$$

откуда $p_z(x_k) = 0$ при всех k. Итак, z – решение однородной системы тогда и только тогда, когда $p_z(t_1) = \dots = p_z(t_r) = 0$.

Шаг 3: $r \geq M+1$. По шагу 2 у p_z не меньше $M+1$ различных корней, поэтому p_z нулевой и $z = 0$. Значит, $\Delta \neq 0$, и по правилу Крамера решение системы существует и единственно.

Шаг 4: $r \leq M$. Многочлен $(x-t_1)\cdots(x-t_r) = x^r + \dots$ ненулевой, степени $r \leq M$ и равен нулю во всех узлах. Его коэффициенты, дополненные нулями, – решение $z \neq 0$ однородной системы (шаг 2), поэтому $\Delta = 0$ и правило Крамера неприменимо.

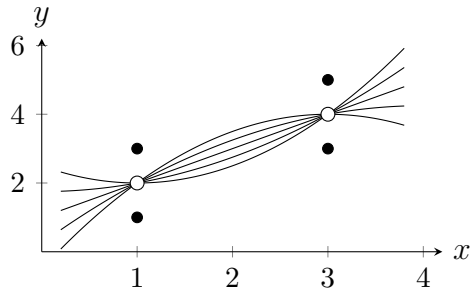
Шаг 5: решение при $r \leq M$. По шагу 1 нужен многочлен q степени не выше M, для которого выполнено $(*)$. При $x_k = t_s$ имеем $x_k^i = t_s^i$ и $q(x_k) = q(t_s)$, поэтому

$$\sum_{k=1}^N x_k^i \big(y_k - q(x_k)\big) = \sum_{s=1}^r t_s^i \underbrace{\sum_{k:\, x_k = t_s} \big(y_k - q(t_s)\big)}_{0 \text{ при } q(t_s) = \bar{y}_s},$$

так как сумма отклонений от среднего равна нулю. Многочлен Лагранжа через точки $(t_s, \bar{y}_s)$ имеет степень не выше $r-1 < M$; его коэффициенты, дополненные нулями, дают решение w.

Решений бесконечно много: $w + cz$ с z из шага 4. Разность двух решений – решение однородной системы, поэтому (шаг 2) их многочлены совпадают во всех узлах и дают одно значение E. На рисунке $M = 2$, выборка из раздела о средних, решения

$$x + 1 + c\,(x-1)(x-3).$$



Ответ. Минимизирующие E коэффициенты удовлетворяют $(*)$, то есть системе. Система разрешима при любой выборке:

$$\begin{aligned} r \geq M+1: &\quad \Delta \neq 0, \quad \text{решение единственно;} \\ r \leq M: &\quad \Delta = 0, \quad \text{решений бесконечно много.} \end{aligned}$$

Так как $r \leq N$, для единственности нужно $N \geq M+1$.

Замечание. При $M = 1$, $w_0 = B$, $w_1 = A$ система совпадает с (4), а условие $r \geq 2$ – с условием задания 1.