

Задача 3. Метод наименьших квадратов

Нейронные сети и машинное обучение

Задания 1, 2 и 4

1 Что нужно знать

1.1 Обозначения

$\{(x_k, y_k)\}_{k=1}^N$	выборка, $x_k = x^{(k)}$, $y_k = y^{(k)}$
$\tilde{f}(x, w)$	восстанавливаемая зависимость с параметрами w
$E(w)$	функция ошибки
M	степень многочлена в полиномиальной регрессии
$A^\top$	транспонированная матрица
$\ker A$	ядро: множество w , для которых $Aw = 0$
$\text{Im } A$	образ: множество значений Aw
$\text{rank } A$	ранг, $\text{rank } A = \dim \text{Im } A$
$\ w\ _1, \ w\ _2$	нормы L_1 и L_2
$\hat{w}$	решение метода наименьших квадратов без регуляризации
η	радиус сферы в норме L_1
e_i	i -й базисный вектор

1.2 Задача регрессии и метод наименьших квадратов

Дана выборка $\{(x_k, y_k)\}_{k=1}^N$, где значения y_k получены с некоторой случайной ошибкой измерения. Требуется восстановить зависимость $y = f(x)$. Метод наименьших квадратов выбирает ту функцию из заданного семейства, которая даёт наименьшую сумму квадратов отклонений:

$$E(w) = \frac{1}{2} \sum_{k=1}^N (y_k - \tilde{f}(x_k, w))^2 \longrightarrow \min_w. \quad (1)$$

Множитель $1/2$ поставлен только для того, чтобы он сократился при дифференцировании.

Если $\tilde{f}$ линейно зависит от параметров w (а это так и для линейной, и для полиномиальной регрессии), то $E(w)$ – квадратичная функция от w . Необходимое условие минимума – равенство нулю всех частных производных $\partial E / \partial w_j$. Оно приводит к системе линейных уравнений, которую называют *системой нормальных уравнений*.

1.3 Матрица Грама

Пусть Φ – матрица, столбцы которой – какие-то векторы из $\mathbb{R}^N$. Матрица $G = \Phi^\top \Phi$ называется *матрицей Грама* этих столбцов: её элемент G_{ij} равен скалярному произведению i -го и j -го столбцов. Нам понадобятся два её свойства.

Неотрицательная определённость. Для любого w

$$w^\top G w = w^\top \Phi^\top \Phi w = (\Phi w)^\top (\Phi w) = \|\Phi w\|^2 \geq 0.$$

Совпадение ядер. Если $Gw = 0$, то $\|\Phi w\|^2 = w^\top Gw = 0$, значит $\Phi w = 0$. Обратное очевидно. Поэтому

$$\ker G = \ker \Phi, \quad \text{rank } G = \text{rank } \Phi. \quad (2)$$

В частности G невырождена тогда и только тогда, когда столбцы Φ линейно независимы.

1.4 Число обусловленности

Число обусловленности $\text{cond } A = \|A\| \cdot \|A^{-1}\|$ показывает, во сколько раз ошибка в правой части системы $Aw = b$ может усилиться в решении. При $\text{cond } A \sim 10^{16}$ в двойной точности от решения не остаётся ни одной верной цифры: формально невырожденная матрица становится вырожденной численно.

1.5 Многочлены и матрица Вандермонда

Ненулевой многочлен степени не выше M имеет не более M корней. Отсюда следует нужное нам утверждение: если многочлен степени $\leq M$ обращается в нуль более чем в M различных точках, то он тождественно нулевой.

Матрицей Вандермонда для узлов $x_1, \dots, x_N$ называется

$$V = (x_k^j)_{k=1..N, j=0..M} = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^M \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_N & x_N^2 & \dots & x_N^M \end{pmatrix}.$$

Умножение Vw даёт вектор значений многочлена $\sum_j w_j x^j$ в узлах $x_1, \dots, x_N$.

1.6 Регуляризация

Чтобы коэффициенты не становились слишком большими, к функции ошибки добавляют штраф за их величину:

$$E_\lambda(w) = E(w) + \frac{\lambda}{2} \sum_{i=1}^M |w_i|^q, \quad \lambda > 0. \quad (3)$$

Свободный член w_0 обычно не штрафуют. При $q = 2$ регуляризацию называют гребневой, при $q = 1$ – ЛАССО. Нормы векторов: $\|w\|_1 = \sum_i |w_i|$ и $\|w\|_2 = (\sum_i w_i^2)^{1/2}$.

Форма с ограничением. Пусть $\tilde{w}$ – точка минимума E_λ при $q = 1$ и $\eta = \|\tilde{w}\|_1$. Тогда $\tilde{w}$ – точка минимума E на шаре $\|w\|_1 \leq \eta$: для любого w из этого шара

$$E(w) = E_\lambda(w) - \frac{\lambda}{2} \|w\|_1 \geq E_\lambda(\tilde{w}) - \frac{\lambda}{2} \eta = E(\tilde{w}).$$

Поэтому решение лежит там, где линия уровня E касается сферы $\|w\|_1 = \eta$, если минимум E без штрафа лежит вне шара. Чем больше λ , тем меньше η .

1.7 Сфера в норме L_1

Множество $\{w : \|w\|_1 = \eta\}$ при двух координатах – квадрат с вершинами $(\pm\eta, 0)$ и $(0, \pm\eta)$ на осях, его стороны наклонены к осям под углом 45° . При n координатах это многогранник с $2n$ вершинами $\pm\eta e_i$; в условии задания 4 он назван гиперкубом. В вершине все координаты, кроме одной, равны нулю. Сфера в норме L_2 – окружность, вершин у неё нет.

1.8 Вероятность и площадь

Если случайный вектор на плоскости имеет плотность распределения, то вероятность попасть в множество нулевой площади, например на прямую, равна нулю. Для убывающих событий $B_1 \supseteq B_2 \supseteq \dots$ выполняется $P(B_n) \rightarrow P(\bigcap_n B_n)$ (непрерывность вероятности). Если вектор $y \in \mathbb{R}^N$ имеет плотность, а матрица C размера $n \times N$ имеет ранг n , то вектор Cy тоже имеет плотность.

2 Задания

Задание 1

Дано. Линейная регрессия: восстанавливаемая зависимость имеет вид $\tilde{f}(x) = Ax + B$ с двумя неизвестными параметрами. Функция ошибки

$$E(A, B) = \frac{1}{2} \sum_{k=1}^N (y_k - Ax_k - B)^2,$$

а условие минимума $\partial E / \partial A = \partial E / \partial B = 0$ даёт систему нормальных уравнений

$$\begin{cases} \left(\sum_k x_k^2 \right) A + \left(\sum_k x_k \right) B = \sum_k x_k y_k, \\ \left(\sum_k x_k \right) A + NB = \sum_k y_k. \end{cases} \quad (4)$$

Требуется. Указать, когда система (4) разрешима; объяснить, почему в этом случае решение единственно; описать выборку, для которой определитель системы равен нулю.

Зачем это нужно. Линейная регрессия – простейший случай метода наименьших квадратов. На нём видно, от чего зависит единственность решения нормальных уравнений.

Решение.

Определитель. Выпишем матрицу системы и заметим, что она является матрицей Грама:

$$G = \begin{pmatrix} \sum_k x_k^2 & \sum_k x_k \\ \sum_k x_k & N \end{pmatrix} = \Phi^\top \Phi, \quad \Phi = \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{pmatrix}.$$

Действительно, скалярное произведение первого столбца на себя равно $\sum_k x_k^2$, первого на второй – $\sum_k x_k$, второго на себя – N .

Считаем определитель, обозначив $\bar{x} = \frac{1}{N} \sum_k x_k$:

$$\det G = N \sum_k x_k^2 - \left(\sum_k x_k \right)^2 = N \sum_k x_k^2 - N^2 \bar{x}^2 = N \sum_k (x_k - \bar{x})^2.$$

Последний переход – обычное преобразование суммы квадратов отклонений: $\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - N \bar{x}^2$.

Полученное выражение неотрицательно как сумма квадратов, и обращается в нуль только когда все слагаемые нулевые:

$$\det G = 0 \iff x_k = \bar{x} \text{ для всех } k \iff \text{все } x_k \text{ совпадают.}$$

Значит система (4) однозначно разрешима тогда и только тогда, когда среди x_k есть хотя бы два различных значения. Тот же вывод получается и из (2): столбцы Φ – это вектор $(x_1, \dots, x_N)$ и вектор из единиц, они линейно зависимы ровно тогда, когда первый тоже постоянен.

Единственность. Единственность решения невырожденной линейной системы – факт линейной алгебры. Но здесь важнее другое: найденная точка действительно даёт минимум, а не какую-то иную стационарную точку. Функция $E(A, B)$ квадратична, и её матрица вторых производных равна как раз G . При $\det G > 0$ (а след G положителен всегда) матрица G положительно определена, значит E строго выпукла. У строго выпуклой функции стационарная точка единственна и является точкой глобального минимума.

Вырожденный случай. Равенство $\det G = 0$ означает, что все измерения выполнены при одном и том же значении $x_k \equiv x_0$: точки выборки лежат на одной вертикальной прямой. Подставим это в функцию ошибки:

$$E(A, B) = \frac{1}{2} \sum_k (y_k - (Ax_0 + B))^2.$$

Она зависит от A и B только через одну комбинацию $t = Ax_0 + B$ и минимальна при $t = \bar{y}$ (задача о постоянной величине: минимум суммы квадратов отклонений достигается на среднем арифметическом). Решением служит вся прямая $Ax_0 + B = \bar{y}$ в плоскости параметров: бесконечно много пар (A, B) , дающих одну и ту же ошибку. Содержательно это очевидно: по точкам, стоящим на одной вертикали, наклон прямой определить нельзя.

Задание 2

Дано. Полиномиальная регрессия: $\tilde{f}(x, w) = \sum_{j=0}^M w_j x^j$, функция ошибки $E(w)$ из (1).

Требуется. Показать, что минимизирующие $E(w)$ коэффициенты являются решениями системы

$$\sum_{j=0}^M a_{ij} w_j = b_i, \quad a_{ij} = \sum_{k=1}^N x_k^{i+j}, \quad b_i = \sum_{k=1}^N x_k^i y_k, \quad i = 0, \dots, M. \quad (5)$$

Выяснить, всегда ли эта система разрешима.

Зачем это нужно. Именно эта система решается в программной реализации полиномиальной регрессии, поэтому нужно знать, когда её решение существует и единственно.

Решение.

Вывод системы. Подставим $\tilde{f}$ в (1) и продифференцируем по w_i . Производная внутренней скобки по w_i равна $-x_k^i$, множитель $1/2$ сокращается с двойкой:

$$\frac{\partial E}{\partial w_i} = - \sum_{k=1}^N \left(y_k - \sum_{j=0}^M w_j x_k^j \right) x_k^i = 0.$$

Раскрываем скобку и переносим слагаемое с y_k вправо:

$$\sum_{k=1}^N \sum_{j=0}^M w_j x_k^j x_k^i = \sum_{k=1}^N x_k^i y_k.$$

Меняем порядок суммирования в левой части (сумма конечна) и выносим w_j :

$$\sum_{j=0}^M \underbrace{\left(\sum_{k=1}^N x_k^{i+j} \right)}_{a_{ij}} w_j = \sum_{k=1}^N \underbrace{x_k^i y_k}_{b_i},$$

что и есть (5). ■

Матричная форма. Заметим, что $a_{ij} = \sum_k x_k^i x_k^j$ – это скалярное произведение i -го и j -го столбцов матрицы Вандермонда V . Значит

$$A = V^\top V, \quad b = V^\top y,$$

то есть A – матрица Грама столбцов V , а система (5) есть $Aw = b$.

Когда решение единственно. По (2) $\ker A = \ker V$, а условие $Vw = 0$ означает, что многочлен $\sum_j w_j x^j$ степени не выше M обращается в нуль во всех узлах x_k . Обозначим через r число *различных* узлов. Если $r \geq M + 1$, то ненулевой многочлен степени $\leq M$ не может иметь столько корней, значит $w = 0$ и $\ker A = \{0\}$. Если же $r \leq M$, то многочлен $\prod_{\text{различные } x_s} (x - x_s)$ имеет степень $r \leq M$, не равен тождественно нулю и обращается в нуль во всех узлах, то есть даёт ненулевой элемент ядра. Итого

$$\text{rank } A = \min(r, M + 1), \quad \det A \neq 0 \iff r \geq M + 1.$$

Совместность есть всегда. Из $\ker A = \ker V$ следует $\text{rank } A = \text{rank } V = \text{rank } V^\top$. Кроме того $\text{Im } A = \text{Im}(V^\top V) \subseteq \text{Im } V^\top$, а подпространство, вложенное в другое и имеющее ту же размерность, совпадает с ним:

$$\text{Im } A = \text{Im } V^\top.$$

Правая часть системы $b = V^\top y$ по построению лежит в $\text{Im } V^\top$, а значит и в $\text{Im } A$. Следовательно система (5) совместна при любой выборке.

Собирая вместе, ответ на вопрос задания:

- если различных узлов не меньше $M + 1$, решение существует и единственно;
- если различных узлов $r \leq M$, решение по-прежнему существует, но их бесконечно много: множество решений – аффинное подпространство размерности $M + 1 - r$. Все эти решения задают многочлены, принимающие в узлах одни и те же значения, и дают одну и ту же ошибку E . Различаются они лишь поведением между узлами, о котором выборка ничего не говорит.

Замечание о вычислениях. Формальной невырожденности мало. Если узлы лежат в $[0, 1]$ и распределены равномерно, то

$$a_{ij} = \sum_k x_k^{i+j} \approx N \int_0^1 x^{i+j} dx = \frac{N}{i + j + 1},$$

то есть A с точностью до множителя N совпадает с матрицей Гильберта – классическим примером плохо обусловленной матрицы. Её число обусловленности растёт с M экспоненциально: при $M = 5$ оно порядка 10^7 , при $M = 10$ около $5 \cdot 10^{14}$, при $M = 11$ больше 10^{16} , и в двойной точности матрица становится численно вырожденной, хотя формально остаётся невырожденной. Это одна из причин, по которым при больших

M переходят к регуляризации или к ортогональным системам многочленов вместо степеней x^j .

Задание 4

Дано. Полиномиальная регрессия с ЛАССО-регуляризацией: минимизируется E_λ из (3) при $q = 1$. Матрица A системы (5) невырождена. Измеренные значения y_k содержат случайную ошибку, имеющую плотность распределения. Для простоты штрафуются все коэффициенты вектора w , случай нештрафуемого w_0 разобран в замечании. **Требуется.** Доказать, что линии уровня функции ошибки E и сфера в норме L_1 с центром в начале координат (в условии названная гиперкубом) с вероятностью 1 касаются в вершинах этой сферы. Выяснить, чем определяется центр окружностей – линий уровня функции ошибки без регуляризационного слагаемого.

Зачем это нужно. Объясняет, почему ЛАССО-регуляризация обнуляет часть коэффициентов, то есть убирает из модели лишние базисные функции, а гребневая только уменьшает коэффициенты.

Решение.

Центр линий уровня. Пусть $\hat{w}$ – решение системы $A\hat{w} = b$, то есть точка минимума E без регуляризации. В матричной записи $E(w) = \frac{1}{2} \|y - Vw\|_2^2$. Подставим $y - Vw = (y - V\hat{w}) - V(w - \hat{w})$:

$$E(w) = E(\hat{w}) - (w - \hat{w})^\top V^\top (y - V\hat{w}) + \frac{1}{2} (w - \hat{w})^\top V^\top V (w - \hat{w}).$$

Среднее слагаемое равно нулю, так как $V^\top (y - V\hat{w}) = b - A\hat{w} = 0$. Поэтому

$$E(w) = E(\hat{w}) + \frac{1}{2} (w - \hat{w})^\top A (w - \hat{w}). \quad (6)$$

Линии уровня $E(w) = c$ – эллипсы с центром $\hat{w}$, при $A = aI$ – окружности. Центр определяется выборкой: это решение метода наименьших квадратов без регуляризации $\hat{w} = A^{-1}b$, где A зависит от узлов x_k , а b ещё и от измеренных значений y_k . Вектор $\hat{w} = A^{-1}V^\top y$ получается из y умножением на матрицу ранга $M + 1$, поэтому центр – случайный вектор с плотностью распределения.

Простой случай: два коэффициента, окружности. Пусть $w = (w_1, w_2)$ и $A = aI$, $a > 0$. По (6) $E(w) = E(\hat{w}) + \frac{a}{2} \|w - \hat{w}\|_2^2$, то есть E растёт вместе с расстоянием от w до $\hat{w}$. Зафиксируем $\eta > 0$ и найдём минимум E на шаре $\|w\|_1 \leq \eta$: по форме с ограничением задача с λ сводится к такой. Это ближайшая к $\hat{w}$ точка шара.

Если $\hat{w}$ лежит внутри шара, ответ $\hat{w}$ и касания нет. Пусть $\hat{w} = (u, v)$ лежит вне шара, тогда ближайшая точка лежит на его границе. Смена знака координаты переводит шар в себя и не меняет расстояний, поэтому можно считать $u, v \geq 0$. Ближайшая точка тоже лежит в первой четверти: точка $(|w_1|, |w_2|)$ принадлежит шару и не дальше от $\hat{w}$, чем w . В первой четверти граница шара – сторона $S = \{w_1 + w_2 = \eta, w_1, w_2 \geq 0\}$.

Основание перпендикуляра из $\hat{w}$ на прямую $w_1 + w_2 = \eta$:

$$p = \hat{w} - \frac{u + v - \eta}{2} (1, 1), \quad p_1 = \frac{u - v + \eta}{2}, \quad p_2 = \frac{v - u + \eta}{2}.$$

Расстояние от $\hat{w}$ до точки прямой растёт с удалением этой точки от p . Отсюда три случая:

- $|u - v| < \eta$: $p_1 > 0$ и $p_2 > 0$, точка p лежит внутри стороны S и является ответом. Окружность касается стороны, обе координаты ответа ненулевые;
- $u - v \geq \eta$: $p_2 \leq 0$, ближайшая точка отрезка S – его конец $(\eta, 0)$, вершина сферы;
- $v - u \geq \eta$: так же получается вершина $(0, \eta)$.

Возвращая знаки, получаем: касание происходит в вершине тогда и только тогда, когда

$$||\hat{w}_1| - |\hat{w}_2|| \geq \eta. \quad (7)$$

Если это неравенство не выполнено, то либо центр лежит внутри шара, либо окружность касается стороны, и тогда центр лежит в полосе ширины $\eta\sqrt{2}$ напротив этой стороны.

Вероятность. События $B_\eta = \{||\hat{w}_1| - |\hat{w}_2|| < \eta\}$ убывают при уменьшении η , а их пересечение – событие $|\hat{w}_1| = |\hat{w}_2|$, то есть попадание $\hat{w}$ на две диагонали, множество нулевой площади. Центр $\hat{w}$ имеет плотность, поэтому по непрерывности вероятности

$$P(\text{решение не в вершине}) = P(B_\eta) \xrightarrow{\eta \rightarrow 0} P(|\hat{w}_1| = |\hat{w}_2|) = 0.$$

Итак, при сильной регуляризации (малом η , то есть большом λ) линии уровня касаются L_1 -сферы в вершине с вероятностью, стремящейся к 1, и один из коэффициентов решения равен нулю. При фиксированном $\eta > 0$ касание по стороне тоже возможно, но для этого центр должен попасть в полосу ширины $\eta\sqrt{2}$; вероятность этого мала, когда η мало по сравнению с разбросом $\hat{w}$. ■

Сравнение с гребневой регуляризацией. Сфера $\|w\|_2 = \eta$ – окружность с центром в начале координат, и ближайшая к $\hat{w}$ её точка $\eta\hat{w}/\|\hat{w}\|_2$ лежит на луче из начала координат в $\hat{w}$. Координата решения равна нулю, только если равна нулю та же координата $\hat{w}$, а это событие вероятности 0 при любом η .

Замечание об общем случае. При n штрафующих коэффициентах и $A = aI$ рассуждение то же. После смены знаков и перенумерации $\hat{w}_1 \geq \hat{w}_2 \geq \dots \geq \hat{w}_n \geq 0$, и касание в вершине происходит тогда и только тогда, когда $\hat{w}_1 - \hat{w}_2 \geq \eta$. Это проверяется признаком ближайшей точки выпуклого множества: p ближайшая к $\hat{w}$ точка шара, если $(\hat{w} - p)^\top(w - p) \leq 0$ для всех w шара. Для $p = \eta e_1$ при $\hat{w}_1 - \eta \geq \hat{w}_2$

$$(\hat{w} - p)^\top(w - p) = (\hat{w}_1 - \eta)(w_1 - \eta) + \sum_{i \geq 2} \hat{w}_i w_i \leq (\hat{w}_2 - (\hat{w}_1 - \eta))(\eta - |w_1|) \leq 0,$$

а при $\hat{w}_1 - \hat{w}_2 < \eta$ точка $w = \eta e_2$ даёт $(\hat{w} - p)^\top(w - p) = \eta(\eta - \hat{w}_1 + \hat{w}_2) > 0$; для остальных вершин проверка такая же. При $\eta \rightarrow 0$ вероятность касания в вершине стремится к вероятности того, что две наибольшие по модулю координаты $\hat{w}$ различны, то есть к 1. Если линии уровня – эллипсы, на шаре малого радиуса $E(w) = E(0) - b^\top w + \frac{1}{2}w^\top A w$, где последнее слагаемое порядка η^2 , а минимум линейной функции $-b^\top w$ на шаре достигается в вершине с наибольшим $|b_j|$. Нештрафующий свободный член w_0 находится минимизацией E по w_0 при остальных коэффициентах фиксированных; как функция остальных коэффициентов E остаётся квадратичной вида (6).