Задача 3. Метод наименьших квадратов

Нейронные сети и машинное обучение

Задания 1 и 2

1 Что нужно знать

1.1 Обозначения

$\{(x_k, y_k)\}_{k=1}^N$	выборка, $x_k = x^{(k)}$, $y_k = y^{(k)}$
x_k^i	i-я степень числа x_k
$\bar{x}$, $\bar{y}$	средние арифметические, $\bar{x} = \frac{1}{N}\sum_k x_k$
$\tilde{f}(x, w)$	восстанавливаемая зависимость с параметрами w
$E(w)$	функция ошибки
M	степень многочлена в полиномиальной регрессии
$p_w(x)$	многочлен $w_0 + w_1 x + \cdots + w_M x^M$ с коэффициентами w
Δ	определитель системы линейных уравнений

1.2 Метод наименьших квадратов

Значения y_k измерены с ошибкой, зависимость ищется в виде $\tilde{f}(x, w)$ с неизвестными параметрами w. Метод наименьших квадратов выбирает w, на котором минимальна функция ошибки

$$E(w) = \frac{1}{2}\sum_{k=1}^{N}\big(y_k - \tilde{f}(x_k, w)\big)^2.$$

В точке минимума все частные производные $\partial E/\partial w_i$ равны нулю. В линейной регрессии $\tilde{f} = Ax + B$ и в полиномиальной $\tilde{f} = p_w(x)$ зависимость от параметров линейна, поэтому E – многочлен второй степени от параметров, а условия $\partial E/\partial w_i = 0$ – система линейных уравнений. Это необходимое условие: любая точка минимума E является решением системы.

1.3 Линейные системы

Система линейных уравнений *разрешима*, если у неё есть хотя бы одно решение. У системы из n уравнений с n неизвестными есть *определитель* Δ – определитель таблицы коэффициентов при неизвестных. Для двух уравнений

$$\begin{cases} a_{11}u + a_{12}v = b_1, \\ a_{21}u + a_{22}v = b_2, \end{cases} \qquad \Delta = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}.$$

Разрешимость и единственность решения проверяются по двум теоремам.

Правило Крамера. Если $\Delta \neq 0$, то решение существует и единственно: $w_j = \Delta_j/\Delta$, где Δ_j – определитель, в котором j-й столбец заменён столбцом правых частей.

Теорема Кронекера-Капелли. Система разрешима тогда и только тогда, когда ранг таблицы коэффициентов равен рангу расширенной таблицы (с добавленным столбцом правых частей). Если этот общий ранг меньше числа неизвестных, решений бесконечно много. Ранг таблицы – наибольшее число её линейно независимых строк;

например, у таблицы из двух ненулевых пропорциональных строк ранг равен 1. Эта теорема нужна, когда $\Delta = 0$ и правило Крамера неприменимо.

Система называется *однородной*, если все её правые части равны нулю; у однородной системы всегда есть нулевое решение. $\Delta \neq 0$ тогда и только тогда, когда однородная система с теми же коэффициентами имеет только нулевое решение. Решения системы и однородной системы связаны: разность двух решений системы – решение однородной системы (при вычитании правые части дают нули), а если w – решение системы и z – решение однородной, то $w + cz$ – решение системы при любом числе c.

1.4 Многочлены

Степень. Многочлен степени не выше M – это выражение $z_0 + z_1 x + \cdots + z_M x^M$ с любыми коэффициентами, в том числе нулевыми. Например, $x^2 - 1$ – многочлен степени не выше 3 с коэффициентами $(z_0, z_1, z_2, z_3) = (-1, 0, 1, 0)$. Многочлен *нулевой*, если все его коэффициенты равны нулю; тогда он равен нулю при всех x.

Корни. Корень многочлена p – число a, при котором $p(a) = 0$. Ненулевой многочлен степени не выше M имеет не более M различных корней: ненулевая прямая $z_0 + z_1 x$ пересекает ось абсцисс не более одного раза, парабола – не более двух раз. Причина: если $p(a) = 0$, то $p(x) = (x - a)\, q(x)$, где степень q на единицу меньше (теорема Безу), и каждый следующий корень отделяет ещё один множитель вида $(x - b)$; у ненулевого многочлена степени не выше M таких множителей не больше M. Отсюда: если многочлен степени не выше M обращается в нуль в $M+1$ или более различных точках, то он нулевой.

Интерполяционный многочлен Лагранжа. Через r точек (t_s, v_s) с различными t_s проходит многочлен степени не выше $r - 1$: через две точки – прямая, через три – парабола. Его формула

$$q(x) = \sum_{s=1}^{r} v_s \prod_{u \neq s} \frac{x - t_u}{t_s - t_u}.$$

При $x = t_s$ произведение в s-м слагаемом равно 1, а в каждом другом слагаемом есть множитель $t_s - t_s = 0$, поэтому $q(t_s) = v_s$. В каждом слагаемом $r - 1$ множителей с x, поэтому степень q не выше $r - 1$. При $r = 1$ произведение пустое и $q(x) = v_1$.

2 Задания

Задание 1

Дано. Линейная регрессия $\tilde{f}(x) = Ax + B$, функция ошибки

$$E(A, B) = \frac{1}{2} \sum_{k=1}^{N} \big(y_k - Ax_k - B\big)^2.$$

Условия $\partial E/\partial A = 0$ и $\partial E/\partial B = 0$ дают систему

$$\begin{cases} \Big(\sum_k x_k^2\Big) A + \Big(\sum_k x_k\Big) B = \sum_k x_k y_k, \\ \Big(\sum_k x_k\Big) A + NB = \sum_k y_k. \end{cases} \tag{4}$$

Требуется. Указать, когда разрешима система (4), и объяснить, почему решение в этом случае единственно. Выяснить, какой выборке соответствует равенство нулю определителя системы.

Зачем это нужно. Система (4) решается, когда прямую проводят по точкам методом наименьших квадратов. Нужно знать, при каких выборках прямая определяется однозначно.

Решение. *Что нужно проверить.* Система (4) – два линейных уравнения с двумя неизвестными A и B. Для такой системы разрешимость и единственность проверяются по определителю: если $\Delta \neq 0$, то по правилу Крамера решение существует и единственно. Если $\Delta = 0$, правило Крамера неприменимо, и разрешимость проверяется по теореме Кронекера-Капелли. Поэтому сначала найдём определитель системы (4) и выясним, при каких выборках он не равен нулю, а затем проверим условия этих теорем в обоих случаях.

Шаг 1: определитель. Определитель составлен из коэффициентов при A и B:

$$\Delta = \begin{vmatrix} \sum_k x_k^2 & \sum_k x_k \\ \sum_k x_k & N \end{vmatrix} = N \sum_k x_k^2 - \Big(\sum_k x_k \Big)^2 .$$

Чтобы понять, когда $\Delta = 0$, выразим его через отклонения x_k от среднего $\bar{x}$. Так как $\sum_k x_k = N\bar{x}$, раскрытие квадрата даёт

$$\sum_k (x_k - \bar{x})^2 = \sum_k x_k^2 - 2\bar{x} \sum_k x_k + N\bar{x}^2 = \sum_k x_k^2 - N\bar{x}^2,$$

а $\Delta = N \sum_k x_k^2 - N^2 \bar{x}^2$, поэтому

$$\Delta = N \sum_k (x_k - \bar{x})^2 .$$

Сумма квадратов неотрицательна и равна нулю только тогда, когда равны нулю все слагаемые, то есть $x_k = \bar{x}$ при всех k. Значит,

$$\begin{aligned} &\Delta > 0, \quad \text{если среди } x_k \text{ есть хотя бы два различных,} \\ &\Delta = 0, \quad \text{если } x_1 = \cdots = x_N . \end{aligned}$$

Шаг 2: среди x_k есть различные. Тогда $\Delta > 0$, условие правила Крамера выполнено, и система имеет единственное решение

$$A = \frac{\Delta_A}{\Delta}, \qquad \Delta_A = \begin{vmatrix} \sum_k x_k y_k & \sum_k x_k \\ \sum_k y_k & N \end{vmatrix} = N \sum_k x_k y_k - \sum_k x_k \sum_k y_k,$$

$$B = \frac{\Delta_B}{\Delta}, \qquad \Delta_B = \begin{vmatrix} \sum_k x_k^2 & \sum_k x_k y_k \\ \sum_k x_k & \sum_k y_k \end{vmatrix} = \sum_k x_k^2 \sum_k y_k - \sum_k x_k \sum_k x_k y_k .$$

Шаг 3: все x_k равны. Пусть $x_k = x_0$ при всех k. Тогда $\Delta = 0$, правило Крамера неприменимо, и проверяем условие теоремы Кронекера-Капелли. Подставим $\sum_k x_k = Nx_0$, $\sum_k x_k^2 = Nx_0^2$, $\sum_k y_k = N\bar{y}$, $\sum_k x_k y_k = x_0 \sum_k y_k = Nx_0\bar{y}$ в расширенную таблицу системы (за чертой правые части):

$$\left(\begin{array}{cc|c} Nx_0^2 & Nx_0 & Nx_0\bar{y} \\ Nx_0 & N & N\bar{y} \end{array} \right).$$

Первая строка – это вторая, умноженная на x_0, вместе с правой частью, а вторая строка ненулевая, так как $N \geq 1$. Поэтому ранг таблицы коэффициентов и ранг расширенной таблицы равны 1. Ранги равны, значит система разрешима; ранг 1 меньше числа неизвестных 2, значит решений бесконечно много. Действительно, система сводится к одному уравнению $Nx_0A + NB = N\bar{y}$, то есть $B = \bar{y} - x_0A$ при любом A. Это все прямые $y = Ax + B$, проходящие через точку $(x_0, \bar{y})$.

Такая выборка получается, когда все измерения сделаны при одном значении x: точки выборки лежат на одной вертикальной прямой $x = x_0$ (в частности, при $N = 1$).

Ответ. Система (4) разрешима при любой выборке. Если среди x_k есть хотя бы два различных значения, то определитель $\Delta = N\sum_k (x_k - \bar{x})^2$ положителен, и по правилу Крамера решение единственно. Определитель равен нулю, когда все x_k одинаковы, то есть точки выборки лежат на одной вертикальной прямой; тогда по теореме Кронекера-Капелли система разрешима, но решений бесконечно много.

Замечание: найденная прямая даёт наименьшую ошибку. Система (4) – только необходимое условие минимума, поэтому проверим, что при $\Delta > 0$ её решение действительно минимизирует E. Обозначим через $d_k = y_k - Ax_k - B$ отклонения точек от найденной прямой. Второе и первое уравнения системы (4) означают

$$\sum_k d_k = 0, \qquad \sum_k d_k x_k = 0.$$

Для любого сдвига параметров (a, b)

$$\begin{aligned} E(A + a, B + b) &= \frac{1}{2}\sum_k \big(d_k - ax_k - b\big)^2 \\ &= E(A, B) - a\sum_k d_k x_k - b\sum_k d_k + \frac{1}{2}\sum_k (ax_k + b)^2 \\ &= E(A, B) + \frac{1}{2}\sum_k (ax_k + b)^2. \end{aligned}$$

Значит $E(A + a, B + b) \geq E(A, B)$, и равенство только при $ax_k + b = 0$ для всех k. Для двух различных $x_i \neq x_j$ вычитание этих равенств даёт $a(x_i - x_j) = 0$, откуда $a = 0$, а затем $b = 0$.

Задание 2

Дано. Полиномиальная регрессия $\tilde{f}(x, w) = p_w(x) = \sum_{j=0}^{M} w_j x^j$, функция ошибки

$$E(w) = \frac{1}{2}\sum_{k=1}^{N} \big(y_k - p_w(x_k)\big)^2.$$

Требуется. Показать, что коэффициенты w, минимизирующие $E(w)$, являются решениями системы

$$\sum_{j=0}^{M} a_{ij} w_j = b_i, \quad i = 0, \ldots, M, \qquad a_{ij} = \sum_{k=1}^{N} x_k^{i+j}, \quad b_i = \sum_{k=1}^{N} x_k^i y_k.$$

Выяснить, всегда ли эта система разрешима.

Зачем это нужно. Эту систему решает программа полиномиальной регрессии. Нужно знать, есть ли у неё решение при любой выборке и когда оно единственно.

Решение. Сначала выведем систему из условия минимума, затем выясним, сколько у неё решений.

Шаг 1: вывод системы. В точке минимума E все частные производные равны нулю: $\partial E/\partial w_i = 0$, $i = 0, \ldots, M$. Производная $p_w(x_k)$ по w_i равна x_k^i, а множитель $\frac{1}{2}$ сокращается с двойкой из производной квадрата:

$$\frac{\partial E}{\partial w_i} = -\sum_{k=1}^{N} x_k^i \big(y_k - p_w(x_k)\big) = 0. \qquad (*)$$

Подставляем $p_w(x_k) = \sum_j w_j x_k^j$ и переносим слагаемое с y_k вправо:

$$\sum_{k=1}^{N} \sum_{j=0}^{M} x_k^{i+j} w_j = \sum_{k=1}^{N} x_k^i y_k.$$

Меняем порядок суммирования в левой части:

$$\sum_{j=0}^{M} \Big(\sum_{k=1}^{N} x_k^{i+j} \Big) w_j = \sum_{k=1}^{N} x_k^i y_k, \qquad \text{то есть} \qquad \sum_{j=0}^{M} a_{ij} w_j = b_i.$$

Итак, коэффициенты, минимизирующие E, являются решениями системы. Все преобразования обратимы, поэтому система равносильна условиям $(*)$. ■

Что нужно проверить. Получилась система из $M+1$ уравнений с $M+1$ неизвестными $w_0, \ldots, w_M$, и проверять нужно то же, что в задании 1: если $\Delta \neq 0$, то по правилу Крамера решение существует и единственно, а при $\Delta = 0$ разрешимость нужно проверить отдельно. Вычислять определитель порядка $M+1$ в общем виде неудобно, поэтому условие $\Delta \neq 0$ проверим через равносильное ему: однородная система

$$\sum_{j=0}^{M} a_{ij} z_j = 0, \qquad i = 0, \ldots, M,$$

имеет только нулевое решение. Сначала выясним, какие z её решают (шаг 2), затем разберём случаи $\Delta \neq 0$ (шаг 3) и $\Delta = 0$ (шаги 4 и 5).

Шаг 2: решения однородной системы. Левая часть однородной системы выражается через многочлен $p_z(x) = \sum_j z_j x^j$:

$$\sum_{j=0}^{M} a_{ij} z_j = \sum_{k=1}^{N} x_k^i \sum_{j=0}^{M} z_j x_k^j = \sum_{k=1}^{N} x_k^i \, p_z(x_k).$$

Если $p_z(x_k) = 0$ во всех узлах, то эта сумма равна нулю, и z – решение. Обратно, пусть z – решение. Умножим i-е уравнение на z_i и сложим по i:

$$0 = \sum_{i=0}^{M} z_i \sum_{k=1}^{N} x_k^i \, p_z(x_k) = \sum_{k=1}^{N} p_z(x_k) \sum_{i=0}^{M} z_i x_k^i = \sum_{k=1}^{N} p_z(x_k)^2,$$

а сумма квадратов равна нулю, только если $p_z(x_k) = 0$ для всех k. Итак, z – решение однородной системы тогда и только тогда, когда многочлен p_z обращается в нуль во всех узлах $x_1, \ldots, x_N$.

Что осталось выяснить. По шагу 2 вопрос о решениях однородной системы стал вопросом о многочленах: бывает ли *ненулевой* многочлен степени не выше M, равный нулю во всех узлах $x_1, \dots, x_N$? Если не бывает, то однородная система имеет только решение $z = 0$, и $\Delta \neq 0$. Если бывает, то $\Delta = 0$. Многочлен может обращаться в нуль в отдельных точках, не будучи нулевым (например, $x^2 - 1$ при $x = \pm 1$), поэтому ответ зависит от того, сколько среди узлов различных точек. Узлы могут повторяться; обозначим их различные значения $t_1, \dots, t_r$. Всё решает сравнение r с M и факт о корнях: ненулевой многочлен степени не выше M имеет не больше M различных корней.

Шаг 3: различных значений не меньше $M + 1$. Пусть z – решение однородной системы. По шагу 2 многочлен p_z равен нулю во всех узлах, то есть у него не меньше $M + 1$ различных корней $t_1, \dots, t_r$. У ненулевого многочлена степени не выше M столько корней быть не может, значит p_z нулевой: $z = 0$. Например, при $M = 1$ многочлен $p_z(x) = z_0 + z_1 x$ – это прямая, и если она проходит через нуль при двух разных x, то это ось абсцисс, $z_0 = z_1 = 0$. Итак, однородная система имеет только нулевое решение, значит $\Delta \neq 0$, и по правилу Крамера система имеет решение, и притом единственное.

Шаг 4: различных значений не больше M. Теперь ненулевой многочлен, равный нулю во всех узлах, есть:

$$(x - t_1)(x - t_2) \cdots (x - t_r).$$

При $x = t_s$ один из множителей равен нулю, поэтому он равен нулю во всех узлах. После раскрытия скобок это многочлен степени r, а $r \leq M$, поэтому он записывается как $z_0 + z_1 x + \cdots + z_M x^M$, где коэффициенты при степенях выше r равны нулю. Например, при $M = 3$ и двух различных узлах

$$(x - t_1)(x - t_2) = t_1 t_2 - (t_1 + t_2)\, x + x^2, \qquad z = \big(t_1 t_2,\ -(t_1 + t_2),\ 1,\ 0\big).$$

По шагу 2 такой ненулевой z – решение однородной системы, значит $\Delta = 0$, и правило Крамера неприменимо. Сравнивать ранги таблиц в общем виде неудобно, поэтому разрешимость проверим самым прямым способом: предъявим решение.

Шаг 5: решение при $\Delta = 0$. По шагу 1 система равносильна условиям $(*)$, поэтому нужен многочлен q степени не выше M, для которого $\sum_k x_k^i \big(y_k - q(x_k)\big) = 0$ при всех i. Сгруппируем слагаемые по различным узлам: при $x_k = t_s$ имеем $x_k^i = t_s^i$ и $q(x_k) = q(t_s)$, поэтому

$$\sum_{k=1}^{N} x_k^i \big(y_k - q(x_k)\big) = \sum_{s=1}^{r} t_s^i \sum_{k:\, x_k = t_s} \big(y_k - q(t_s)\big).$$

Внутренняя сумма равна нулю, если $q(t_s)$ – среднее значение $\bar{y}_s$ тех y_k, у которых $x_k = t_s$: сумма отклонений от среднего равна нулю. Значит, нужен многочлен степени не выше M, проходящий через r точек $(t_s, \bar{y}_s)$. Такой есть: интерполяционный многочлен Лагранжа через эти точки имеет степень не выше $r - 1$, а $r - 1 < M$. Его коэффициенты, дополненные нулями до $M + 1$ штук, дают решение w системы.

Решение не единственно: вместе с w решениями будут все $w + cz$ при любом c, где z – ненулевое решение однородной системы из шага 4, то есть решений бесконечно много. Разность двух решений – решение однородной системы, и по шагу 2 её многочлен равен нулю во всех узлах. Поэтому все решения задают многочлены с одинаковыми значениями в узлах и дают одно и то же значение E.

Ответ. Система разрешима при любой выборке, а её решение единственно тогда и только тогда, когда среди x_k не меньше $M+1$ различных значений (для этого нужно $N \geq M+1$). Иначе решений бесконечно много.

Замечание. При $M=1$, $w_0=B$, $w_1=A$ имеем $a_{00}=N$, $a_{01}=a_{10}=\sum_k x_k$, $a_{11}=\sum_k x_k^2$, $b_0=\sum_k y_k$, $b_1=\sum_k x_k y_k$, и система совпадает с (4). Условие $r \geq 2$ при этом совпадает с условием из задания 1, а при $r=1$ многочлен q – это константа $\bar{y}$, то есть прямая $A=0$, $B=\bar{y}$, одна из прямых, найденных в задании 1.