Задача 3. Метод наименьших квадратов

Нейронные сети и машинное обучение

Задания 1 и 2

1 Что нужно знать

1.1 Обозначения

$\{(x_k, y_k)\}_{k=1}^N$	выборка, $x_k = x^{(k)}$, $y_k = y^{(k)}$
x_k^i	i-я степень числа x_k
$\bar{x}$, $\bar{y}$	средние арифметические, $\bar{x} = \frac{1}{N}\sum_k x_k$
$\tilde{f}(x, w)$	восстанавливаемая зависимость с параметрами w
$E(w)$	функция ошибки
M	степень многочлена в полиномиальной регрессии
$p_w(x)$	многочлен $w_0 + w_1 x + \cdots + w_M x^M$ с коэффициентами w
Δ	определитель системы линейных уравнений

1.2 Метод наименьших квадратов

Значения y_k измерены с ошибкой, зависимость ищется в виде $\tilde{f}(x, w)$ с неизвестными параметрами w. Метод наименьших квадратов выбирает w, на котором минимальна функция ошибки

$$E(w) = \frac{1}{2}\sum_{k=1}^{N}\big(y_k - \tilde{f}(x_k, w)\big)^2.$$

В точке минимума все частные производные $\partial E/\partial w_i$ равны нулю. В линейной регрессии $\tilde{f} = Ax + B$ и в полиномиальной $\tilde{f} = p_w(x)$ зависимость от параметров линейна, поэтому E – многочлен второй степени от параметров, а условия $\partial E/\partial w_i = 0$ – система линейных уравнений. Это необходимое условие: любая точка минимума E является решением системы.

1.3 Линейные системы

Система из n линейных уравнений с n неизвестными называется *квадратной*. Её *определитель* Δ – определитель таблицы коэффициентов при неизвестных, для двух уравнений

$$\begin{cases} a_{11}u + a_{12}v = b_1, \\ a_{21}u + a_{22}v = b_2, \end{cases} \qquad \Delta = a_{11}a_{22} - a_{12}a_{21}.$$

Система называется *однородной*, если все её правые части равны нулю; у однородной системы всегда есть нулевое решение. Определитель нужен потому, что по нему видно, сколько решений у системы:

- *правило Крамера*: если $\Delta \neq 0$, решение существует и единственно, $w_j = \Delta_j/\Delta$, где Δ_j – определитель, в котором j-й столбец заменён столбцом правых частей;
- $\Delta \neq 0$ тогда и только тогда, когда однородная система с теми же коэффициентами имеет только нулевое решение.

Решения системы и однородной системы с теми же коэффициентами связаны: разность двух решений системы – решение однородной системы (при вычитании правые части дают нули), а если w – решение системы и z – решение однородной, то $w + cz$ – решение системы при любом числе c. Поэтому при $\Delta = 0$, когда у однородной системы есть ненулевое решение z, у системы либо нет решений, либо их бесконечно много: вместе с решением w решениями будут все $w + cz$.

1.4 Многочлены

Корни. Ненулевой многочлен степени не выше M имеет не более M различных корней. Поэтому если многочлен степени не выше M обращается в нуль в $M + 1$ или более различных точках, то все его коэффициенты равны нулю.

Интерполяционный многочлен Лагранжа. Через точки (t_s, v_s), $s = 1, \ldots, r$, с различными t_s проходит многочлен степени не выше $r - 1$:

$$q(x) = \sum_{s=1}^{r} v_s \prod_{u \neq s} \frac{x - t_u}{t_s - t_u}.$$

Действительно, при $x = t_s$ произведение в s-м слагаемом равно 1, а в каждом другом слагаемом есть множитель $t_s - t_s = 0$, поэтому $q(t_s) = v_s$. При $r = 1$ произведение пустое и $q(x) = v_1$.

2 Задания

Задание 1

Дано. Линейная регрессия $\tilde{f}(x) = Ax + B$, функция ошибки

$$E(A, B) = \frac{1}{2} \sum_{k=1}^{N} \big(y_k - Ax_k - B\big)^2.$$

Условия $\partial E/\partial A = 0$ и $\partial E/\partial B = 0$ дают систему

$$\begin{cases} \Big(\sum_k x_k^2\Big) A + \Big(\sum_k x_k\Big) B = \sum_k x_k y_k, \\ \Big(\sum_k x_k\Big) A + NB = \sum_k y_k. \end{cases} \tag{4}$$

Требуется. Указать, когда разрешима система (4), и объяснить, почему решение в этом случае единственно. Выяснить, какой выборке соответствует равенство нулю определителя системы.

Зачем это нужно. Система (4) решается, когда прямую проводят по точкам методом наименьших квадратов. Нужно знать, при каких выборках прямая определяется однозначно.

Решение. Система (4) – два линейных уравнения с двумя неизвестными A и B. Чтобы понять, когда у неё есть решение и когда оно одно, решим её исключением неизвестных. По ходу станет видно, что всё зависит от одного числа – определителя

системы: на него приходится делить, чтобы найти A и B. Для краткости обозначим суммы

$$S_1 = \sum_k x_k, \qquad S_2 = \sum_k x_k^2, \qquad T_0 = \sum_k y_k, \qquad T_1 = \sum_k x_k y_k,$$

тогда система (4) и её определитель записываются так:

$$\begin{cases} S_2 A + S_1 B = T_1, & \text{(а)} \\ S_1 A + N B = T_0, & \text{(б)} \end{cases} \qquad \Delta = S_2 N - S_1^2.$$

Шаг 1: исключение неизвестных. Умножим (а) на N, (б) на S_1 и вычтем второе из первого: слагаемые с B сократятся. Умножим (б) на S_2, (а) на S_1 и снова вычтем: сократятся слагаемые с A. Получаем

$$\Delta \cdot A = N T_1 - S_1 T_0, \qquad \Delta \cdot B = S_2 T_0 - S_1 T_1. \tag{в}$$

Равенства (в) – следствия (а) и (б), поэтому им удовлетворяет каждое решение системы. Перед обоими неизвестными стоит один и тот же множитель Δ. Если $\Delta \neq 0$, из (в) неизвестные находятся делением на Δ. Если $\Delta = 0$, левые части (в) равны нулю и ничего не говорят об A и B. Поэтому дальше нужно выяснить, при какой выборке $\Delta = 0$.

Шаг 2: когда определитель равен нулю. Запишем Δ через отклонения x_k от их среднего $\bar{x} = S_1/N$. Раскрывая квадрат и подставляя $S_1 = N\bar{x}$, получаем

$$\sum_k (x_k - \bar{x})^2 = S_2 - 2\bar{x} S_1 + N\bar{x}^2 = S_2 - \frac{S_1^2}{N},$$

и после умножения на N

$$\Delta = N S_2 - S_1^2 = N \sum_k (x_k - \bar{x})^2.$$

Сумма квадратов неотрицательна и равна нулю только тогда, когда равны нулю все слагаемые, то есть $x_k = \bar{x}$ при всех k. Значит,

$$\begin{aligned} &\Delta > 0, \quad \text{если среди } x_k \text{ есть хотя бы два различных,} \\ &\Delta = 0, \quad \text{если } x_1 = \cdots = x_N. \end{aligned}$$

Шаг 3: среди x_k есть различные, $\Delta > 0$.

Единственность. Делим (в) на Δ: любое решение системы обязано равняться

$$A = \frac{N T_1 - S_1 T_0}{\Delta}, \qquad B = \frac{S_2 T_0 - S_1 T_1}{\Delta}, \tag{г}$$

поэтому двух разных решений быть не может.

Существование. Равенства (в) выведены из системы, но обратное пока не проверено: подставим числа (г) в (а) и (б):

$$S_2 A + S_1 B = \frac{N S_2 T_1 - S_1 S_2 T_0 + S_1 S_2 T_0 - S_1^2 T_1}{\Delta} = \frac{(N S_2 - S_1^2)\, T_1}{\Delta} = T_1,$$

$$S_1 A + N B = \frac{N S_1 T_1 - S_1^2 T_0 + N S_2 T_0 - N S_1 T_1}{\Delta} = \frac{(N S_2 - S_1^2)\, T_0}{\Delta} = T_0.$$

Оба уравнения выполняются, значит (г) – решение, и других нет. Формулы (г) – это правило Крамера для двух уравнений: числители равны определителям, в которых столбец коэффициентов при A или при B заменён столбцом правых частей.

Шаг 4: все x_k равны, $\Delta = 0$. Делить на Δ нельзя, поэтому смотрим на саму систему. Пусть $x_k = x_0$ при всех k. Тогда $S_1 = Nx_0$, $S_2 = Nx_0^2$, $T_1 = x_0T_0$, и система принимает вид

$$\text{(а)}: \ Nx_0^2A + Nx_0B = x_0T_0, \qquad \text{(б)}: \ Nx_0A + NB = T_0.$$

Уравнение (а) – это (б), умноженное на x_0, поэтому система равносильна одному уравнению (б), то есть $B = \bar{y} - x_0A$, где $\bar{y} = T_0/N$. Решение есть, но не одно: A можно взять любым и найти по нему B. Это все прямые $y = Ax + B$, проходящие через точку $(x_0, \bar{y})$.

Такая выборка получается, когда все измерения сделаны при одном значении x: точки выборки лежат на одной вертикальной прямой $x = x_0$ (в частности, при $N = 1$).

Ответ. Система (4) разрешима при любой выборке. Если среди x_k есть хотя бы два различных значения, то определитель $\Delta = N\sum_k (x_k - \bar{x})^2$ положителен, неизвестные однозначно находятся делением на Δ, и решение единственно. Определитель равен нулю, когда все x_k одинаковы, то есть точки выборки лежат на одной вертикальной прямой; тогда решений бесконечно много.

Замечание: найденная прямая даёт наименьшую ошибку. Система (4) – только необходимое условие минимума, поэтому проверим, что при $\Delta > 0$ её решение действительно минимизирует E. Обозначим через $d_k = y_k - Ax_k - B$ отклонения точек от найденной прямой. Уравнения (б) и (а) означают

$$\sum_k d_k = 0, \qquad \sum_k d_k x_k = 0.$$

Для любого сдвига параметров (a, b)

$$\begin{aligned} E(A+a, B+b) &= \frac{1}{2}\sum_k \big(d_k - ax_k - b\big)^2 \\ &= E(A,B) - a\sum_k d_k x_k - b\sum_k d_k + \frac{1}{2}\sum_k (ax_k + b)^2 \\ &= E(A,B) + \frac{1}{2}\sum_k (ax_k + b)^2. \end{aligned}$$

Значит $E(A+a, B+b) \geq E(A,B)$, и равенство только при $ax_k + b = 0$ для всех k. Для двух различных $x_i \neq x_j$ вычитание этих равенств даёт $a(x_i - x_j) = 0$, откуда $a = 0$, а затем $b = 0$.

Задание 2

Дано. Полиномиальная регрессия $\tilde{f}(x, w) = p_w(x) = \sum_{j=0}^{M} w_j x^j$, функция ошибки

$$E(w) = \frac{1}{2}\sum_{k=1}^{N} \big(y_k - p_w(x_k)\big)^2.$$

Требуется. Показать, что коэффициенты w, минимизирующие $E(w)$, являются решениями системы

$$\sum_{j=0}^{M} a_{ij} w_j = b_i, \quad i = 0, \ldots, M, \qquad a_{ij} = \sum_{k=1}^{N} x_k^{i+j}, \quad b_i = \sum_{k=1}^{N} x_k^i y_k.$$

Выяснить, всегда ли эта система разрешима.

Зачем это нужно. Эту систему решает программа полиномиальной регрессии. Нужно знать, есть ли у неё решение при любой выборке и когда оно единственно.

Решение. Сначала выведем систему из условия минимума, затем выясним, сколько у неё решений.

Шаг 1: вывод системы. В точке минимума E все частные производные равны нулю: $\partial E / \partial w_i = 0$, $i = 0, \ldots, M$. Производная $p_w(x_k)$ по w_i равна x_k^i, а множитель $\frac{1}{2}$ сокращается с двойкой из производной квадрата:

$$\frac{\partial E}{\partial w_i} = -\sum_{k=1}^{N} x_k^i \big(y_k - p_w(x_k)\big) = 0. \qquad (*)$$

Подставляем $p_w(x_k) = \sum_j w_j x_k^j$ и переносим слагаемое с y_k вправо:

$$\sum_{k=1}^{N} \sum_{j=0}^{M} x_k^{i+j} w_j = \sum_{k=1}^{N} x_k^i y_k.$$

Меняем порядок суммирования в левой части:

$$\sum_{j=0}^{M} \Big(\sum_{k=1}^{N} x_k^{i+j} \Big) w_j = \sum_{k=1}^{N} x_k^i y_k, \qquad \text{то есть} \qquad \sum_{j=0}^{M} a_{ij} w_j = b_i.$$

Итак, коэффициенты, минимизирующие E, являются решениями системы. Все преобразования обратимы, поэтому система равносильна условиям $(*)$. ■

План. Получилась квадратная система: $M+1$ уравнений и $M+1$ неизвестных $w_0, \ldots, w_M$. Решать её исключением неизвестных, как в задании 1, при произвольном M неудобно. Вместо этого воспользуемся фактами о квадратных системах: если однородная система

$$\sum_{j=0}^{M} a_{ij} z_j = 0, \qquad i = 0, \ldots, M,$$

имеет только нулевое решение, то $\Delta \neq 0$, и по правилу Крамера решение системы существует и единственно. Если же у однородной системы есть ненулевое решение, то решение системы не единственно, а его существование придётся доказать отдельно. Поэтому сначала выясним, какие z решают однородную систему (шаг 2), а затем разберём два случая (шаги 3 и 4).

Шаг 2: решения однородной системы. Левая часть однородной системы выражается через многочлен $p_z(x) = \sum_j z_j x^j$:

$$\sum_{j=0}^{M} a_{ij} z_j = \sum_{k=1}^{N} x_k^i \sum_{j=0}^{M} z_j x_k^j = \sum_{k=1}^{N} x_k^i \, p_z(x_k).$$

Если $p_z(x_k) = 0$ во всех узлах, то эта сумма равна нулю, и z – решение. Обратно, пусть z – решение. Умножим i-е уравнение на z_i и сложим по i:

$$0 = \sum_{i=0}^{M} z_i \sum_{k=1}^{N} x_k^i \, p_z(x_k) = \sum_{k=1}^{N} p_z(x_k) \sum_{i=0}^{M} z_i x_k^i = \sum_{k=1}^{N} p_z(x_k)^2,$$

а сумма квадратов равна нулю, только если $p_z(x_k) = 0$ для всех k. Итак, z – решение однородной системы тогда и только тогда, когда многочлен p_z обращается в нуль во всех узлах $x_1, \ldots, x_N$.

Пусть среди $x_1, \ldots, x_N$ ровно r различных значений $t_1, \ldots, t_r$. Дальше всё зависит от того, сколько их: многочлен степени не выше M с $M+1$ различными корнями нулевой, а при $r \le M$ ненулевой многочлен может обращаться в нуль во всех узлах.

Шаг 3: различных значений не меньше $M+1$. Если z – решение однородной системы, то многочлен p_z степени не выше M обращается в нуль в $r \ge M+1$ различных точках $t_1, \ldots, t_r$, поэтому все его коэффициенты нулевые: $z = 0$. Однородная система имеет только нулевое решение, значит $\Delta \ne 0$, и по правилу Крамера система имеет решение, и притом единственное.

Шаг 4: различных значений не больше M. Теперь у однородной системы есть ненулевое решение: многочлен $(x - t_1) \cdots (x - t_r)$ степени $r \le M$ не равен нулю и обращается в нуль во всех узлах, поэтому по шагу 2 его коэффициенты z, дополненные нулями до $M+1$ штук, – ненулевое решение однородной системы. Значит $\Delta = 0$, правило Крамера неприменимо, и существование решения докажем, предъявив его.

Обозначим через $\bar{y}_s$ среднее значение y_k по тем k, для которых $x_k = t_s$, и возьмём интерполяционный многочлен Лагранжа q с $q(t_s) = \bar{y}_s$, $s = 1, \ldots, r$. Его степень не выше $r - 1 < M$, поэтому его коэффициенты, дополненные нулями до $M+1$ штук, задают набор w с $p_w = q$. Проверим для него условия $(*)$, равносильные системе. Сгруппируем слагаемые по узлам: при $x_k = t_s$ имеем $q(x_k) = \bar{y}_s$, и

$$\sum_{k=1}^{N} x_k^i \big(y_k - q(x_k)\big) = \sum_{s=1}^{r} t_s^i \sum_{k:\, x_k = t_s} \big(y_k - \bar{y}_s\big) = 0,$$

так как сумма отклонений от среднего равна нулю. Значит этот набор w – решение системы. Вместе с ним решениями будут все $w + cz$ при любом c, то есть решений бесконечно много. Разность двух решений – решение однородной системы, и по шагу 2 её многочлен равен нулю во всех узлах. Поэтому все решения задают многочлены с одинаковыми значениями в узлах и дают одно и то же значение E.

Ответ. Система разрешима при любой выборке, а её решение единственно тогда и только тогда, когда среди x_k не меньше $M+1$ различных значений (для этого нужно $N \ge M+1$). Иначе решений бесконечно много.

Замечание. При $M = 1$, $w_0 = B$, $w_1 = A$ имеем $a_{00} = N$, $a_{01} = a_{10} = \sum_k x_k$, $a_{11} = \sum_k x_k^2$, $b_0 = \sum_k y_k$, $b_1 = \sum_k x_k y_k$, и система совпадает с (4). Условие $r \ge 2$ при этом совпадает с условием из задания 1, а при $r = 1$ многочлен q – это константа $\bar{y}$, то есть прямая $A = 0$, $B = \bar{y}$, одна из прямых, найденных в задании 1.