

Задача 4. Нейронные сети

Нейронные сети и машинное обучение

Задания 1–8

1 Что нужно знать

1.1 Обозначения

$x \in \mathbb{R}^m$	вектор признаков
w	вектор весов (параметров)
$\langle w, x \rangle$	скалярное произведение
θ	ступенчатая функция активации
η	коэффициент обучения
$\mathcal{C}_1, \mathcal{C}_2$	классы
$\mathcal{H}_1, \mathcal{H}_2$	обучающие выборки этих классов
$\tilde{w}$	разделяющий вектор весов
$w(n)$	веса на n -й итерации
W_l, b_l	матрица весов и вектор сдвигов l -го слоя
$\sigma, \tanh$	логистический сигмоид и гиперболический тангенс

1.2 Элементарный перцептрон

Элементарный перцептрон вычисляет

$$y(x) = \theta(\langle w, x \rangle), \quad \theta(a) = \begin{cases} 1, & a > 0, \\ -1, & a \leq 0. \end{cases}$$

Геометрически $\langle w, x \rangle = 0$ задаёт гиперплоскость с нормалью w , а перцептрон относит точку к одному из классов по тому, с какой стороны от неё точка лежит. Свободный член включается в w добавлением к x фиктивной компоненты, равной единице.

Классы *линейно отделимы*, если существует гиперплоскость, разделяющая их, то есть существует $\tilde{w}$ с

$$\langle \tilde{w}, x \rangle > 0 \quad \forall x \in \mathcal{C}_1, \quad \langle \tilde{w}, x \rangle < 0 \quad \forall x \in \mathcal{C}_2.$$

1.3 Алгоритм обучения перцептрона

Обучающая выборка $\mathcal{H} = \mathcal{H}_1 \cup \mathcal{H}_2$ размера N , элементы пронумерованы и перебираются циклически: $x(n) = x(n \bmod N)$. Начальные веса $w(0) = 0$. На каждой итерации:

- если классификация $x(n)$ верна, веса не меняются: $w(n+1) = w(n)$;
- если $x(n) \in \mathcal{H}_1$ классифицирован неверно: $w(n+1) = w(n) + \eta x(n)$;
- если $x(n) \in \mathcal{H}_2$ классифицирован неверно: $w(n+1) = w(n) - \eta x(n)$.

Изменение весов будем называть *коррекцией*. Алгоритм сходится, если за конечное число итераций веса перестают меняться и классификация верна для всей выборки.

1.4 Теорема о сходимости и её доказательство

Теорема 1. *Если классы линейно отделимы, алгоритм обучения перцептрона сходится.*

Схема доказательства такова. Полагается $\eta = 1$, $w(0) = 0$, и рассматривается случай, когда все встречающиеся $x(k)$ лежат в $\mathcal{H}_1$ и классифицируются неверно, так что $w(n+1) = \sum_{i=0}^n x(i)$. Вводятся

$$\alpha = \min_{x \in \mathcal{H}_1} \langle \tilde{w}, x \rangle > 0, \quad \beta = \max_{x \in \mathcal{H}_1} \|x\|^2.$$

Оценка снизу. Из $\langle \tilde{w}, w(n+1) \rangle = \sum_i \langle \tilde{w}, x(i) \rangle \geq n\alpha$ и неравенства Коши-Буняковского $\|\tilde{w}\|^2 \|w(n+1)\|^2 \geq \langle \tilde{w}, w(n+1) \rangle^2$ следует

$$\|w(n+1)\|^2 \geq \frac{(n\alpha)^2}{\|\tilde{w}\|^2}. \quad (1)$$

Оценка сверху. Из $w(k+1) = w(k) + x(k)$

$$\|w(k+1)\|^2 = \|w(k)\|^2 + \|x(k)\|^2 + 2\langle w(k), x(k) \rangle,$$

а при неверной классификации $\langle w(k), x(k) \rangle \leq 0$, поэтому $\|w(k+1)\|^2 - \|w(k)\|^2 \leq \|x(k)\|^2$. Суммируя по k ,

$$\|w(n+1)\|^2 \leq n\beta. \quad (2)$$

Вывод. Нижняя оценка растёт как n^2 , верхняя как n , поэтому они могут одновременно выполняться лишь до некоторого номера. Приравнявая, $n_0^2 \alpha^2 / \|\tilde{w}\|^2 = n_0 \beta$, получаем

$$n_0 = \frac{\beta \|\tilde{w}\|^2}{\alpha^2}. \quad (3)$$

Больше n_0 коррекций быть не может.

Три упрощения этого рассуждения снимаются в заданиях 2 и 3: произвольное η , элементы обоих классов, наличие верных классификаций на промежуточных итерациях.

1.5 Многослойный перцептрон

Многослойный перцептрон вычисляет последовательность преобразований

$$z^{(l)} = \varphi(W_l z^{(l-1)} + b_l), \quad l = 1, \dots, L, \quad z^{(0)} = x,$$

где φ – функция активации, применяемая покомпонентно, W_l имеет размер $h_l \times h_{l-1}$, а h_l – число узлов l -го слоя. Активация *линейна*, если $\varphi(a) = a$ (или, в общем виде, $\varphi(a) = \kappa a + \lambda$).

Понадобится свойство ранга: $\text{rank}(AB) \leq \min(\text{rank } A, \text{rank } B)$, а rank матрицы размера $p \times q$ не превосходит $\min(p, q)$.

2 Задания

Задание 1

Дано. Алгоритм обучения перцептрона и доказательство теоремы о сходимости.

Требуется. Выяснить, важен ли порядок, в котором пронумерованы векторы признаков обучающей выборки.

Решение. Разделим два вопроса: влияет ли порядок на *факт* сходимости и на *результат* работы алгоритма.

На сходимость не влияет. В оценку (3) входят только α , β и $\|\tilde{w}\|$. Величины α и β определены как минимум и максимум по выборке как по *множеству*, а $\tilde{w}$ существует по условию линейной отделимости, тоже независимо от нумерации. Значит и оценка n_0 , и сам факт сходимости от порядка не зависят: при любой нумерации коррекций будет не более n_0 .

На результат влияет. Траектория $w(n)$, фактическое число коррекций и итоговый вектор весов зависят от того, в каком порядке встретились неверно классифицированные элементы. Причина в том, что каждая коррекция прибавляет конкретный $x(n)$, и сумма зависит от того, какие именно элементы успели оказаться неверно классифицированными. Алгоритм находит *какой-то* разделяющий вектор из бесконечного множества подходящих, а какой именно – определяется порядком.

Одно требование к нумерации всё же есть: каждый элемент выборки должен встречаться бесконечно много раз. Циклический перебор $x(n) = x(n \bmod N)$ это обеспечивает. Если же какой-то элемент перестанет предъявляться, алгоритм может остановиться на векторе, который на этом элементе ошибается: критерий остановки проверяет неизменность весов на протяжении N подряд идущих итераций, и смысл он имеет только при полном переборе выборки за эти N шагов.

Задание 2

Дано. Алгоритм обучения перцептрона с коэффициентом обучения η .

Требуется. Показать, что если алгоритм сходится при $\eta = 1$, то он сходится и при меньших η , но потребует большего числа итераций.

Решение. Рассмотрим сначала случай $w(0) = 0$, как в доказательстве теоремы.

Сходимость сохраняется. Докажем по индукции, что $w_\eta(n) = \eta w_1(n)$, где индекс обозначает коэффициент обучения. База: $w_\eta(0) = 0 = \eta \cdot 0$. Переход: пусть $w_\eta(n) = \eta w_1(n)$. Проверка классификации сводится к сравнению $\langle w, x \rangle$ с нулём, а умножение w на положительное число η знака скалярного произведения не меняет:

$$\langle w_\eta(n), x(n) \rangle = \eta \langle w_1(n), x(n) \rangle.$$

Значит оба запуска на этой итерации принимают одно и то же решение. Если коррекции нет, веса не меняются в обоих. Если есть, то

$$w_\eta(n+1) = \eta w_1(n) \pm \eta x(n) = \eta (w_1(n) \pm x(n)) = \eta w_1(n+1).$$

Индукция завершена. Следовательно последовательность решений одна и та же, и алгоритм сходится при любом $\eta > 0$ ровно за то же число коррекций, отличаясь только масштабом весов.

Тот же вывод даёт и оценка. Подставим $w_\eta(n) = \eta w_1(n)$ в (1) и (2): обе части умножаются на η^2 ,

$$\frac{(n\eta\alpha)^2}{\|\tilde{w}\|^2} \leq \|w_\eta(n+1)\|^2 \leq n\eta^2\beta \implies n_0 = \frac{\beta \|\tilde{w}\|^2}{\alpha^2},$$

и η сокращается: оценка от него не зависит.

Откуда берётся рост числа итераций. Утверждение про большее число итераций относится к случаю $w(0) \neq 0$, когда приведённая индукция уже не проходит: начальный вектор на η не масштабируется. Разделим в этом случае все веса на η и обозначим $v(n) = w(n)/\eta$. Правило коррекции превращается в $v(n+1) = v(n) \pm x(n)$, а проверка знака при делении на положительное η не меняется. Значит

работа с коэффициентом η из начальной точки $w(0)$ совпадает с работой с коэффициентом 1 из начальной точки $w(0)/\eta$.

Чем меньше η , тем больше норма стартового вектора $w(0)/\eta$. Если этот вектор классифицирует часть выборки неверно, каждая коррекция сдвигает его лишь на $\|x\| \leq \sqrt{\beta}$, поэтому число коррекций, нужных чтобы его перебить, растёт пропорционально $\|w(0)\|/\eta$, то есть как $1/\eta$.

Формально это видно из тех же оценок с $w(0) \neq 0$: после n коррекций $\langle \tilde{w}, w(n) \rangle \geq \langle \tilde{w}, w(0) \rangle + n\eta\alpha$ и $\|w(n)\|^2 \leq \|w(0)\|^2 + n\eta^2\beta$, и неравенство Коши-Буняковского даёт

$$(\langle \tilde{w}, w(0) \rangle + n\eta\alpha)^2 \leq \|\tilde{w}\|^2 (\|w(0)\|^2 + n\eta^2\beta).$$

Разделив на η^2 , получаем ту же оценку с заменой $w(0)$ на $w(0)/\eta$: граница для числа коррекций растёт при уменьшении η .

Задание 3

Дано. Доказательство теоремы о сходимости проведено в предположении, что $x(n) \in \mathcal{H}_1$ и классификация производится неверно на всех итерациях вплоть до $(n+1)$ -й.

Требуется. Показать, что при других возможных промежуточных результатах (встречаются итерации с верной классификацией, встречаются элементы класса $\mathcal{H}_2$) проведённых рассуждений достаточно для вывода о сходимости.

Решение. Снимем оба ограничения по очереди.

Элементы обоих классов. Введём для каждого элемента выборки вектор

$$z(i) = \begin{cases} x(i), & x(i) \in \mathcal{H}_1, \\ -x(i), & x(i) \in \mathcal{H}_2. \end{cases}$$

Проверим, что в новых обозначениях оба случая выглядят одинаково.

Классификация верна для $x(i) \in \mathcal{H}_1$, когда $\langle w, x(i) \rangle > 0$, и для $x(i) \in \mathcal{H}_2$, когда $\langle w, x(i) \rangle \leq 0$, то есть $\langle w, -x(i) \rangle \geq 0$. В обоих случаях это условие $\langle w, z(i) \rangle > 0$ с точностью до границы. Правило коррекции: для $\mathcal{H}_1$ это $w + \eta x(i)$, для $\mathcal{H}_2$ это $w - \eta x(i)$, то есть в обоих случаях

$$w \leftarrow w + \eta z(i).$$

Линейная отделимость даёт $\langle \tilde{w}, z(i) \rangle > 0$ сразу для всех i , поэтому величины

$$\alpha = \min_i \langle \tilde{w}, z(i) \rangle > 0, \quad \beta = \max_i \|z(i)\|^2 = \max_i \|x(i)\|^2$$

определены и положительны. Выкладки, приводящие к (1) и (2), дословно повторяются с заменой x на z , поскольку в них использовались только вид коррекции и знак $\langle \tilde{w}, x \rangle$.

Обратим внимание на одну тонкость: отделимость должна быть строгой, то есть $\langle \tilde{w}, x \rangle < 0$ для $x \in \mathcal{C}_2$, а не ≤ 0 . При нестрогом неравенстве возможно $\alpha = 0$, и тогда оценка (3) теряет смысл. Для конечной выборки строгая отделимость следует из нестрогой малым поворотом гиперплоскости, но упомянуть это нужно.

Верные классификации на промежуточных итерациях. Такие итерации оставляют $w(n+1) = w(n)$. Значит они не добавляют слагаемых ни в сумму $\langle \tilde{w}, w(n+1) \rangle = \sum \langle \tilde{w}, z(k) \rangle$, ни в сумму $\|w(n+1)\|^2 \leq \sum \|z(k)\|^2$. Поэтому обе оценки остаются верными, если читать n как число *коррекции*, а не как номер итерации. Именно так их и надо понимать: неравенства (1) и (2) связывают норму весов с числом уже сделанных коррекций.

Завершение. Из (1) и (2) число коррекций не превосходит n_0 . После последней коррекции веса не меняются, а циклический перебор гарантирует, что за следующие N итераций будут предъявлены все элементы выборки, и ни на одном из них коррекции не произойдёт. Значит классификация верна для всей выборки, и критерий остановки срабатывает. Это и есть определение сходимости. ■

Задание 4

Дано. Обучающая выборка состоит из одного элемента $\{x, +1\}$, то есть $x \in \mathcal{H}_1$. Начальные веса $w(0)$ выбираются случайно: компоненты независимы и равномерно распределены на $[0, 1]$.

Требуется. Найти математическое ожидание числа неверных классификаций подряд. Выяснить, как оно зависит от $\|x\|$, и показать, что чем меньше коэффициент обучения, тем оно больше.

Решение. Так как элемент один, все итерации предъявляют один и тот же x , и коррекции идут подряд, пока классификация неверна. После k коррекций

$$w_k = w(0) + k\eta x, \quad \langle w_k, x \rangle = \langle w(0), x \rangle + k\eta \|x\|^2.$$

Обозначим $S = \langle w(0), x \rangle$. Скалярное произведение растёт с каждой коррекцией на постоянную величину $\eta \|x\|^2 > 0$, поэтому число неверных классификаций K – это наименьшее k , при котором оно становится положительным:

$$K = \begin{cases} 0, & S > 0, \\ \left\lfloor \frac{-S}{\eta \|x\|^2} \right\rfloor + 1, & S \leq 0. \end{cases}$$

Выделим направление: $x = \|x\| u$, где $\|u\| = 1$, и положим $t = -\langle w(0), u \rangle$. Тогда $S = -\|x\| t$ и

$$\frac{-S}{\eta \|x\|^2} = \frac{\|x\| t}{\eta \|x\|^2} = \frac{t}{\eta \|x\|},$$

поэтому

$$K = \mathbf{1}\{t \geq 0\} \left(\left\lfloor \frac{t}{c} \right\rfloor + 1 \right), \quad c = \eta \|x\|. \quad (4)$$

Отсюда сразу видно главное: K зависит от η и $\|x\|$ только через их произведение $c = \eta \|x\|$. Величина t от η и $\|x\|$ не зависит, она определяется только направлением u и распределением $w(0)$.

Оценим математическое ожидание. Из $t/c - 1 < \lfloor t/c \rfloor \leq t/c$ следует

$$\frac{Mt_+}{c} \leq MK \leq \frac{Mt_+}{c} + P(t \geq 0), \quad t_+ = \max(t, 0). \quad (5)$$

Отсюда асимптотика: $MK \rightarrow P(t \geq 0)$ при $c \rightarrow \infty$ и $MK \sim Mt_+/c$ при $c \rightarrow 0$.

Зависимость от $\|x\|$. По (5) при малых c величина MK обратно пропорциональна $\|x\|$: чем длиннее вектор, тем сильнее каждая коррекция сдвигает скалярное произведение, и тем быстрее оно становится положительным.

Зависимость от η . Точно так же MK обратно пропорциональна η : уменьшение коэффициента обучения вдвое примерно вдвое увеличивает число ошибок подряд. Это и требовалось показать. ■

Частный случай. Если все компоненты x неотрицательны (например x – яркости пикселей), то $S = \langle w(0), x \rangle \geq 0$ почти наверное, так как все компоненты $w(0)$ неотрицательны. Тогда $K = 0$: ни одной ошибки не произойдёт независимо от η .

Задание 5

Дано. Нейронная сеть, в которой функция активации линейна.

Требуется. Показать, что задаваемое такой сетью преобразование линейно.

Решение. При $\varphi(a) = a$ слой вычисляет $z^{(l)} = W_l z^{(l-1)} + b_l$. Развернём композицию слоёв, начиная с $z^{(0)} = x$:

$$z^{(1)} = W_1 x + b_1, \quad z^{(2)} = W_2 W_1 x + W_2 b_1 + b_2,$$

и по индукции

$$z^{(L)} = \underbrace{W_L W_{L-1} \cdots W_1}_M x + \underbrace{\sum_{l=1}^L W_L \cdots W_{l+1} b_l}_c = Mx + c.$$

Это аффинное преобразование, при $b_l = 0$ линейное. Если активация имеет общий линейный вид $\varphi(a) = \kappa a + \lambda$, то множитель κ вносится в W_l , а сдвиг λ в b_l , и результат тот же. ■

Практический смысл: любое число слоёв с линейной активацией сворачивается в один слой с матрицей M . Глубина сама по себе ничего не добавляет, и именно нелинейность активации делает наращивание слоёв осмысленным.

Задание 6

Дано. Сеть с линейными функциями активации, в которой количество узлов некоторого скрытого слоя меньше числа входов и меньше числа выходов сети.

Требуется. Показать, что задаваемое сетью линейное преобразование имеет меньшую размерность, чем размерность входа или выхода.

Решение. По заданию 5 сеть задаёт преобразование с матрицей $M = W_L \cdots W_1$, где W_l имеет размер $h_l \times h_{l-1}$. Ранг произведения не превосходит ранга каждого сомножителя, а ранг матрицы не превосходит меньшей из её размерностей, поэтому

$$\text{rank } M \leq \min_{1 \leq l \leq L} \text{rank } W_l \leq \min_{0 \leq l \leq L} h_l.$$

Пусть скрытый слой с номером s содержит $h_s = h$ узлов, причём $h < h_0$ (вход) и $h < h_L$ (выход). Тогда

$$\text{rank } M \leq h < \min(h_0, h_L).$$

Значит образ преобразования лежит в подпространстве размерности не выше h , а его ядро имеет размерность $\dim \ker M = h_0 - \text{rank } M \geq h_0 - h > 0$. ■

Содержательно: узкий слой работает как бутылочное горлышко. Существуют различные входные векторы, дающие одинаковый выход (их разность лежит в ядре), поэтому часть информации о входе теряется безвозвратно, какими бы ни были значения весов. На этом же эффекте, только уже с нелинейными слоями, построены автоэнкодеры.

Задание 7

Дано. Нейронная сеть с линейными функциями активации, в которой допустимы дуги, соединяющие узлы из разных слоёв, а не только соседних.

Требуется. Показать, что для ограниченных входных значений такая сеть эквивалентна многослойному перцептрону с линейными скрытыми узлами.

Решение. Докажем два включения.

Такая сеть задаёт аффинное преобразование. Граф сети ациклический, поэтому его узлы можно упорядочить топологически: каждая дуга ведёт от более раннего узла к более позднему. Идём по этому порядку. Значение входного узла есть x_i , то есть аффинная функция от x . Значение любого другого узла есть линейная комбинация значений его предшественников плюс сдвиг, а линейная комбинация аффинных функций аффинна. По индукции значение каждого узла, включая выходные, есть аффинная функция от x .

Любое такое преобразование реализуется обычным МСП. Достаточно показать, как убрать дуги, идущие через слой. Расширим состояние каждого слоя копией всех предыдущих:

$$\hat{z}^{(l)} = (z^{(l)}, z^{(l-1)}, \dots, z^{(0)}).$$

Тогда $\hat{z}^{(l)} = M_l \hat{z}^{(l-1)}$, где первая блочная строка M_l содержит веса всех дуг, входящих в слой l (в том числе идущих из далёких слоёв, значения которых теперь доступны в $\hat{z}^{(l-1)}$), а остальные блоки единичные и просто пробрасывают значения дальше. Все узлы линейные, все дуги соединяют только соседние слои.

Пример для дуги, идущей со входа сразу на выход, $y = W_2 W_1 x + Sx$:

$$M_1 = \begin{pmatrix} W_1 \\ I \end{pmatrix}, \quad M_2 = (W_2 \quad S), \quad M_2 M_1 x = W_2 W_1 x + Sx = y. \quad \blacksquare$$

Замечание про ограниченность входа. Для линейной активации равенство точное, и никакой ограниченности не требуется. Условие становится существенным, если линейность активации сама является приближением на ограниченном участке: так, $\sigma(a) \approx 1/2 + a/4$ вблизи нуля, и рассуждение работает лишь пока преактивации остаются малыми.

Задание 8

Дано. Логистический сигмоид $\sigma(a) = 1/(1+e^{-a})$ и гиперболический тангенс $\tanh(a) = (e^a - e^{-a})/(e^a + e^{-a})$.

Требуется. Найти их производные и объяснить, почему такие функции активации удобны при реализации метода обратного распространения ошибки.

Решение. Дифференцируем сигмоид как сложную функцию и группируем множители:

$$\sigma'(a) = \frac{e^{-a}}{(1+e^{-a})^2} = \frac{1}{1+e^{-a}} \cdot \frac{e^{-a}}{1+e^{-a}} = \sigma(a)(1-\sigma(a)),$$

где во второй дроби использовано $\frac{e^{-a}}{1+e^{-a}} = 1 - \frac{1}{1+e^{-a}}$.

Для гиперболического тангенса дифференцируем как частное:

$$\tanh'(a) = \frac{(e^a + e^{-a})^2 - (e^a - e^{-a})^2}{(e^a + e^{-a})^2} = 1 - \tanh^2(a).$$

Почему это удобно. Метод обратного распространения устроен так: сначала прямой проход вычисляет активации всех узлов, затем обратный проход перемножает по цепному правилу производные активаций. Обе найденные производные выражаются *через само значение функции*, а не через её аргумент. Поэтому прямой проход достаточно сохранить в виде значений $z = \sigma(a)$, и на обратном проходе производная получается как $z(1-z)$: не нужно ни хранить преактивации a , ни заново вычислять экспоненты. Вместо вызова `exp` на каждый узел остаётся одно умножение, что при миллионах узлов существенно.

Дополнительно обе функции монотонны, гладки на всей прямой и имеют ограниченные производные ($\sigma' \leq 1/4$, $\tanh' \leq 1$), поэтому множители в цепном правиле не растут. Обратная сторона той же ограниченности – затухание градиента: при большом числе слоёв произведение множителей, меньших единицы, стремится к нулю.

Функции связаны соотношением $\tanh(a) = 2\sigma(2a) - 1$, то есть с точностью до масштаба это одна и та же функция; $\tanh$ отличается тем, что центрирован относительно нуля, а его производная в нуле равна 1 против $1/4$ у сигмоида.