Задача 4. Нейронные сети

Нейронные сети и машинное обучение

Задания 1–8

1 Что нужно знать

1.1 Обозначения

x	вектор признаков, компонента $x_0 = 1$ отвечает за смещение
w, $\langle w, x\rangle$	вектор весов и скалярное произведение
θ	ступенчатая функция активации
η	коэффициент обучения
$\mathcal{C}_1, \mathcal{C}_2$	классы
$\mathcal{H}_1, \mathcal{H}_2$	обучающие выборки этих классов, $\mathcal{H} = \mathcal{H}_1 \cup \mathcal{H}_2$
N	размер выборки $\mathcal{H}$
$\tilde{w}$	разделяющий вектор весов
$w(n)$	веса на n-й итерации
W_l, b_l	матрица весов и вектор смещений l-го слоя
d_l	число узлов l-го слоя, d_0 – входов, d_L – выходов
h	функция активации
σ, tanh	логистический сигмоид и гиперболический тангенс

1.2 Элементарный перцептрон

Элементарный перцептрон вычисляет

$$y(x) = \theta\big(\langle w, x\rangle\big), \qquad \theta(t) = \begin{cases} 1, & t > 0, \\ -1, & t \le 0. \end{cases}$$

Уравнение $\langle w, x\rangle = 0$ задаёт гиперплоскость, и точка относится к классу по тому, с какой стороны от неё она лежит. Классы *линейно отделимы*, если существует $\tilde{w}$ с

$$\langle \tilde{w}, x\rangle > 0 \;\; \forall x \in \mathcal{C}_1, \qquad \langle \tilde{w}, x\rangle \le 0 \;\; \forall x \in \mathcal{C}_2.$$

1.3 Алгоритм обучения перцептрона

Элементы выборки $\mathcal{H}$ пронумерованы и предъявляются по кругу: на n-й итерации предъявляется элемент $x(n)$ с номером $n \bmod N$. Начальные веса $w(0) = 0$, и

$$w(n+1) = \begin{cases} w(n) + \eta\, x(n), & x(n) \in \mathcal{H}_1,\ \langle w(n), x(n)\rangle \le 0, \\ w(n) - \eta\, x(n), & x(n) \in \mathcal{H}_2,\ \langle w(n), x(n)\rangle > 0, \\ w(n) & \text{иначе, то есть при верной классификации.} \end{cases}$$

Изменение весов будем называть *коррекцией*. Алгоритм *сходится*, если за конечное число итераций находятся веса, которые дальше не меняются и верно классифицируют всю выборку. Для этого достаточно, чтобы за N итераций подряд не было ни одной коррекции: тогда каждый элемент предъявлен и классифицирован верно при одних и тех же весах.

1.4 Теорема о сходимости

Теорема 1. *Если классы линейно отделимы, алгоритм обучения перцептрона сходится.*

В доказательстве полагается $\eta = 1$ и рассматривается случай, когда все встречающиеся $x(k)$ лежат в $\mathcal{H}_1$ и классифицируются неверно. Тогда после n коррекций $w(n) = x(0) + \cdots + x(n-1)$. Обозначим

$$\alpha = \min_{x \in \mathcal{H}_1} \langle \tilde{w}, x \rangle > 0, \qquad \beta = \max_{x \in \mathcal{H}_1} \|x\|^2 .$$

Оценка снизу. Каждое слагаемое в $\langle \tilde{w}, w(n) \rangle = \sum_{i=0}^{n-1} \langle \tilde{w}, x(i) \rangle$ не меньше α, и по неравенству Коши-Буняковского

$$\|w(n)\|^2 \geq \frac{\langle \tilde{w}, w(n) \rangle^2}{\|\tilde{w}\|^2} \geq \frac{(n\alpha)^2}{\|\tilde{w}\|^2}. \tag{1}$$

Оценка сверху. При неверной классификации $\langle w(k), x(k) \rangle \leq 0$, поэтому

$$\|w(k+1)\|^2 = \|w(k)\|^2 + 2\langle w(k), x(k) \rangle + \|x(k)\|^2 \leq \|w(k)\|^2 + \beta,$$

и суммирование по $k = 0, \ldots, n-1$ даёт

$$\|w(n)\|^2 \leq n\beta. \tag{2}$$

Из (1) и (2) $n^2\alpha^2 \leq n\beta \|\tilde{w}\|^2$, то есть коррекций не больше

$$n_0 = \frac{\beta \|\tilde{w}\|^2}{\alpha^2}. \tag{3}$$

Предположение $\eta = 1$ снимается в задании 2, а предположение о том, что все элементы лежат в $\mathcal{H}_1$ и классифицируются неверно, – в задании 3.

1.5 Многослойный перцептрон

Многослойный перцептрон вычисляет

$$z^{(l)} = h\big(W_l z^{(l-1)} + b_l\big), \qquad l = 1, \ldots, L, \qquad z^{(0)} = x,$$

где h применяется покомпонентно, а W_l имеет размер $d_l \times d_{l-1}$. Активация *линейна*, если $h(a) = a$ или, в общем виде, $h(a) = \kappa a + \lambda$.

Для задания 6 понадобятся свойства ранга матрицы A размера $p \times q$:

$$\operatorname{rank}(BA) \leq \min(\operatorname{rank} B,\ \operatorname{rank} A), \qquad \operatorname{rank} A \leq \min(p, q),$$

и $\dim \ker A = q - \operatorname{rank} A$.

1.6 Обратное распространение ошибки

Для одного объекта выборки с ошибкой E_n нейрон j вычисляет $a_j = \sum_i w_{ij} z_i$ по входящим дугам и $z_j = h(a_j)$. Обозначим $\delta_j = \partial E_n / \partial a_j$. Тогда

$$\frac{\partial E_n}{\partial w_{ij}} = \delta_j z_i, \qquad \delta_j = h'(a_j) \sum_k w_{jk} \delta_k,$$

где вторая сумма берётся по дугам, выходящим из нейрона j. Значения z_j вычисляются на прямом проходе, значения δ_j – на обратном, от выходного слоя к входному.

2 Задания

Задание 1

Дано. Алгоритм обучения перцептрона из доказательства теоремы о сходимости: векторы признаков обучающей выборки пронумерованы и предъявляются по кругу в порядке нумерации.

Требуется. Выяснить, важен ли порядок, в котором пронумерованы векторы признаков обучающей выборки.

Зачем это нужно. Нумерация выбирается при реализации произвольно, и нужно знать, влияет ли она на сходимость и на результат обучения.

Решение. *На сходимость порядок не влияет.* Коррекций не больше n_0 из (3) (в общем случае это показано в задании 3), а α, β и $\tilde{w}$ определяются выборкой как множеством и от нумерации не зависят. После последней коррекции за N итераций предъявляются все элементы при любой нумерации, поэтому алгоритм сходится при любом порядке.

На результат порядок влияет. Пусть признак один, векторы имеют вид $(1, t)$, $\eta = 1$,

$$\mathcal{H}_1 = \{a, b\}, \quad \mathcal{H}_2 = \{c\}, \qquad a = (1, 1), \quad b = (1, 2), \quad c = (1, -2).$$

В обоих порядках первый элемент даёт $\langle 0, x\rangle = 0$ и коррекцию $w = x$, после чего коррекций больше нет:

$$\begin{aligned} &a, b, c: \quad w = a = (1, 1), \quad \langle w, b\rangle = 3 > 0, \quad \langle w, c\rangle = -1 \le 0, \quad \langle w, a\rangle = 2 > 0; \\ &b, a, c: \quad w = b = (1, 2), \quad \langle w, a\rangle = 3 > 0, \quad \langle w, c\rangle = -3 \le 0. \end{aligned}$$

Оба вектора разделяют выборку, но задают разные гиперплоскости $1 + t = 0$ и $1 + 2t = 0$. Значит найденный разделяющий вектор зависит от нумерации.

Задание 2

Дано. Алгоритм обучения перцептрона с коэффициентом обучения $\eta > 0$.

Требуется. Показать, что если сходимость алгоритма имеет место при коэффициенте обучения, равном 1, то она имеет место и при меньших значениях η, но потребует большего количества итераций.

Зачем это нужно. Этим обосновывается выбор $\eta = 1$ в доказательстве теоремы.

Решение. *Начальные веса $w(0) = 0$, как в алгоритме.* Обозначим через $w_\eta(n)$ веса на n-й итерации при коэффициенте η и докажем по индукции, что $w_\eta(n) = \eta\, w_1(n)$. База: $w_\eta(0) = 0 = \eta\, w_1(0)$. Переход: решение о коррекции принимается по знаку скалярного произведения, а

$$\langle w_\eta(n), x(n)\rangle = \eta\, \langle w_1(n), x(n)\rangle$$

имеет тот же знак, что и $\langle w_1(n), x(n)\rangle$. Значит оба запуска на итерации n поступают одинаково: либо оба не меняют веса, либо

$$w_\eta(n+1) = \eta w_1(n) \pm \eta x(n) = \eta\big(w_1(n) \pm x(n)\big) = \eta\, w_1(n+1).$$

Следовательно, при любом $\eta > 0$ алгоритм принимает те же решения, что при $\eta = 1$, и сходится ровно за то же число итераций. При $w(0) = 0$ число итераций от η не зависит; оно растёт при уменьшении η, только если $w(0) \neq 0$.

Замечание: начальные веса $w(0) \neq 0$. Положим $v(n) = w(n)/\eta$. Тогда

$$v(n+1) = v(n) \pm x(n),$$

а знаки скалярных произведений при делении на $\eta > 0$ не меняются. Значит работа с коэффициентом η из точки $w(0)$ совпадает с работой с коэффициентом 1 из точки $v(0) = w(0)/\eta$. Как в теореме, будем считать, что корректируются элементы $\mathcal{H}_1$ (общий случай сводится к этому в задании 3).

Сходимость. После n коррекций $\langle \tilde{w}, v\rangle \geq \langle \tilde{w}, v(0)\rangle + n\alpha$ и $\|v\|^2 \leq \|v(0)\|^2 + n\beta$, поэтому при $n \geq -\langle \tilde{w}, v(0)\rangle/\alpha$ неравенство Коши-Буняковского даёт

$$\big(\langle \tilde{w}, v(0)\rangle + n\alpha\big)^2 \leq \|\tilde{w}\|^2 \big(\|v(0)\|^2 + n\beta\big).$$

Слева многочлен второй степени от n со старшим коэффициентом $\alpha^2 > 0$, справа первой степени, поэтому неравенство верно лишь для конечного числа n, и число коррекций конечно.

Рост числа итераций. Пусть $w(0)$ неверно классифицирует элемент $x^* \in \mathcal{H}_1$, то есть $\langle w(0), x^*\rangle < 0$. Каждая коррекция прибавляет к v вектор $x(k) \in \mathcal{H}_1$, и так как $\langle x(k), x^*\rangle \leq \|x(k)\|\,\|x^*\| \leq \beta$, после n коррекций

$$\langle v, x^*\rangle = \frac{\langle w(0), x^*\rangle}{\eta} + \sum_k \langle x(k), x^*\rangle \leq \frac{\langle w(0), x^*\rangle}{\eta} + n\beta.$$

В момент сходимости x^* классифицируется верно, $\langle v, x^*\rangle > 0$, откуда

$$n > \frac{|\langle w(0), x^*\rangle|}{\eta\beta}.$$

Число коррекций, а с ним и число итераций, растёт при уменьшении η не медленнее, чем $1/\eta$.

Задание 3

Дано. Теорема о сходимости доказана в предположении, что $x(n) \in \mathcal{H}_1$ и классификация производится неверно на всех итерациях вплоть до $(n+1)$-й.

Требуется. Показать, что при других возможных промежуточных результатах работы алгоритма обучения к $(n+1)$-й итерации (имеются итерации, на которых классификация производится верно; выбираемые в соответствии с нумерацией векторы признаков принадлежат классу $\mathcal{H}_2$) проведённых рассуждений достаточно, чтобы утверждать сходимость алгоритма.

Зачем это нужно. Задание дополняет упрощённое доказательство теоремы до полного.

Решение. *Элементы обоих классов.* Положим $z = x$ для $x \in \mathcal{H}_1$ и $z = -x$ для $x \in \mathcal{H}_2$. Неверная классификация в обоих случаях означает $\langle w, z\rangle \leq 0$, а коррекция в обоих случаях имеет вид $w \leftarrow w + \eta z$. Если $\langle \tilde{w}, z\rangle > 0$ для всех z, то

$$\alpha = \min_z \langle \tilde{w}, z\rangle > 0, \qquad \beta = \max_z \|z\|^2 = \max_{x\in\mathcal{H}} \|x\|^2,$$

и выкладки (1), (2) повторяются дословно с заменой x на z: в них использовались только вид коррекции и знаки скалярных произведений.

Условие $\langle \tilde{w}, z \rangle > 0$ для $x \in \mathcal{H}_2$ означает строгое неравенство $\langle \tilde{w}, x \rangle < 0$. Его можно обеспечить: если $\gamma = \min_{x \in \mathcal{H}_1} \langle \tilde{w}, x \rangle > 0$, то уменьшение компоненты $\tilde{w}_0$ на $\gamma/2$ уменьшает все $\langle \tilde{w}, x \rangle$ на $\gamma/2$ (так как $x_0 = 1$) и даёт значения $\geq \gamma/2$ на $\mathcal{H}_1$ и $\leq -\gamma/2$ на $\mathcal{H}_2$.

Итерации с верной классификацией веса не меняют и не добавляют слагаемых ни в $\langle \tilde{w}, w \rangle$, ни в оценку $\|w\|^2$. Поэтому (1) и (2) верны, если n – число коррекций, а не номер итерации.

Завершение. Коррекций не больше n_0. После последней коррекции веса не меняются, и за следующие N итераций предъявляются все элементы выборки без единой коррекции. Значит все они классифицируются верно, и алгоритм сошёлся. ■

Задание 4

Дано. Обучающая выборка состоит из одного элемента $\{x, +1\}$, то есть $x \in \mathcal{H}_1$. Начальные веса выбираются случайно: компоненты $w(0)$ независимы и равномерно распределены на $[0, 1]$.

Требуется. Найти, сколько в среднем неверных классификаций подряд может быть произведено при выполнении алгоритма обучения (среднее – математическое ожидание). Выяснить, как оно зависит от $\|x\|$, и показать, что чем меньше коэффициент обучения, тем оно больше.

Зачем это нужно. На простейшем примере видно, как число ошибок при обучении зависит от начальных весов, длины вектора признаков и коэффициента обучения.

Решение. Элемент один, поэтому все итерации предъявляют x, и коррекции идут подряд, пока классификация неверна. После k коррекций $w = w(0) + k\eta x$ и

$$\langle w, x \rangle = S + k\eta \|x\|^2, \qquad S = \langle w(0), x \rangle.$$

Число неверных классификаций K – наименьшее k, при котором это выражение положительно:

$$K = 0 \ \text{ при } S > 0, \qquad K = \left\lfloor \frac{-S}{\eta \|x\|^2} \right\rfloor + 1 \ \text{ при } S \leq 0.$$

Одна компонента. Пусть $x \in \mathbb{R}$, $x \neq 0$, смещения нет, вес $w(0) = w$ равномерен на $[0, 1]$ и $S = wx$. При $x > 0$ почти наверное $S > 0$ и $K = 0$. При $x < 0$ имеем $-S = w|x|$ и

$$K = \left\lfloor \frac{w}{c} \right\rfloor + 1, \qquad c = \eta |x|.$$

Так как $\lfloor w/c \rfloor = \sum_{j \geq 1} \mathbf{1}\{w \geq jc\}$, а $\mathsf{P}(w \geq jc) = 1 - jc$ при $jc \leq 1$ и 0 при $jc > 1$,

$$\mathsf{M}K = 1 + \sum_{j=1}^{q} (1 - jc) = 1 + q - \frac{c\, q(q+1)}{2}, \qquad q = \left\lfloor \frac{1}{c} \right\rfloor.$$

Из $w/c - 1 < \lfloor w/c \rfloor \leq w/c$ и $\mathsf{M}w = 1/2$

$$\frac{1}{2\eta |x|} < \mathsf{M}K \leq \frac{1}{2\eta |x|} + 1,$$

то есть $\mathsf{M}K$ примерно обратно пропорционально $\|x\| = |x|$ и η. Каждое слагаемое $\mathsf{P}(w \geq jc) = \max(0, 1 - jc)$ не возрастает с ростом $c = \eta |x|$, а при $c < 1$ слагаемое с

$j = 1$ строго убывает. Поэтому чем меньше η, тем больше $\mathsf{M}K$: строго, пока $\eta\,|x| < 1$, а при $\eta\,|x| \geq 1$ почти наверное $K = 1$. ■

Замечание: общий случай. Пусть $x \in \mathbb{R}^{m+1}$, $x_0 = 1$, $u = x/\,\|x\|$ и $t = -\langle w(0), u\rangle$. Тогда $-S = \|x\|\,t$ и

$$K = \mathbf{1}\{t \geq 0\}\Big(\Big\lfloor \frac{t}{c} \Big\rfloor + 1\Big), \qquad c = \eta\,\|x\|\,.$$

Величина t не зависит от η и $\|x\|$, а K при каждом t не возрастает с ростом c. Поэтому $\mathsf{M}K$ зависит от η и $\|x\|$ только через $c = \eta\,\|x\|$, не убывает при уменьшении η, и

$$\frac{\mathsf{M}t_+}{c} \leq \mathsf{M}K \leq \frac{\mathsf{M}t_+}{c} + \mathsf{P}(t \geq 0), \qquad t_+ = \max(t, 0).$$

Если все компоненты x неотрицательны (например, x – яркости пикселей и $x_0 = 1$), то $t < 0$ почти наверное и $K = 0$ при любом η.

Задание 5

Дано. Нейронная сеть, в которой функция активации линейна: $h(a) = a$.
Требуется. Показать, что преобразование, задаваемое такой нейронной сетью, будет линейным.

Зачем это нужно. Объясняет, зачем в нейронных сетях нужны нелинейные функции активации.

Решение. Докажем по индукции, что $z^{(l)} = M_l x + c_l$ с некоторыми матрицей M_l и вектором c_l. База: $z^{(0)} = x$, $M_0 = I$, $c_0 = 0$. Переход:

$$z^{(l+1)} = W_{l+1}\big(M_l x + c_l\big) + b_{l+1} = \underbrace{W_{l+1}M_l}_{M_{l+1}}\,x + \underbrace{W_{l+1}c_l + b_{l+1}}_{c_{l+1}}.$$

Итак, сеть задаёт преобразование $x \mapsto Mx + c$ с $M = W_L \cdots W_1$; при нулевых смещениях оно линейно, в общем случае аффинно. Если $h(a) = \kappa a + \lambda$, то $h(Wz + b) = (\kappa W)z + (\kappa b + \lambda\mathbf{1})$, где $\mathbf{1}$ – вектор из единиц: множитель κ вносится в веса, сдвиг λ в смещения, и вывод тот же. ■

Задание 6

Дано. Сеть с линейными функциями активации, в которой число узлов d скрытого слоя меньше числа входов d_0 или числа выходов d_L.
Требуется. Показать, что задаваемое сетью линейное преобразование имеет меньшую размерность, чем размерность входа или выхода.

Зачем это нужно. Узкий скрытый слой используется в автоэнкодерах. Задание показывает, что он ограничивает размерность преобразования при любых весах.

Решение. По заданию 5 сеть задаёт $x \mapsto Mx + c$ с $M = W_L \cdots W_1$. Размерность преобразования – это размерность его образа, то есть $\operatorname{rank} M$. Если скрытый слой с номером l содержит d узлов, то W_l имеет d строк, и $\operatorname{rank} M \leq \operatorname{rank} W_l \leq d$. Если $d < d_0$, то $\operatorname{rank} M < d_0$, и $\dim\ker M = d_0 - \operatorname{rank} M > 0$: разные входы, разность которых лежит в $\ker M$, дают одинаковый выход. Если $d < d_L$, то $\operatorname{rank} M < d_L$: выходы лежат в сдвинутом на c подпространстве размерности меньше d_L. ■

Задание 7

Дано. Нейронная сеть с линейными функциями активации, в которой допустимы дуги, соединяющие узлы из разных слоёв.

Требуется. Показать, что для ограниченных входных значений такая сеть эквивалентна многослойному перцептрону с линейными скрытыми узлами, то есть со скрытыми узлами, в которых значения z_j получаются с помощью линейных функций.

Зачем это нужно. Показывает, что соединения через слой, как в остаточных сетях, при линейных активациях не расширяют класс задаваемых преобразований.

Решение. *Сеть задаёт аффинное преобразование.* Граф сети не содержит ориентированных циклов, поэтому узлы можно перенумеровать так, чтобы каждая дуга вела от узла с меньшим номером к узлу с большим. Значение входного узла есть x_i. Значение любого другого узла – линейная комбинация значений узлов с меньшими номерами плюс смещение; если те аффинно зависят от x, то и оно. По индукции все узлы, включая выходные, аффинно зависят от x, и выход сети равен $Mx + c$.

Перцептрон с тем же преобразованием. Перцептрон с одним скрытым слоем из d_0 линейных узлов и весами $W_1 = I$, $b_1 = 0$, $W_2 = M$, $b_2 = c$ вычисляет $M(Ix) + c = Mx + c$. ■

Замечание об ограниченности входа. Для строго линейных узлов она не нужна. Она нужна, если линейный узел заменяется сигмоидальным, работающим на почти линейном участке:

$$\frac{4}{\varepsilon}\Big(\sigma(\varepsilon a) - \frac{1}{2}\Big) = a + O(\varepsilon^2 a^3).$$

Узел с весом входа ε, весом выхода $4/\varepsilon$ и сдвигом $-2/\varepsilon$ воспроизводит a равномерно на $|a| \le R$ с ошибкой $O(\varepsilon^2 R^3)$. При неограниченном a это неверно, так как σ ограничена.

Задание 8

Дано. Логистический сигмоид и гиперболический тангенс

$$\sigma(a) = \frac{1}{1 + e^{-a}}, \qquad \tanh(a) = \frac{e^{a} - e^{-a}}{e^{a} + e^{-a}}.$$

Требуется. Найти их производные и объяснить, почему такие функции активации удобно использовать при реализации метода обратного распространения ошибки.

Зачем это нужно. Производные функций активации вычисляются на каждом шаге обратного распространения ошибки.

Решение. Для сигмоида

$$\sigma'(a) = \frac{e^{-a}}{(1 + e^{-a})^2} = \frac{1}{1 + e^{-a}} \cdot \frac{e^{-a}}{1 + e^{-a}} = \sigma(a)\big(1 - \sigma(a)\big),$$

так как $e^{-a}/(1+e^{-a}) = 1 - 1/(1+e^{-a})$. Для тангенса по формуле производной частного

$$\tanh'(a) = \frac{(e^{a} + e^{-a})^2 - (e^{a} - e^{-a})^2}{(e^{a} + e^{-a})^2} = 1 - \tanh^2(a).$$

Почему это удобно. Обратный проход вычисляет $\delta_j = h'(a_j) \sum_k w_{jk}\delta_k$, и множитель $h'(a_j)$ для этих функций выражается через значение нейрона $z_j = h(a_j)$:

$$h = \sigma: \quad h'(a_j) = z_j(1 - z_j), \qquad h = \tanh: \quad h'(a_j) = 1 - z_j^2.$$

Значения z_j уже вычислены на прямом проходе, поэтому на обратном проходе производная получается одним умножением: не нужно ни хранить a_j, ни заново вычислять экспоненты.