Задача 4. Нейронные сети

Нейронные сети и машинное обучение

Задания 1–8

1 Что нужно знать

1.1 Обозначения

$x = (x_0, x_1, \ldots, x_m)$	вектор признаков, $x_0 = 1$
$w = (w_0, w_1, \ldots, w_m)$	веса перцептрона, w_0 – смещение
$\langle u, v\rangle$, $\|u\|$	скалярное произведение и длина вектора
$\mathcal{C}_1, \mathcal{C}_2$	классы
$\mathcal{H}_1, \mathcal{H}_2$	обучающие выборки классов, $\mathcal{H} = \mathcal{H}_1 \cup \mathcal{H}_2$
N	число элементов $\mathcal{H}$
$x(n)$, $w(n)$	предъявленный элемент и веса на n-й итерации
η	коэффициент обучения
$\tilde{w}$	разделяющий вектор весов
a_j, z_j	взвешенная сумма входов нейрона j и его выход
w_{ji}	вес дуги из узла i в нейрон j, w_{j0} – смещение нейрона j
h	функция активации: $z_j = h(a_j)$
θ, σ, tanh	ступенчатая функция, сигмоид, гиперболический тангенс
W_l, b_l, d_l	матрица весов, вектор смещений и число нейронов слоя l
δ_j	производная ошибки по a_j
P, M	вероятность и математическое ожидание
$\mathbf{1}\{A\}$	индикатор: 1, если A верно, и 0 иначе
$\lfloor y \rfloor$	целая часть: наибольшее целое, не большее y

1.2 Скалярное произведение

$$\langle u, v\rangle = \sum_i u_i v_i, \qquad \|u\|^2 = \langle u, u\rangle, \qquad \|u+v\|^2 = \|u\|^2 + 2\langle u, v\rangle + \|v\|^2 .$$

Неравенство Коши-Буняковского: $|\langle u, v\rangle| \le \|u\|\ \|v\|$.

1.3 Элементарный перцептрон

Перцептрон относит x к классу по знаку взвешенной суммы признаков:

$$y(x) = \theta\big(\langle w, x\rangle\big), \qquad \langle w, x\rangle = w_0 + w_1 x_1 + \cdots + w_m x_m, \qquad \theta(t) = \begin{cases} 1, & t > 0, \\ -1, & t \le 0. \end{cases}$$

Значение $y = 1$ означает класс $\mathcal{C}_1$, значение $y = -1$ – класс $\mathcal{C}_2$. Граница классов – гиперплоскость $\langle w, x\rangle = 0$; её точки отнесены к $\mathcal{C}_2$, как в условии отделимости и в алгоритме обучения. Пример: один признак, $x = (1, t)$, $w = (-1, 2)$:

$$\langle w, x\rangle = 2t - 1, \qquad y = 1 \text{ при } t > \tfrac{1}{2}, \qquad y = -1 \text{ при } t \le \tfrac{1}{2}.$$

Классы *линейно отделимы*, если существует $\tilde{w}$ с

$$\langle \tilde{w}, x\rangle > 0 \ \ \forall x \in \mathcal{C}_1, \qquad \langle \tilde{w}, x\rangle \le 0 \ \ \forall x \in \mathcal{C}_2.$$

1.4 Алгоритм обучения перцептрона

Элементы $\mathcal{H}$ пронумерованы и предъявляются по кругу: $x(n)$ – элемент с номером $n \bmod N$. Начальные веса $w(0) = 0$,

$$w(n+1) = \begin{cases} w(n) + \eta\, x(n), & x(n) \in \mathcal{H}_1,\ \langle w(n), x(n)\rangle \le 0 \ \ \text{(ошибка)},\\ w(n) - \eta\, x(n), & x(n) \in \mathcal{H}_2,\ \langle w(n), x(n)\rangle > 0 \ \ \text{(ошибка)},\\ w(n) & \text{иначе (верно)}. \end{cases}$$

Изменение весов называется *коррекцией*. Коррекция сдвигает $\langle w, x\rangle$ в нужную сторону:

$$\langle w + \eta x, x\rangle = \langle w, x\rangle + \eta \left\|x\right\|^2, \qquad \langle w - \eta x, x\rangle = \langle w, x\rangle - \eta \left\|x\right\|^2. \tag{1}$$

Пример: $\eta = 1$, $x(0) = (1,1) \in \mathcal{H}_1$. Тогда $\langle w(0), x(0)\rangle = 0$ – ошибка, $w(1) = (1,1)$ и $\langle w(1), x(0)\rangle = 2 > 0$.

Алгоритм *сходится*, если за конечное число итераций находятся веса, которые дальше не меняются и верно классифицируют всю выборку. Для этого достаточно N итераций подряд без коррекций: за них предъявлен каждый элемент.

1.5 Теорема о сходимости

Теорема 1. *Если классы линейно отделимы, алгоритм обучения перцептрона сходится.*

Доказательство проводится при $\eta = 1$ в предположении, что на всех итерациях $x(k) \in \mathcal{H}_1$ и классификация неверна (общий случай – задания 2 и 3). Тогда $w(n) = x(0) + \cdots + x(n-1)$. Обозначим

$$\alpha = \min_{x\in\mathcal{H}_1} \langle \tilde{w}, x\rangle > 0, \qquad \beta = \max_{x\in\mathcal{H}_1} \left\|x\right\|^2.$$

Оценка снизу (по неравенству Коши-Буняковского):

$$\langle \tilde{w}, w(n)\rangle = \sum_{k=0}^{n-1} \underbrace{\langle \tilde{w}, x(k)\rangle}_{\ge\alpha} \ge n\alpha, \qquad \left\|w(n)\right\|^2 \ge \frac{\langle \tilde{w}, w(n)\rangle^2}{\left\|\tilde{w}\right\|^2} \ge \frac{n^2\alpha^2}{\left\|\tilde{w}\right\|^2}. \tag{2}$$

Оценка сверху:

$$\left\|w(k+1)\right\|^2 = \left\|w(k)\right\|^2 + 2\underbrace{\langle w(k), x(k)\rangle}_{\le 0} + \underbrace{\left\|x(k)\right\|^2}_{\le\beta} \le \left\|w(k)\right\|^2 + \beta,$$

и сложение по $k = 0, \ldots, n-1$ даёт

$$\left\|w(n)\right\|^2 \le n\beta. \tag{3}$$

Из (2) и (3)

$$\frac{n^2\alpha^2}{\left\|\tilde{w}\right\|^2} \le n\beta, \qquad n \le n_0 = \frac{\beta \left\|\tilde{w}\right\|^2}{\alpha^2}. \tag{4}$$

1.6 Случайные величины и целая часть

Если w равномерно распределена на $[0,1]$, то

$$\mathsf{P}(w \geq s) = \begin{cases} 1-s, & 0 \leq s \leq 1, \\ 0, & s > 1, \end{cases} \qquad \mathsf{P}(w = s) = 0, \qquad \mathsf{M}w = \tfrac{1}{2}.$$

Для индикатора $\mathsf{M}\mathbf{1}\{A\} = \mathsf{P}(A)$. Математическое ожидание линейно и монотонно:

$$\mathsf{M}\Big(\sum_i \xi_i\Big) = \sum_i \mathsf{M}\xi_i, \qquad \mathsf{M}(a\xi + b) = a\mathsf{M}\xi + b, \qquad \xi \leq \zeta \text{ влечёт } \mathsf{M}\xi \leq \mathsf{M}\zeta.$$

Целая часть числа $y \geq 0$ – количество целых $j \geq 1$, не больших y:

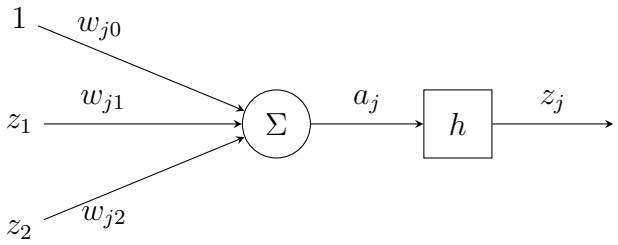
$$\lfloor y \rfloor = \sum_{j \geq 1} \mathbf{1}\{y \geq j\}, \qquad y - 1 < \lfloor y \rfloor \leq y, \qquad \text{например, } \lfloor 2{,}7 \rfloor = 1 + 1 + 0 + \cdots = 2.$$

1.7 Нейрон и функция активации h

На вход нейрона j подаются числа $z_1, \ldots, z_M$ (у первого слоя это признаки $x_1, \ldots, x_m$), и он вычисляет два числа:

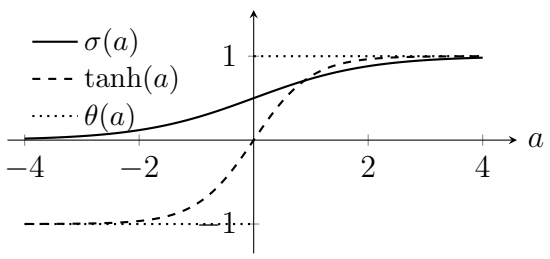
$$a_j = w_{j0} + \sum_{i=1}^{M} w_{ji} z_i, \qquad z_j = h(a_j). \tag{5}$$

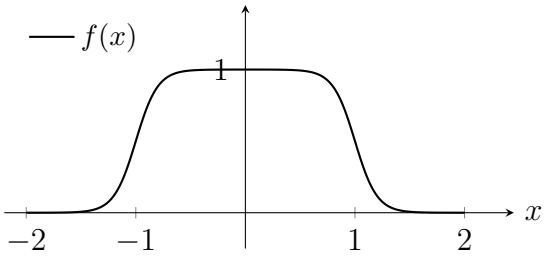
Сначала, как у перцептрона, входы складываются с весами, затем сумма a_j подставляется в функцию h, а результат z_j идёт на входы следующего слоя:



Функция активации h – обычная функция одного числа: получает сумму a_j и возвращает выход z_j. Она одна для всех нейронов слоя и параметров не имеет: при обучении подбираются только веса w_{ji}.

$h(a)$	значения	$a = -2$	$a = 0$	$a = 2$
$\theta(a)$	$\{-1, 1\}$	-1	-1	1
a (линейная)	$\mathbb{R}$	-2	0	2
$\sigma(a) = \dfrac{1}{1+e^{-a}}$	$(0,1)$	0,12	0,5	0,88
$\tanh(a) = \dfrac{e^a - e^{-a}}{e^a + e^{-a}}$	$(-1,1)$	$-0{,}96$	0	0,96





Элементарный перцептрон – один нейрон с $h = \theta$. Функции σ и $\tanh$ – сглаженные ступеньки: при больших $|a|$ почти постоянны, около нуля почти линейны. В отличие от θ, у них есть производная, а она нужна обратному распространению ошибки.

Пример нейрона: $z = (1, 2)$, $w_{j0} = 1$, $w_{j1} = 0{,}5$, $w_{j2} = -1$:

$$a_j = 1 + 0{,}5 \cdot 1 - 1 \cdot 2 = -0{,}5, \qquad z_j = \tanh(-0{,}5) = -0{,}46 \;\text{ или }\; z_j = \sigma(-0{,}5) = 0{,}38.$$

Зачем нужна h. Сеть с одним входом, двумя скрытыми нейронами с $h = \sigma$ и выходом, равным разности их выходов (график справа):

$$f(x) = \sigma(10x + 10) - \sigma(10x - 10), \qquad f(-2) \approx 0, \quad f(0) \approx 1, \quad f(2) \approx 0.$$

Функция растёт около $x = -1$ и убывает около $x = 1$, а линейная функция так не умеет. С $h(a) = a$ та же сеть даёт $f(x) = (10x + 10) - (10x - 10) = 20$: без нелинейной h любая сеть задаёт линейное преобразование (задание 5).

1.8 Многослойный перцептрон

Слои вычисляются по очереди: выходы слоя $l - 1$ – входы слоя l. Все суммы a_j слоя записываются одним вектором:

$$z^{(0)} = x, \qquad z^{(l)} = h\big(W_l z^{(l-1)} + b_l\big), \quad l = 1, \ldots, L.$$

Строка j матрицы W_l размера $d_l \times d_{l-1}$ – веса w_{ji} нейрона j, $(b_l)_j = w_{j0}$, а h применяется к каждой компоненте: $h(a_1, \ldots, a_d) = \big(h(a_1), \ldots, h(a_d)\big)$. Здесь x без $x_0 = 1$: смещения записаны в b_l. Активация *линейна*, если $h(a) = a$ или, в общем виде, $h(a) = \kappa a + \lambda$.

Произведение матрицы на вектор – линейная комбинация её столбцов $m_1, \ldots, m_q$:

$$Mx = x_1 m_1 + \cdots + x_q m_q, \qquad \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \end{pmatrix} = 5 \begin{pmatrix} 1 \\ 3 \end{pmatrix} + 6 \begin{pmatrix} 2 \\ 4 \end{pmatrix} = \begin{pmatrix} 17 \\ 39 \end{pmatrix}.$$

Размерность преобразования $Mx + c$ – размерность множества значений $\{Mx\}$, сдвиг на c её не меняет. Линейная оболочка d векторов (множество их линейных комбинаций) имеет размерность не больше d.

1.9 Обратное распространение ошибки

Градиентный спуск уменьшает каждый вес на $\eta\, \partial E_n / \partial w_{ji}$, где E_n – ошибка на объекте (x_n, y_n). Обозначим $\delta_j = \partial E_n / \partial a_j$. Вес w_{ji} входит только в a_j, а a_j влияет на ошибку только через суммы a_k нейронов, в которые идёт выход z_j:

$$a_j = w_{j0} + \cdots + w_{ji} z_i + \ldots, \qquad a_k = w_{k0} + \cdots + w_{kj} h(a_j) + \ldots$$

По правилу дифференцирования сложной функции

$$\frac{\partial E_n}{\partial w_{ji}} = \frac{\partial E_n}{\partial a_j} \frac{\partial a_j}{\partial w_{ji}} = \delta_j z_i, \qquad \delta_j = \sum_k \frac{\partial E_n}{\partial a_k} \frac{\partial a_k}{\partial a_j} = h'(a_j) \sum_k w_{kj} \delta_k \tag{6}$$

(для смещения $z_0 = 1$). У выходного нейрона регрессии h нет: выход $f = a$, $E_n = \frac{1}{2}(f - y_n)^2$ и $\delta = f - y_n$. Прямой проход вычисляет все a_j, z_j, обратный – все δ_j, от выходного слоя к входному.

Пример: вход $x = 2$, $y = 1$, скрытый нейрон $a_1 = ux$, $z_1 = \tanh(a_1)$, выход $f = vz_1$, веса $u = 0{,}25$, $v = 1$; производная $\tanh'(a) = 1 - \tanh^2(a)$ найдена в задании 8:

прямой проход:	$a_1 = 0{,}5, \quad z_1 = 0{,}462,$	$f = 0{,}462,$
обратный проход:	$\delta_2 = f - y = -0{,}538,$	$\partial E / \partial v = \delta_2 z_1 = -0{,}249,$
	$\delta_1 = (1 - z_1^2)\, v\, \delta_2 = -0{,}423,$	$\partial E / \partial u = \delta_1 x = -0{,}846.$

1.10 Формула Тейлора

Если третья производная функции f ограничена, то $f(t) = f(0) + f'(0)\,t + \frac{1}{2}f''(0)\,t^2 + O(t^3)$, где $|O(t^3)| \le C\,|t|^3$ с постоянной C.

2 Задания

Задание 1

Дано. Алгоритм обучения перцептрона: векторы признаков обучающей выборки пронумерованы и предъявляются по кругу в порядке нумерации.
Требуется. Выяснить, важен ли порядок, в котором пронумерованы векторы признаков обучающей выборки.

Зачем это нужно. Нумерация при реализации выбирается произвольно, и нужно знать, влияет ли она на сходимость и на найденные веса.

Решение. *Что нужно проверить.* Зависят ли от нумерации граница n_0 числа коррекций из теоремы о сходимости и итоговые веса.

Шаг 1: сходимость от порядка не зависит. Коррекций не больше

$$n_0 = \frac{\beta\,\|\tilde{w}\|^2}{\alpha^2}$$

(в общем случае – задание 3), а α и β – минимум и максимум по множеству $\mathcal{H}$, нумерация их не меняет. После последней коррекции N итераций подряд проходят без коррекций при любом порядке.

Шаг 2: итоговые веса от порядка зависят. Пусть $x = (1, t)$, $\eta = 1$,

$$\mathcal{H}_1 = \{a, b\}, \quad \mathcal{H}_2 = \{c\}, \qquad a = (1, 1), \quad b = (1, 2), \quad c = (1, -2).$$

	порядок a, b, c			порядок b, a, c		
n	$x(n)$	$\langle w(n), x(n)\rangle$	$w(n+1)$	$x(n)$	$\langle w(n), x(n)\rangle$	$w(n+1)$
0	a	0, ошибка	$(1, 1)$	b	0, ошибка	$(1, 2)$
1	b	3	$(1, 1)$	a	3	$(1, 2)$
2	c	-1	$(1, 1)$	c	-3	$(1, 2)$
3	a	2	$(1, 1)$	b	5	$(1, 2)$

В обоих порядках за коррекцией на итерации 0 следуют $N = 3$ итерации без коррекций, но границы классов разные:

$$w = (1, 1): \quad 1 + t = 0, \quad t = -1; \qquad w = (1, 2): \quad 1 + 2t = 0, \quad t = -\tfrac{1}{2}.$$

Ответ. На сходимость порядок не влияет, на найденные веса влияет.

Задание 2

Дано. Алгоритм обучения перцептрона с коэффициентом обучения $\eta > 0$.
Требуется. Показать, что если сходимость алгоритма имеет место при коэффициенте обучения, равном 1, то она имеет место и при меньших значениях η, но потребует большего количества итераций.

Зачем это нужно. Этим обосновывается выбор $\eta = 1$ в доказательстве теоремы.

Решение. *Что нужно проверить.* Запуск с η сводится к запуску с коэффициентом 1, для которого верна теорема о сходимости; останется сравнить число коррекций. Нижний индекс у весов – коэффициент запуска.

Шаг 1: $w(0) = 0$. Докажем по индукции, что $w_\eta(n) = \eta\, w_1(n)$. База: $w_\eta(0) = 0 = \eta\, w_1(0)$. Переход: решение о коррекции принимается по знаку

$$\langle w_\eta(n), x(n)\rangle = \eta\,\langle w_1(n), x(n)\rangle,$$

он в обоих запусках одинаков, поэтому либо оба запуска не меняют веса, либо

$$w_\eta(n+1) = \eta\, w_1(n) \pm \eta\, x(n) = \eta\big(w_1(n) \pm x(n)\big) = \eta\, w_1(n+1).$$

Коррекции идут на одних и тех же итерациях, и запуск с η сходится за то же число итераций, что и запуск с коэффициентом 1.

Шаг 2: $w(0) \neq 0$, *сходимость.* Для $v(n) = w(n)/\eta$

$$v(n+1) = v(n) \pm x(n), \qquad \langle v(n), x(n)\rangle = \frac{\langle w(n), x(n)\rangle}{\eta}\ :$$

это запуск с коэффициентом 1 из точки $v(0) = w(0)/\eta$. Коррекции на $\mathcal{H}_2$ заменой x на $-x$ сводятся к коррекциям на $\mathcal{H}_1$ (задание 3), поэтому считаем, что корректируются элементы $\mathcal{H}_1$. После n коррекций, как в (2) и (3),

$$\langle \tilde w, v\rangle \geq \langle \tilde w, v(0)\rangle + n\alpha, \qquad \|v\|^2 \leq \|v(0)\|^2 + n\beta.$$

При $n \geq -\langle \tilde w, v(0)\rangle/\alpha$ первая правая часть неотрицательна, и по неравенству Коши-Буняковского

$$\big(\langle \tilde w, v(0)\rangle + n\alpha\big)^2 \leq \langle \tilde w, v\rangle^2 \leq \|\tilde w\|^2\, \|v\|^2 \leq \|\tilde w\|^2\, \big(\|v(0)\|^2 + n\beta\big).$$

Слева многочлен от n степени 2 со старшим коэффициентом $\alpha^2 > 0$, справа степени 1. Неравенство верно лишь для конечного числа n: коррекций конечное число.

Шаг 3: $w(0) \neq 0$, *число итераций.* Пусть $\langle w(0), x^*\rangle < 0$ для некоторого $x^* \in \mathcal{H}_1$. Каждая коррекция прибавляет к v вектор $x(k)$ с $\langle x(k), x^*\rangle \leq \|x(k)\|\, \|x^*\| \leq \beta$, поэтому

$$\langle v, x^*\rangle \leq \frac{\langle w(0), x^*\rangle}{\eta} + n\beta.$$

После сходимости x^* классифицируется верно: $\langle v, x^*\rangle > 0$, откуда

$$n > \frac{|\langle w(0), x^*\rangle|}{\eta\beta}.$$

Ответ. Если алгоритм сходится при $\eta = 1$, он сходится при любом $\eta > 0$. При $w(0) = 0$ число итераций от η не зависит. При $w(0) \neq 0$ коррекций больше $|\langle w(0), x^*\rangle|\,/(\eta\beta)$, и эта граница растёт при уменьшении η.

Задание 3

Дано. Теорема о сходимости доказана в предположении, что $x(n) \in \mathcal{H}_1$ и классификация производится неверно на всех итерациях вплоть до $(n+1)$-й.

Требуется. Показать, что при других возможных промежуточных результатах работы алгоритма обучения к $(n+1)$-й итерации (имеются итерации, на которых классификация производится верно; выбираемые в соответствии с нумерацией векторы признаков принадлежат классу $\mathcal{H}_2$) проведённых рассуждений достаточно, чтобы утверждать сходимость алгоритма.

Зачем это нужно. Задание дополняет упрощённое доказательство теоремы до полного.

Решение. *Что нужно проверить.* Оценки (2), (3) и $n \le n_0$ остаются верными, если n – число коррекций, а коррекции бывают и на $\mathcal{H}_2$. Как в теореме, $\eta = 1$ (задание 2).

Шаг 1: коррекция на обоих классах одной формулой. Положим $z = x$ при $x \in \mathcal{H}_1$ и $z = -x$ при $x \in \mathcal{H}_2$:

	ошибка	ошибка через z	коррекция
$x \in \mathcal{H}_1:$	$\langle w, x\rangle \le 0$	$\langle w, z\rangle \le 0$	$w + x = w + z$
$x \in \mathcal{H}_2:$	$\langle w, x\rangle > 0$	$\langle w, z\rangle < 0$	$w - x = w + z$

Каждая коррекция: $w(k+1) = w(k) + z(k)$, $\langle w(k), z(k)\rangle \le 0$.

Шаг 2: $\langle \tilde{w}, z\rangle > 0$ для всех z. На $\mathcal{H}_2$ это строгое неравенство $\langle \tilde{w}, x\rangle < 0$. Уменьшим $\tilde{w}_0$ на $\gamma/2$, где $\gamma = \min_{\mathcal{H}_1}\langle \tilde{w}, x\rangle > 0$. Так как $x_0 = 1$, все $\langle \tilde{w}, x\rangle$ уменьшатся на $\gamma/2$:

$$\langle \tilde{w}, x\rangle \ge \frac{\gamma}{2} \ \ (x \in \mathcal{H}_1), \qquad \langle \tilde{w}, x\rangle \le -\frac{\gamma}{2} \ \ (x \in \mathcal{H}_2), \qquad \alpha = \min_z \langle \tilde{w}, z\rangle \ge \frac{\gamma}{2} > 0.$$

Длины не меняются: $\|z\| = \|x\|$, $\beta = \max_{x\in\mathcal{H}} \|x\|^2$.

Шаг 3: оценки для n коррекций. Итерации с верной классификацией веса не меняют, поэтому после n коррекций на итерациях $k_1, \ldots, k_n$

$$w = z(k_1) + \cdots + z(k_n), \qquad \langle \tilde{w}, w\rangle = \sum_{s=1}^{n} \langle \tilde{w}, z(k_s)\rangle \ge n\alpha, \qquad \|w\|^2 \le n\beta,$$

где вторая оценка – (3) с z вместо x. Как в (4), $n \le n_0 = \beta \|\tilde{w}\|^2 / \alpha^2$.

Шаг 4: сходимость. После последней коррекции веса не меняются, и следующие N итераций предъявляют все элементы без коррекций: все они классифицируются верно. ■

Задание 4

Дано. Обучающая выборка состоит из одного элемента $\{x, +1\}$, то есть $x \in \mathcal{H}_1$. Компоненты начальных весов $w(0)$ независимы и равномерно распределены на $[0, 1]$.
Требуется. Найти, сколько в среднем неверных классификаций подряд может быть произведено при выполнении алгоритма обучения (среднее – математическое ожидание). Выяснить, как оно зависит от $\|x\|$, и показать, что чем меньше коэффициент обучения, тем оно больше.

Зачем это нужно. На простейшем примере видно, как число ошибок при обучении зависит от начальных весов, длины вектора признаков и коэффициента обучения.

Решение. *Что нужно проверить.* Число неверных классификаций K выражается формулой через $w(0)$; $\mathsf{M}K$ находится по линейности математического ожидания.

Шаг 1: формула для K. Элемент один, поэтому на каждой итерации предъявляется x, и коррекции идут подряд, пока классификация неверна. По (1) после k коррекций

$$\langle w(0) + k\eta x, x\rangle = S + k\eta \|x\|^2, \qquad S = \langle w(0), x\rangle,$$

и K – наименьшее целое $k \geq 0$, при котором это число положительно. При $S \leq 0$ нужно $k > y = -S/(\eta \|x\|^2) \geq 0$, а наименьшее целое, большее y, равно $\lfloor y \rfloor + 1$:

$$K = 0 \ \ (S > 0), \qquad K = \left\lfloor \frac{-S}{\eta \|x\|^2} \right\rfloor + 1 \ \ (S \leq 0).$$

Шаг 2: одна компонента. Пусть $x \in \mathbb{R}$, $x \neq 0$, смещения нет, $w(0) = w$ и $S = wx$. При $x > 0$ с вероятностью 1 $w > 0$, $S > 0$ и $K = 0$. При $x < 0$

$$\frac{-S}{\eta x^2} = \frac{w\,|x|}{\eta x^2} = \frac{w}{c}, \qquad c = \eta\,|x|\,, \qquad K = \left\lfloor \frac{w}{c} \right\rfloor + 1.$$

Так как $w \leq 1$, слагаемые $\mathbf{1}\{w \geq jc\}$ с $jc > 1$ равны нулю, и при $q = \lfloor 1/c \rfloor$

$$\mathsf{M}K = 1 + \mathsf{M}\sum_{j=1}^{q} \mathbf{1}\{w \geq jc\} = 1 + \sum_{j=1}^{q} \mathsf{P}(w \geq jc) = 1 + \sum_{j=1}^{q} (1 - jc) = 1 + q - \frac{c\,q(q+1)}{2}.$$

Шаг 3: зависимость от $\|x\|$. Из $y - 1 < \lfloor y \rfloor \leq y$ при $y = w/c$ и $\mathsf{M}w = \frac{1}{2}$

$$\frac{w}{c} < K \leq \frac{w}{c} + 1, \qquad \frac{1}{2\eta\,|x|} \leq \mathsf{M}K \leq \frac{1}{2\eta\,|x|} + 1 :$$

$\mathsf{M}K$ примерно обратно пропорционально $\|x\| = |x|$.

Шаг 4: зависимость от η. При $j \leq q$ слагаемое $1 - jc$ равно $\max(0,\, 1 - jc)$, а при $j > q$ величина $\max(0,\, 1 - jc) = 0$, поэтому

$$\mathsf{M}K = 1 + \sum_{j \geq 1} \max(0,\, 1 - jc).$$

Каждое слагаемое не возрастает с ростом $c = \eta\,|x|$, а слагаемое $1 - c$ при $c < 1$ строго убывает. Значит, чем меньше η, тем больше $\mathsf{M}K$: строго при $\eta\,|x| < 1$, а при $\eta\,|x| \geq 1$ с вероятностью 1 $w < 1 \leq c$ и $K = 1$.

Ответ. При $x > 0$ $\mathsf{M}K = 0$; при $x < 0$ $\mathsf{M}K = 1 + q - c\,q(q+1)/2$, где $c = \eta\,|x|$, $q = \lfloor 1/c \rfloor$, и $\mathsf{M}K \approx 1/(2\eta\,|x|)$. ■

Замечание: общий случай. Пусть $x \in \mathbb{R}^{m+1}$, $x_0 = 1$, $u = x/\|x\|$ и $t = -\langle w(0), u \rangle$. Тогда $-S = \|x\|\, t$, и, как в шагах 1–3, при $c = \eta\,\|x\|$ и $t_+ = \max(t, 0)$

$$K = \mathbf{1}\{t \geq 0\}\Big(\left\lfloor \frac{t}{c} \right\rfloor + 1\Big), \qquad \frac{\mathsf{M}t_+}{c} \leq \mathsf{M}K \leq \frac{\mathsf{M}t_+}{c} + \mathsf{P}(t \geq 0).$$

Распределение t от η и $\|x\|$ не зависит, а K при каждом t не возрастает с ростом c: $\mathsf{M}K$ зависит от η и $\|x\|$ только через $c = \eta\,\|x\|$ и не убывает при уменьшении η. Если все $x_i \geq 0$ (например, яркости пикселей), то $\langle w(0), x \rangle \geq w_0(0) > 0$ с вероятностью 1 и $K = 0$ при любом η.

Задание 5

Дано. Нейронная сеть, в которой функция активации линейна: $h(a) = a$.

Требуется. Показать, что преобразование, задаваемое такой нейронной сетью, будет линейным.

Зачем это нужно. Объясняет, зачем в нейронных сетях нужны нелинейные функции активации.

Решение. *Что нужно проверить.* Выход сети имеет вид $Mx + c$ с не зависящими от x матрицей M и вектором c.

Шаг 1: индукция по слоям. Докажем, что $z^{(l)} = M_l x + c_l$. База: $z^{(0)} = x = Ix + 0$. Переход при $h(a) = a$:

$$z^{(l+1)} = W_{l+1} z^{(l)} + b_{l+1} = W_{l+1}\big(M_l x + c_l\big) + b_{l+1} = \underbrace{W_{l+1} M_l}_{M_{l+1}}\, x + \underbrace{W_{l+1} c_l + b_{l+1}}_{c_{l+1}}.$$

Шаг 2: вывод. Выход сети $z^{(L)} = Mx + c$, где $M = W_L \cdots W_1$: при нулевых смещениях преобразование линейно, в общем случае – линейно со сдвигом (аффинно).

Шаг 3: $h(a) = \kappa a + \lambda$. Для $\mathbf{1} = (1, \ldots, 1)$

$$h(Wz + b) = (\kappa W)z + (\kappa b + \lambda \mathbf{1}) :$$

это слой того же вида с весами κW и смещениями $\kappa b + \lambda \mathbf{1}$, и шаги 1, 2 повторяются. ■

Задание 6

Дано. Сеть с линейными функциями активации, в которой число узлов d некоторого скрытого слоя l меньше числа входов d_0 или числа выходов d_L.

Требуется. Показать, что задаваемое сетью линейное преобразование имеет меньшую размерность, чем размерность входа или выхода.

Зачем это нужно. Узкий скрытый слой используется в автоэнкодерах. Задание показывает, что он ограничивает размерность преобразования при любых весах.

Решение. *Что нужно проверить.* Все значения Mx лежат в линейной оболочке d векторов, а её размерность не больше d.

Шаг 1: разбиение произведения. По заданию 5 сеть задаёт $Mx + c$, и

$$M = W_L \cdots W_1 = UV, \qquad V = W_l \cdots W_1 \;\; (d \times d_0), \qquad U = W_L \cdots W_{l+1} \;\; (d_L \times d).$$

Шаг 2: значения Mx. Пусть $u_1, \ldots, u_d$ – столбцы U. Так как произведение матрицы на вектор – линейная комбинация её столбцов,

$$Mx = U(Vx) = (Vx)_1\, u_1 + \cdots + (Vx)_d\, u_d.$$

Шаг 3: вывод. Все Mx лежат в линейной оболочке $u_1, \ldots, u_d$: размерность преобразования не больше $d < d_0$ (или $d < d_L$). ■

Задание 7

Дано. Нейронная сеть с линейными функциями активации, в которой допустимы дуги, соединяющие узлы из разных слоёв, а не только соседних. Слои пронумерованы от входного (слой 0) до выходного, и каждая дуга ведёт из слоя с меньшим номером в слой с большим.

Требуется. Показать, что для ограниченных входных значений такая сеть эквивалентна многослойному перцептрону с линейными скрытыми узлами, то есть со скрытыми узлами, в которых значения z_j получаются с помощью линейных функций.

Зачем это нужно. Показывает, что соединения через слой, как в остаточных сетях, при линейных активациях не расширяют класс задаваемых преобразований.

Решение. *Что нужно проверить.* Сеть задаёт преобразование $Mx + c$, и такое же преобразование задаёт перцептрон с одним скрытым слоем.

Шаг 1: значение каждого узла – $\langle m, x\rangle + c$. Индукция по номеру слоя. Слой 0: $x_i = \langle e_i, x\rangle + 0$, где e_i – i-й единичный вектор. Переход: дуги в узел j слоя l идут из слоёв $0, \dots, l-1$, где $z_i = \langle m_i, x\rangle + c_i$, поэтому при $h(a) = a$

$$z_j = w_{j0} + \sum_i w_{ji}\big(\langle m_i, x\rangle + c_i\big) = \Big\langle \sum_i w_{ji} m_i,\ x \Big\rangle + \Big(w_{j0} + \sum_i w_{ji} c_i\Big).$$

Значит, выход сети равен $Mx + c$.

Шаг 2: перцептрон с тем же преобразованием. Один скрытый слой из d_0 линейных узлов, $W_1 = I$, $b_1 = 0$, $W_2 = M$, $b_2 = c$:

$$W_2\big(W_1 x + b_1\big) + b_2 = M(Ix + 0) + c = Mx + c. \qquad \blacksquare$$

Замечание об ограниченности входа. Для линейных узлов она не нужна. Она нужна, если линейный узел заменяется сигмоидальным, работающим около нуля. Из $\sigma(-t) = \frac{1}{1+e^t} = 1 - \sigma(t)$ функция $\sigma(t) - \frac{1}{2}$ нечётна, поэтому $\sigma''(0) = 0$; кроме того, $\sigma(0) = \frac{1}{2}$, $\sigma'(0) = \sigma(0)\big(1 - \sigma(0)\big) = \frac{1}{4}$ (задание 8), а σ''' – многочлен от σ и ограничена. По формуле Тейлора

$$\sigma(t) = \frac{1}{2} + \frac{t}{4} + O(t^3), \qquad \frac{4}{\varepsilon}\,\sigma(\varepsilon a) - \frac{2}{\varepsilon} = a + O(\varepsilon^2 a^3).$$

Узел с весом входа ε, весом выхода $4/\varepsilon$ и сдвигом $-2/\varepsilon$ воспроизводит a при $|a| \le R$ с ошибкой $O(\varepsilon^2 R^3)$. При неограниченном a это неверно: значения $\frac{4}{\varepsilon}\sigma(\varepsilon a) - \frac{2}{\varepsilon}$ лежат в $\big(-\frac{2}{\varepsilon}, \frac{2}{\varepsilon}\big)$.

Задание 8

Дано. Логистический сигмоид и гиперболический тангенс

$$\sigma(a) = \frac{1}{1 + e^{-a}}, \qquad \tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}.$$

Требуется. Найти их производные и объяснить, почему такие функции активации удобно использовать при реализации метода обратного распространения ошибки.

Зачем это нужно. Производные функций активации вычисляются на каждом шаге обратного распространения ошибки.

Решение. *Что нужно проверить.* Производная выражается через значение самой функции; тогда множитель $h'(a_j)$ в (6) находится по z_j.

Шаг 1: сигмоид. Так как $\frac{e^{-a}}{1+e^{-a}} = 1 - \frac{1}{1+e^{-a}} = 1 - \sigma(a)$,

$$\sigma'(a) = \frac{e^{-a}}{(1+e^{-a})^2} = \frac{1}{1+e^{-a}} \cdot \frac{e^{-a}}{1+e^{-a}} = \sigma(a)\big(1 - \sigma(a)\big).$$

Шаг 2: тангенс. По формуле производной частного, так как $(e^a - e^{-a})' = e^a + e^{-a}$ и $(e^a + e^{-a})' = e^a - e^{-a}$,

$$\tanh'(a) = \frac{(e^a + e^{-a})^2 - (e^a - e^{-a})^2}{(e^a + e^{-a})^2} = 1 - \tanh^2(a).$$

Шаг 3: обратный проход. Значение $z_j = h(a_j)$ вычислено на прямом проходе, поэтому (6) принимает вид

$$h = \sigma: \quad \delta_j = z_j(1 - z_j) \sum_k w_{kj}\delta_k, \qquad h = \tanh: \quad \delta_j = (1 - z_j^2) \sum_k w_{kj}\delta_k :$$

производная находится умножением, без хранения a_j и без новых вычислений экспоненты.

Ответ. $\sigma' = \sigma(1 - \sigma)$, $\tanh' = 1 - \tanh^2$.