Задача 5. Деревья решений

Нейронные сети и машинное обучение

Задания 1–9

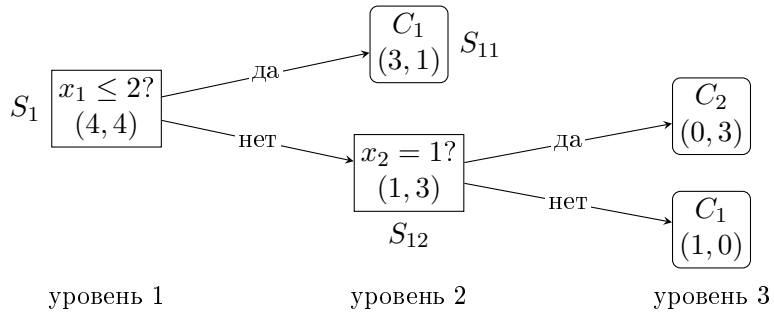
1 Что нужно знать

1.1 Обозначения

$x = (x_1, \ldots, x_d)$	объект: значения его d атрибутов (признаков)
$C_1, \ldots, C_c$	классы ($w_1, \ldots, w_c$ в заданиях 5 и 9), c – их число
k	номер класса (в задании 4 – число значений атрибута)
N	размер обучающей выборки (в задании 5 – n)
h, B	вопрос (классификатор) узла и число его ответов
L	число уровней дерева
S_i, N_i	подвыборка узла i и её размер
S_{ij}, N_{ij}	подвыборка j-го потомка узла i и её размер
$N_i^{(k)}$, $N_{ij}^{(k)}$	число элементов класса C_k в S_i и в S_{ij}
$\mathsf{P}_k = N_i^{(k)}/N_i$	доля класса C_k в S_i
$\mathsf{P}_{jk} = N_{ij}^{(k)}/N_{ij}$	доля класса C_k в S_{ij}
$q_j = N_{ij}/N_i$	доля элементов узла, ушедших в потомка j
H, $\mathcal{I}_2$, $\mathcal{I}_3$	энтропия, Джини, ошибка классификации
$\Delta\mathcal{I}$	уменьшение неоднородности при разбиении узла
log, ln	логарифмы по основанию 2 и e
$\lceil y \rceil$	наименьшее целое, не меньшее y
$O(g)$	величина не больше Cg при некоторой постоянной C
$\neg$, $\wedge$, $\vee$	логические NOT, AND, OR

1.2 Дерево решений

Внутренний узел задаёт вопрос (классификатор) h: функция принимает объект x и возвращает один из B ответов, по ответу объект идёт в потомка. Лист возвращает класс, а дерево T – класс $T(x)$ листа, в который пришёл x. Корень – уровень 1, его потомки – уровень 2 и так далее, L – наибольший уровень. S_i – элементы обучающей выборки, дошедшие до узла i; вопрос делит их на $S_{i1}, \ldots, S_{iB}$. Лист с элементами разных классов возвращает самый частый класс.



В скобках – число элементов C_1 и C_2. Для $x = (3, 1)$: $x_1 \le 2$ – нет, $x_2 = 1$ – да, $T(x) = C_2$. Здесь $L = 3$, $N_1 = 8$, $N_{11} = N_{12} = 4$.

T и T' *функционально эквивалентны*, если $T(x) = T'(x)$ для всех x: например, если в корне спрашивать $x_1 > 2$ и поменять местами рёбра да и нет. Дерево *двоичное*, если у каждого вопроса два ответа, да и нет.

Вопрос от одного атрибута ($x_1 \le 2$, $x_2 = 1$) – *покоординатный*, дерево из таких вопросов – *монотетичное*; вопрос от нескольких атрибутов ($x_1 + x_2 \le 3$) и дерево из таких вопросов – *политетичные*. Для $x = (1, 3)$: $x_1 \le 2$ – да, $x_1 + x_2 \le 3$ – нет.

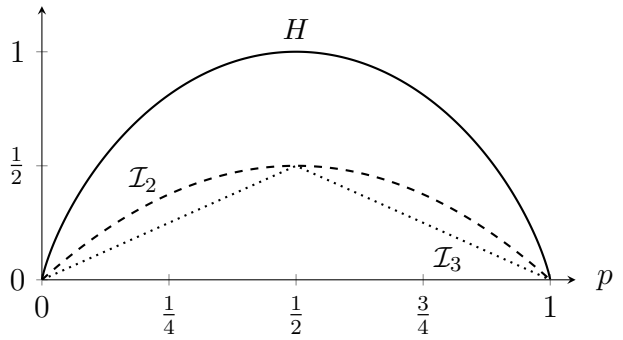
1.3 Меры неоднородности

Мера неоднородности принимает доли классов подвыборки P_1, …, P_c (неотрицательные, в сумме 1) и возвращает число: 0, если все элементы одного класса, и тем больше, чем сильнее классы перемешаны:

$$H = -\sum_{k=1}^{c} \mathsf{P}_k \log \mathsf{P}_k = \sum_{k=1}^{c} \mathsf{P}_k \log \frac{1}{\mathsf{P}_k}, \quad \mathcal{I}_2 = \sum_{k \ne l} \mathsf{P}_k \mathsf{P}_l = 1 - \sum_{k=1}^{c} \mathsf{P}_k^2, \quad \mathcal{I}_3 = 1 - \max_k \mathsf{P}_k,$$

где $0 \log 0 = 0$, а равенство для $\mathcal{I}_2$ следует из $1 = \left(\sum_k \mathsf{P}_k\right)^2 = \sum_k \mathsf{P}_k^2 + \sum_{k \ne l} \mathsf{P}_k \mathsf{P}_l$. H измеряется в битах, $\mathcal{I}_3$ – доля ошибок, если всем элементам приписать самый частый класс, как делает лист. $\mathcal{I}(S_i)$ – мера долей классов в S_i; для двух классов: $H(p, 1-p)$, $\mathcal{I}_2 = 2p(1-p)$, $\mathcal{I}_3 = \min(p, 1-p)$.

доли	H	$\mathcal{I}_2$	$\mathcal{I}_3$
$(1, 0)$	0	0	0
$(\frac{3}{4}, \frac{1}{4})$	0,8113	$\frac{3}{8}$	$\frac{1}{4}$
$(\frac{1}{2}, \frac{1}{2})$	1	$\frac{1}{2}$	$\frac{1}{2}$
$(\frac{1}{2}, \frac{1}{4}, \frac{1}{4})$	$\frac{3}{2}$	$\frac{5}{8}$	$\frac{1}{2}$



Например, $H(\frac{3}{4}, \frac{1}{4}) = \frac{3}{4} \log \frac{4}{3} + \frac{1}{4} \log 4 = 0{,}3113 + 0{,}5 = 0{,}8113$, $\mathcal{I}_2(\frac{3}{4}, \frac{1}{4}) = 1 - \frac{9}{16} - \frac{1}{16} = \frac{3}{8}$, $H(\frac{1}{2}, \frac{1}{4}, \frac{1}{4}) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 = \frac{3}{2}$.

1.4 Разбиение узла

Вопрос узла i делит S_i на $S_{i1}, \ldots, S_{iB}$. *Уменьшение неоднородности* (прирост информации) принимает подвыборку узла и её разбиение и возвращает неоднородность узла минус средневзвешенную неоднородность потомков:

$$\Delta\mathcal{I} = \mathcal{I}(S_i) - \sum_{j=1}^{B} q_j \mathcal{I}(S_{ij}), \qquad q_j = \frac{N_{ij}}{N_i}. \tag{1}$$

В узле выбирают вопрос с наибольшим $\Delta\mathcal{I}$; так как $\mathcal{I}(S_i)$ от вопроса не зависит, это вопрос с наименьшей средневзвешенной неоднородностью потомков. Каждый элемент класса C_k попадает ровно в одного потомка, $N_i^{(k)} = \sum_j N_{ij}^{(k)}$, и после деления на N_i доля класса в узле – средневзвешенная доля в потомках:

$$\mathsf{P}_k = \sum_{j=1}^{B} q_j \mathsf{P}_{jk}. \tag{2}$$

Пример – корень дерева выше: $(4,4)$ делится на $(3,1)$ и $(1,3)$, $q_1 = q_2 = \frac{1}{2}$:

$$\Delta H = 1 - \tfrac{1}{2}\cdot 0{,}8113 - \tfrac{1}{2}\cdot 0{,}8113 = 0{,}1887, \qquad \Delta\mathcal{I}_2 = \tfrac{1}{2} - \tfrac{3}{8} = \tfrac{1}{8}, \qquad \Delta\mathcal{I}_3 = \tfrac{1}{2} - \tfrac{1}{4} = \tfrac{1}{4},$$

а по (2) $\mathsf{P}_1 = \frac{1}{2}\cdot\frac{3}{4} + \frac{1}{2}\cdot\frac{1}{4} = \frac{1}{2}$.

1.5 Оценка энтропии сверху

При $y > 0$ верно $\ln y \le y - 1$: функция $g(y) = y - 1 - \ln y$ имеет производную $1 - \frac{1}{y}$, отрицательную при $y < 1$ и положительную при $y > 1$, поэтому $g(y) \ge g(1) = 0$. Отсюда для долей $q_1, \ldots, q_B$ (неотрицательных, в сумме 1)

$$H(q_1, \ldots, q_B) \le \log B. \tag{3}$$

Действительно, суммируя только по $q_j > 0$ (таких j не больше B), записывая $\log B = \sum_j q_j \log B$ и применяя $\ln y \le y - 1$ при $y = \frac{1}{Bq_j}$ и $\log y = \frac{\ln y}{\ln 2}$:

$$H - \log B = \sum_j q_j \log \frac{1}{Bq_j} \le \frac{1}{\ln 2}\sum_j q_j\Big(\frac{1}{Bq_j} - 1\Big) = \frac{1}{\ln 2}\Big(\sum_j \frac{1}{B} - 1\Big) \le 0.$$

Примеры: $H(q, 1-q) \le \log 2 = 1$; $H(\frac{1}{2}, \frac{1}{4}, \frac{1}{4}) = 1{,}5 \le \log 3 = 1{,}585$; $H(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}) = 2 = \log 4$.

1.6 Сложность вычислений

Сложность алгоритма – число элементарных операций (чтение атрибута, сравнение, сложение) как функция размеров данных с точностью до постоянного множителя. Пример: проход по m элементам с подсчётом классов – m прибавлений к счётчикам, $O(m)$; такой проход для каждого из d атрибутов – $O(dm)$. Сортировка m чисел (слиянием) стоит $O(m \log m)$ сравнений.

1.7 Булева алгебра

Переменные принимают значения 0 и 1; выражение из них с операциями NOT ($\neg$), AND ($\wedge$), OR ($\vee$) возвращает 0 или 1:

x	y	$\neg x$	$x \wedge y$	$x \vee y$	$(x \wedge y) \vee (\neg x \wedge \neg y)$
0	0	1	0	0	1
0	1	1	0	1	0
1	0	0	0	1	0
1	1	0	1	1	1

Последний столбец равен 1 ровно при $x = y$. Правила проверяются подстановкой всех значений:

$$x\wedge(y\vee z) = (x\wedge y)\vee(x\wedge z), \qquad \neg(x\wedge y) = \neg x\vee\neg y, \qquad \neg(x\vee y) = \neg x\wedge\neg y, \qquad \neg\neg x = x,$$

$$x \vee (\neg x \wedge y) = x \vee y \quad (\text{при } x = 1 \text{ обе части равны } 1, \text{ при } x = 0 \text{ обе равны } y).$$

Класс по дереву – OR по листьям класса, лист – AND условий на пути к нему; для дерева выше $C_2 = \neg(x_1 \le 2) \wedge (x_2 = 1)$.

Число операций выражения – число AND и OR. По законам де Моргана отрицания переносятся к переменным без изменения этого числа, после чего каждая операция соединяет два подвыражения в одно: при m вхождениях переменных операций $m-1$ (в последнем столбце таблицы 4 вхождения и 3 операции).

AND и OR не убывают по каждому аргументу. Поэтому если переменная b входит один раз в выражение, где отрицания стоят только у переменных, то с ростом b значение при любых остальных переменных не убывает (вхождение b) или при любых не возрастает (вхождение $\neg b$). Значит, если при одних значениях остальных переменных значение с ростом b падает, а при других растёт, то b входит не меньше двух раз; так у $x = y$ в таблице при $y = 0$ и при $y = 1$.

1.8 Суррогатные расщепления

Пусть основное разбиение узла i идёт по атрибуту x_s, а у объекта x_s не задан. Метод суррогатных (вспомогательных) расщеплений ведёт объект по атрибуту x_r, разбиение по которому чаще всего совпадает с основным:

$$r = \arg\max_{t \neq s} \text{совп}(x_t, x_s),$$

где $\text{совп}(x_t, x_s)$ принимает два атрибута и возвращает долю элементов S_i с заданными x_t и x_s, которые разбиения по x_t и по x_s отправляют в одного потомка. Пример: основное разбиение $x_1 \leq 2$; разбиение $x_2 \leq 5$ совпадает с ним на 90 элементах из 100, $x_3 = 1$ – на 70; суррогат – x_2, и объект без x_1 идёт по ответу на $x_2 \leq 5$.

2 Задания

Задание 1

Дано. Произвольное дерево решений.

Требуется. Доказать, что существует функционально эквивалентное ему дерево решений, в котором последовательность классификаторов (вопросов) на пути от корня к листу содержит только неповторяющиеся классификаторы.

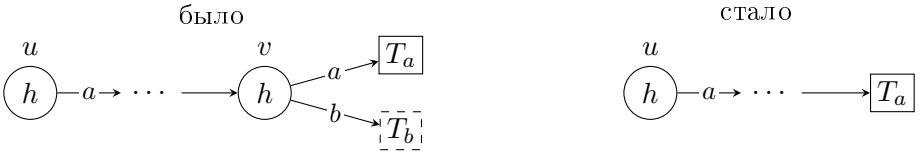
Зачем это нужно. Повторный вопрос на пути не даёт новой информации, такие узлы лишние.

Решение. *Что нужно проверить.* Узел с повторным вопросом удаляется без изменения $T(x)$, а число узлов $|T|$ при этом уменьшается.

Шаг 1: ответ на повторный вопрос известен. Вопрос h задан в узле u и ниже на том же пути в узле v, путь от u к v начинается ребром a. Так как $h(x)$ зависит только от x,

$$x \text{ доходит до } v \text{ только при } h(x) = a,$$

и из v все объекты идут в поддерево T_a, а остальные поддеревья v (на рисунке T_b) недостижимы.



Шаг 2: удаление узла. Поддерево с корнем v заменяем на T_a (рисунок):

$$u, \dots, v, T_a \ \text{ в } T, \quad u, \dots, T_a \ \text{ в } T', \qquad T'(x) = T(x) \ \ \forall x, \qquad |T'| \le |T| - 1.$$

Повторяя замену, не больше чем за $|T|$ шагов уберём все повторы.

Ответ. Эквивалентное дерево без повторов получается удалением узлов с повторными вопросами. ■

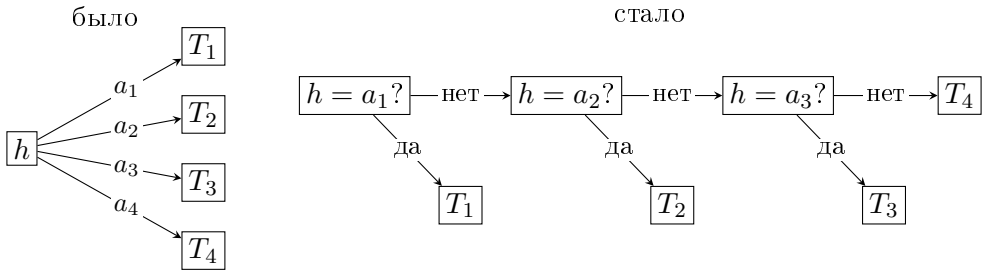
Задание 2

Дано. Произвольное дерево решений.
Требуется. Доказать, что существует эквивалентное ему двоичное дерево решений.

Зачем это нужно. Достаточно изучать двоичные деревья: любое другое заменяется двоичным без изменения ответов.

Решение. *Что нужно проверить.* Узел с $B > 2$ ответами заменяется цепочкой вопросов да/нет, после которой каждый объект попадает в прежнее поддерево.

Шаг 1: цепочка. Узел с вопросом h, ответами $a_1, \dots, a_B$ и поддеревьями $T_1, \dots, T_B$ заменяем узлами $u_1, \dots, u_{B-1}$ с вопросами $h(x) = a_j$ (рисунок для $B = 4$).



Шаг 2: прежнее поддерево. Если $h(x) = a_j$, то $h(x) \neq a_1, \dots, a_{j-1}$:

$h(x)$	ответы $u_1, u_2, \dots$	поддерево
a_1	да	T_1
a_j, $1 < j < B$	нет ($j-1$ раз), да	T_j
a_B	нет ($B-1$ раз)	T_B

Шаг 3: все узлы. Каждая замена убирает один узел с $B > 2$ ответами, а узел с одним ответом заменяется своим поддеревом.

Ответ. Цепочки из $B - 1$ вопросов $h(x) = a_j$ на месте узлов с $B > 2$ ответами дают эквивалентное двоичное дерево. ■

Задание 3

Дано. Дерево с двумя уровнями, в котором корневая вершина смежна с B листьями.
Требуется. Найти нижнюю и верхнюю границы количества уровней в функционально эквивалентном такому дереву двоичном дереве решений как функции от B. Найти количество узлов в таком дереве.

Зачем это нужно. Показывает, сколько уровней и узлов стоит замена одного вопроса с B ответами двоичными вопросами.

Решение. *Что нужно проверить.* Листья взаимно однозначно отвечают B ответам корня (иначе лишние узлы можно добавлять без конца). Узлы считаем по рёбрам, длину пути оцениваем снизу числом листьев, сверху числом внутренних узлов.

Шаг 1: число узлов. У каждого из I внутренних узлов два потомка, каждый узел, кроме корня, – потомок ровно одного узла:

$$2I = \underbrace{(I+B)}_{\text{все узлы}} - \underbrace{1}_{\text{корень}}, \qquad I = B-1, \qquad I+B = 2B-1.$$

Шаг 2: нижняя граница. На L уровнях не больше 2^{L-1} листьев: у корня два поддерева не более чем из $L-1$ уровня, индукция по L. Поэтому

$$B \le 2^{L-1}, \qquad L-1 \ge \log B, \qquad L \ge \lceil \log B \rceil + 1 \ \ (L \text{ целое}).$$

Граница достигается, если вопросы $h(x) \in A$ делят оставшиеся ответы пополам: при $r = \lceil \log B \rceil$ ответов $B \le 2^r$, из $m \le 2^s$ следует $\lceil m/2 \rceil \le 2^{s-1}$, и после r вопросов остаётся один ответ. Пример: $B = 5$, $5 = 3+2$, $3 = 2+1$, $2 = 1+1$, $L = 4$.

Шаг 3: верхняя граница. На пути не больше $I = B-1$ внутренних узлов и лист: $L \le B$. Граница достигается на цепочке из задания 2.

Ответ. $\lceil \log B \rceil + 1 \le L \le B$, узлов $2B-1$.

Задание 4

Дано. Монотетичное и политетичное деревья обучаются на одних и тех же данных: в выборке N элементов, по $N/2$ каждого из двух классов, у элемента d атрибутов, каждый принимает одно из k значений. Предполагается, что наилучшее разбиение делит выборку на две равные части.

Требуется. Сравнить вычислительные сложности классификации с помощью монотетичного и политетичного деревьев:

(а) сколько уровней будет в монотетичном и политетичном деревьях;

(б) какова сложность нахождения оптимального разбиения в корнях таких деревьев;

(в) сравнить общую вычислительную сложность обучения таких деревьев.

Зачем это нужно. Показывает, почему на практике используют монотетичные деревья.

Решение. *Что нужно проверить.* Считаем деревья двоичными, листья – из одного элемента, вопросы – $x_t = v$ и $(x_1, \ldots, x_d) \in A$, где A – множество наборов значений. Сложность – число вопросов (при поиске разбиения – кандидатов), умноженное на стоимость одного.

Шаг 1: (а) уровни. В узле уровня l находится $N/2^{l-1}$ элементов, в листе – один:

$$\frac{N}{2^{L-1}} = 1, \qquad L = \log N + 1 \ \text{ у обоих деревьев.}$$

Шаг 2: классификация. $L - 1 = \log N$ вопросов, монотетичный читает один атрибут, политетичный – d: $O(\log N)$ и $O(d \log N)$.

Шаг 3: (б) корень. Кандидат проверяется проходом по выборке со счётом классов в двух частях. Монотетичных кандидатов dk (атрибут и значение), проверка читает один атрибут элемента. Политетичные кандидаты – подмножества A из $K = k^d$ наборов, кроме пустого и всех, причём A и дополнение дают одно разбиение; проверка читает d атрибутов:

$$dk \cdot O(N) = O(dkN), \qquad \frac{2^K - 2}{2} \cdot O(dN) = O\big(2^{k^d} dN\big).$$

Шаг 4: (в) обучение. На уровне l находится 2^{l-1} узлов по $N/2^{l-1}$ элементов, всего N, а число кандидатов от размера узла не зависит: каждый из $\log N$ уровней стоит как корень,

$$T_{\text{мон}} = O(dkN \log N), \qquad T_{\text{пол}} = O\big(2^{k^d} dN \log N\big), \qquad \frac{T_{\text{пол}}}{T_{\text{мон}}} = O\Big(\frac{2^{k^d}}{k}\Big).$$

Ответ.

	монотетичное	политетичное
(а) уровней	$\log N + 1$	$\log N + 1$
классификация	$O(\log N)$	$O(d \log N)$
(б) разбиение в корне	$O(dkN)$	$O\big(2^{k^d} dN\big)$
(в) обучение	$O(dkN \log N)$	$O\big(2^{k^d} dN \log N\big)$

Задание 5

Дано. Монотетичное дерево решений, при обучении которого используется какая-либо мера неоднородности. Имеется c классов $w_1, \ldots, w_c$, выборка из n элементов размерности d сбалансирована: содержит по n/c элементов каждого класса.

Требуется. Оценить вычислительную сложность обучения:

(а) сколько может быть разбиений в корневой вершине;

(б) какова вычислительная сложность нахождения разбиения, минимизирующего энтропию;

(в) оценить вычислительную сложность разбиения, минимизирующего энтропию, в корневой вершине;

(г) в каждой вершине подвыборка делится на две подвыборки одинакового размера, подвыборка каждого листа состоит из одного элемента; сколько будет уровней в таком дереве;

(д) на 1-м уровне подвыборка корня содержит элементы всех c классов, в узлах, смежных листьям, – двух классов; оценить количество классов для каждого уровня;

(е) оценить вычислительную сложность построения такого дерева решений вплоть до уровня L;

(ж) дана сбалансированная выборка размера $N = 2^{10}$ из 6-мерных векторов признаков, число классов $c = 16$, одна элементарная операция выполняется за 10^{-10} с; сколько времени потребуется для обучения дерева и прогнозирования с его помощью.

Зачем это нужно. Показывает, из чего складывается стоимость обучения дерева решений и сколько стоит прогноз.

Решение. *Что нужно проверить.* Мера – энтропия, вопрос – порог $x_t \leq \theta$. Обучение стоит сумму по узлам стоимости (б), которая зависит от числа элементов n_l и классов c_l в узле уровня l.

Шаг 1: (а) разбиения. Разные разбиения дают только пороги между соседними различными значениями атрибута:

$$\text{разбиений} \leq d(n-1) = O(dn).$$

Шаг 2: (б) узел из m элементов. Сортируем по атрибуту и сдвигаем порог на элемент: меняются два счётчика классов, H частей пересчитывается за $O(c)$:

$$d\Big(\underbrace{O(m\log m)}_{\text{сортировка}}+\underbrace{(m-1)\cdot O(c)}_{\text{положения порога}}\Big)=O\big(dm(\log m+c)\big).$$

Шаг 3: (в) корень. $m=n$: $O\big(dn(\log n+c)\big)$.
Шаг 4: (г) уровни. $n_l=n/2^{l-1}$, в листе один элемент: $n/2^{L-1}=1$, $L=\log n+1$.
Шаг 5: (д) классы. Классов не больше c и не больше элементов:

$$c_l=\min\Big(c,\ \frac{n}{2^{l-1}}\Big),\qquad c_1=c,\qquad c_{L-1}=\min(c,2)=2.$$

Шаг 6: (е) обучение. Уровень l: 2^{l-1} узлов по n_l элементов, по шагу 2

$$2^{l-1}\cdot O\big(dn_l(\log n_l+c_l)\big)=O\big(dn(\log n_l+c_l)\big),\qquad T(L)=O\Big(dn\sum_{l=1}^{L-1}(\log n_l+c_l)\Big).$$

Для полного дерева $L-1=\log n$, $\log n_l\le\log n$, $c_l\le c$: $T=O\big(dn\log n\,(\log n+c)\big)$.
Шаг 7: (ж) время. $n=2^{10}$, $d=6$, $c=16$, $L=11$, в O берём постоянную 1:

l	1	2	3	4	5	6	7	8	9	10	сумма
n_l	1024	512	256	128	64	32	16	8	4	2	
$\log n_l$	10	9	8	7	6	5	4	3	2	1	55
c_l	16	16	16	16	16	16	16	8	4	2	126

$$T\approx 6\cdot 1024\cdot(55+126)\approx 1{,}1\cdot 10^6,\qquad 1{,}1\cdot 10^6\cdot 10^{-10}\text{ с}=1{,}1\cdot 10^{-4}\text{ с}.$$

Прогноз – $L-1=10$ сравнений: $10\cdot 10^{-10}$ с $=10^{-9}$ с на объект.

Ответ. (а) $d(n-1)$; (б) $O\big(dm(\log m+c)\big)$; (в) $O\big(dn(\log n+c)\big)$; (г) $\log n+1$; (д) $\min(c,n/2^{l-1})$; (е) $T(L)$ выше, для полного дерева $O\big(dn\log n\,(\log n+c)\big)$; (ж) $1{,}1\cdot 10^{-4}$ с и 10^{-9} с на объект.

Задание 6

Дано. Разбиение выборки в i-м узле дерева решений:

$$|S_i|=100,\ N_i^{(1)}=90,\ N_i^{(2)}=10;\qquad |S_{i1}|=70,\ N_{i1}^{(1)}=70,\ N_{i1}^{(2)}=0;$$

$$|S_{i2}|=30,\ N_{i2}^{(1)}=20,\ N_{i2}^{(2)}=10.$$

Требуется. Показать, что если нет разбиений, которые давали бы большинство элементов класса C_2 хотя бы в одном из двух потомков, то вероятность ошибки классификации составляет 0,1 для всех возможных разбиений S_i, и поэтому эта мера неоднородности не позволяет выбрать наилучшее разбиение. Выяснить, позволят ли это сделать энтропия и коэффициент Джини.

Зачем это нужно. Объясняет, почему разбиение выбирают по энтропии или коэффициенту Джини, а не по доле ошибок.

Решение. *Что нужно проверить.* При доле C_1 не меньше $\frac{1}{2}$ ошибка $\mathcal{I}_3=1-p$ линейна, поэтому по (2) средняя ошибка потомков равна ошибке узла. H и $\mathcal{I}_2$ помогают, если различают такие разбиения.

Шаг 1: ошибка классификации. Доли потомков q_j, доли C_1 в них по условию $p_j \geq \frac{1}{2}$, по (2) $q_1 p_1 + q_2 p_2 = 0{,}9$:

$$\sum_j q_j \mathcal{I}_3(S_{ij}) = q_1(1-p_1) + q_2(1-p_2) = \underbrace{q_1 + q_2}_{1} - \underbrace{(q_1 p_1 + q_2 p_2)}_{0{,}9} = 0{,}1,$$

и $\Delta\mathcal{I}_3 = 0{,}1 - 0{,}1 = 0$ при любом таком разбиении.

Шаг 2: энтропия и Джини. $H(S_i) = H(\frac{9}{10}, \frac{1}{10}) = 0{,}4690$, $\mathcal{I}_2(S_i) = 2 \cdot 0{,}9 \cdot 0{,}1 = 0{,}18$; у потомков указано число элементов C_1 и C_2:

потомки	$\Delta\mathcal{I}_3$	ΔH	$\Delta\mathcal{I}_2$
$(70, 0)$, $(20, 10)$	0	$0{,}4690 - 0{,}3 \cdot 0{,}9183 = 0{,}1935$	$0{,}18 - 0{,}3 \cdot \frac{4}{9} = 0{,}0467$
$(50, 0)$, $(40, 10)$	0	$0{,}4690 - 0{,}5 \cdot 0{,}7219 = 0{,}1080$	$0{,}18 - 0{,}5 \cdot 0{,}32 = 0{,}02$
$(45, 5)$, $(45, 5)$	0	$0{,}4690 - 0{,}4690 = 0$	$0{,}18 - 0{,}18 = 0$

Здесь $H(\frac{2}{3}, \frac{1}{3}) = 0{,}9183$, $H(\frac{4}{5}, \frac{1}{5}) = 0{,}7219$, $\mathcal{I}_2(\frac{2}{3}, \frac{1}{3}) = \frac{4}{9}$, $\mathcal{I}_2(\frac{4}{5}, \frac{1}{5}) = 0{,}32$.

Ответ. $\Delta\mathcal{I}_3 = 0$ у всех таких разбиений, выбрать по нему нельзя; энтропия и Джини позволяют: у данного разбиения $\Delta H = 0{,}1935$, $\Delta\mathcal{I}_2 = 0{,}0467$, у разбиения $(45, 5)$, $(45, 5)$ нули. ■

Задание 7

Дано. Двоичное дерево решений.

Требуется. (а) Показать, что уменьшение энтропии, которое даёт один да/нет-классификатор, не может быть больше одного бита; обобщить результат на случай произвольного количества потомков узла. (б) Объяснить, почему возможны ситуации, когда неоднородность в узле меньше, чем в его потомке, и привести пример.

Зачем это нужно. Ограничивает пользу одного вопроса и показывает, что критерий следит за средней неоднородностью потомков, а не за каждым из них.

Решение. *Что нужно проверить.* (а) ΔH не больше энтропии долей потомков $H(q_1, q_2)$, а она по (3) не больше 1. (б) Критерий (1) уменьшает среднее $\sum_j q_j \mathcal{I}(S_{ij})$, а не каждое слагаемое.

Обозначим $p_{jk} = N_{ij}^{(k)} / N_i = q_j \mathsf{P}_{jk}$; тогда $\sum_k p_{jk} = q_j$, а по (2) $\sum_j p_{jk} = \mathsf{P}_k$.

Шаг 1: энтропия потомков.

$$\sum_j q_j H(S_{ij}) = -\sum_{j,k} q_j \mathsf{P}_{jk} \log \mathsf{P}_{jk} = -\sum_{j,k} p_{jk} \log \frac{p_{jk}}{q_j} = -\sum_{j,k} p_{jk} \log p_{jk} + \sum_j q_j \log q_j.$$

Шаг 2: первая сумма не меньше $H(S_i)$, так как $p_{jk} \leq \mathsf{P}_k$, а $\log$ возрастает:

$$-\sum_{j,k} p_{jk} \log p_{jk} \geq -\sum_{j,k} p_{jk} \log \mathsf{P}_k = -\sum_k \mathsf{P}_k \log \mathsf{P}_k = H(S_i).$$

Шаг 3: (а) оценка. Подставляем шаги 1, 2 в (1) и применяем (3):

$$\Delta H = H(S_i) - \sum_j q_j H(S_{ij}) \leq -\sum_j q_j \log q_j = H(q_1, q_2) \leq 1.$$

При B потомках суммы идут по $j = 1, \ldots, B$, и $\Delta H \leq H(q_1, \ldots, q_B) \leq \log B$.

Шаг 4: (б) пример. Разбиение из задания 6:

$$H(S_{i2}) = 0{,}9183 > 0{,}4690 = H(S_i), \qquad \sum_j q_j H(S_{ij}) = 0{,}3 \cdot 0{,}9183 = 0{,}2755 < H(S_i).$$

Ответ. (а) $\Delta H \le 1$ бит, при B потомках $\Delta H \le \log B$. (б) $H(S_{i2}) > H(S_i)$ при $\Delta H = 0{,}1935 > 0$: однородный потомок $(70, 0)$ перевешивает. ■

Задание 8

Дано. Метод вспомогательных (суррогатных) расщеплений.

Требуется. Показать, что метод использует предположение, что признак, значение которого не задано для элемента выборки, наиболее информативен.

Зачем это нужно. Уточняет, на каком предположении держится обработка пропущенных значений атрибутов.

Решение. *Что нужно проверить.* Суррогат выбирается по совпадению с разбиением по пропущенному x_s, а не по информативности заданных атрибутов.

Шаг 1: основное разбиение. $\Delta\mathcal{I}(x_t)$ – наибольшее уменьшение (1) при разбиениях по x_t:

$$s = \arg\max_t \Delta\mathcal{I}(x_t), \qquad \Delta\mathcal{I}(x_s) \ge \Delta\mathcal{I}(x_t) \ \ \forall t.$$

Шаг 2: суррогат.

$$r = \arg\max_{t \ne s} \ \text{совп}(x_t, x_s) \quad \text{а не} \quad \arg\max_{t \ne s} \Delta\mathcal{I}(x_t) :$$

объект без x_s идёт туда же, куда по x_s, а не по лучшему из заданных атрибутов.

Шаг 3: вывод. Такой маршрут лучше маршрута по заданным атрибутам, только если $\Delta\mathcal{I}(x_s) \ge \Delta\mathcal{I}(x_t)$ для всех t и на объектах без x_s.

Ответ. Метод копирует разбиение по x_s, то есть считает пропущенный x_s наиболее информативным. ■

Задание 9

Дано. Задача классификации с двумя классами, элементы выборки с двоичными атрибутами a, b, c, d (слева направо):

w_1	w_2
0110	1011
1010	0000
0011	0100
1111	1110

Требуется. (а) Построить дерево решений, используя энтропию в качестве функции неоднородности. (б) С помощью формул булевой алгебры выразить каждый класс простейшим логическим выражением, то есть логическим выражением с наименьшим количеством операций OR и AND.

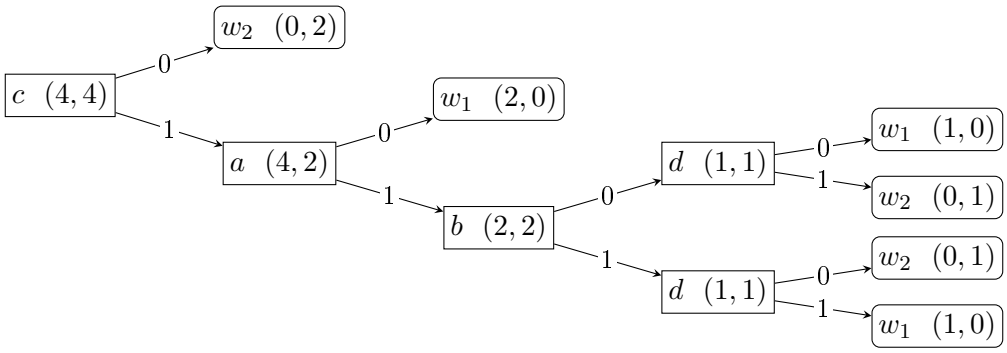
Зачем это нужно. На маленькой выборке дерево строится вручную и переводится в логическую формулу.

Решение. *Что нужно проверить.* (а) В каждом узле берём атрибут с наибольшим ΔH по (1). (б) Выражение по дереву упрощаем правилами булевой алгебры, минимальность проверяем подсчётом вхождений переменных.

Шаг 1: (а) выбор атрибутов. В скобках – число элементов w_1 и w_2 при значении атрибута 0 и 1; $H(\frac{2}{3}, \frac{1}{3}) = 0{,}9183$, $H(\frac{2}{5}, \frac{3}{5}) = 0{,}9710$:

атрибут	$=0$	$=1$	ΔH
корень: $(4,4)$, $H=1$			
a, b	$(2,2)$	$(2,2)$	$1-1=0$
c	$(0,2)$	$(4,2)$	$1-\frac{6}{8}\cdot 0{,}9183=0{,}3113$
d	$(2,3)$	$(2,1)$	$1-\frac{5}{8}\cdot 0{,}9710-\frac{3}{8}\cdot 0{,}9183=0{,}0488$
ветвь $c=1$: $(4,2)$, $H=0{,}9183$			
a	$(2,0)$	$(2,2)$	$0{,}9183-\frac{4}{6}\cdot 1=0{,}2516$
b, d	$(2,1)$	$(2,1)$	$0{,}9183-0{,}9183=0$
ветвь $c=a=1$: $\{1010,1111\}$ из w_1, $\{1011,1110\}$ из w_2, $H=1$			
b, d	$(1,1)$	$(1,1)$	$1-1=0$

В ветви $c=a=1$ класс w_1 ровно при $b=d$: делим по b, затем по d.



Шаг 2: (б) выражения. OR путей к листьям класса, вынесение общего множителя и правило $x\vee(\neg x\wedge y)=x\vee y$ при $x=\neg a$ и $x=\neg c$; здесь $X=(b\wedge d)\vee(\neg b\wedge\neg d)$ – условие $b=d$, $Y=(b\wedge\neg d)\vee(\neg b\wedge d)$ – условие $b\neq d$:

$$w_1=(c\wedge\neg a)\vee(c\wedge a\wedge b\wedge d)\vee(c\wedge a\wedge\neg b\wedge\neg d)=c\wedge\big(\neg a\vee(a\wedge X)\big)=c\wedge(\neg a\vee X),$$
$$w_2=\neg c\vee(c\wedge a\wedge b\wedge\neg d)\vee(c\wedge a\wedge\neg b\wedge d)=\neg c\vee(c\wedge a\wedge Y)=\neg c\vee(a\wedge Y).$$

В каждом выражении 6 вхождений переменных и $3+2=5$ операций AND и OR.

Шаг 3: меньше пяти операций нельзя. Операций на одну меньше, чем вхождений. Выражение для w_1 равно 1 на w_1 и 0 на w_2; если в одной паре оно равно 1 при значении переменной 0, а в другой – при 1, то переменная входит не меньше двух раз. Пары элементов выборки, различающиеся одной переменной:

переменная	пары (w_1 / w_2)	w_1 при значении	вхождений
b	1010 / 1110; 1111 / 1011	$b=0$; $b=1$	≥ 2
d	1010 / 1011; 1111 / 1110	$d=0$; $d=1$	≥ 2
a	0110 / 1110	$a=0$	≥ 1
c	0110 / 0100	$c=1$	≥ 1

Вхождений не меньше $2+2+1+1=6$, операций не меньше 5; для w_2 годятся те же пары.

Ответ. (а) Дерево на рисунке. (б) $w_1=c\wedge\big(\neg a\vee(b\wedge d)\vee(\neg b\wedge\neg d)\big)$, $w_2=\neg c\vee\big(a\wedge((b\wedge\neg d)\vee(\neg b\wedge d))\big)$, по 5 операций, меньше нельзя. ■