Задача 5. Деревья решений

Нейронные сети и машинное обучение

Задания 1–9

1 Что нужно знать

1.1 Обозначения

S_i, $N_i = \lvert S_i \rvert$	подвыборка i-го узла и её размер
S_{ij}, N_{ij}	подвыборка j-го потомка i-го узла и её размер
$N_i^{(k)}$	число элементов класса C_k в S_i
$\mathsf{P}_k = N_i^{(k)}/N_i$	доля класса C_k в S_i
c	число классов
d	число атрибутов (размерность вектора признаков)
k	номер класса; в задании 4 – число значений атрибута
H, $\mathcal{I}_2$, $\mathcal{I}_3$	энтропия, Джини, ошибка классификации
$h(p)$	энтропия двух классов с долями p и $1-p$
$\Delta\mathcal{I}$	уменьшение неоднородности при разбиении узла
log	логарифм по основанию 2, единица энтропии – бит

1.2 Дерево решений

Дерево решений классифицирует объект последовательностью вопросов о его атрибутах. Внутреннему узлу сопоставлен классификатор (вопрос), рёбрам – ответы на него, листьям – классы. Объект спускается от корня к листу и получает класс листа. Корень образует первый уровень, его потомки – второй, и так далее. Узлу i отвечает подвыборка S_i элементов обучающей выборки, дошедших до него; вопрос узла делит её на подвыборки потомков S_{ij}.

Два дерева *функционально эквивалентны*, если на любом объекте дают один и тот же ответ.

Вопросы бывают двух типов:

- *покоординатные*: вопрос об одном атрибуте, $x_i \le \theta$ для порядкового признака или $x_i = v$ для категориального. Дерево из таких вопросов называется *монотетичным*;
- *не покоординатные*: вопрос о нескольких атрибутах сразу, например $\sigma(w^\top x) > 1/2$. Дерево называется *политетичным*.

1.3 Меры неоднородности

$$H(S_i) = -\sum_{k=1}^{c} \mathsf{P}_k \log \mathsf{P}_k, \qquad \mathcal{I}_2(S_i) = 1 - \sum_{k=1}^{c} \mathsf{P}_k^2, \qquad \mathcal{I}_3(S_i) = 1 - \max_k \mathsf{P}_k,$$

где $0 \log 0 = 0$. Все три равны нулю на однородной подвыборке. Вопрос узла выбирают так, чтобы максимизировать уменьшение неоднородности

$$\Delta\mathcal{I} = \mathcal{I}(S_i) - \sum_j \frac{N_{ij}}{N_i} \mathcal{I}(S_{ij}), \tag{1}$$

то есть разность неоднородности узла и средневзвешенной неоднородности потомков.

Два класса. Пусть p – доля первого класса. Тогда

$$H = h(p) = -p\log p - (1-p)\log(1-p), \qquad \mathcal{I}_2 = 2p(1-p), \qquad \mathcal{I}_3 = 1 - \max(p,\, 1-p).$$

Функции $h(p)$ и $2p(1-p)$ строго вогнуты на $[0,1]$: их вторые производные $-\frac{1}{p(1-p)\ln 2}$ и -4 отрицательны. Это значит, что при $0 < q < 1$ и $p_1 \neq p_2$

$$\varphi\big(qp_1 + (1-q)p_2\big) > q\,\varphi(p_1) + (1-q)\,\varphi(p_2), \tag{2}$$

то есть неоднородность смеси двух подвыборок разного состава больше средней неоднородности частей. Обе функции симметричны, $\varphi(p) = \varphi(1-p)$, поэтому $\varphi(1/2) \geq \frac{1}{2}\varphi(p) + \frac{1}{2}\varphi(1-p) = \varphi(p)$: максимум при $p = 1/2$, в частности $h(p) \leq h(1/2) = 1$ бит. Функция $\mathcal{I}_3$ на отрезке $[1/2, 1]$ линейна: $\mathcal{I}_3 = 1 - p$.

1.4 Суррогатные расщепления

Пусть в узле выбрано основное разбиение по атрибуту x_s, а у объекта значение x_s не задано. Метод суррогатных (вспомогательных) расщеплений ищет среди остальных атрибутов тот, разбиение по которому чаще всего совпадает с основным на элементах обучающей выборки, где заданы оба атрибута, и разбивает объект по нему.

2 Задания

Задание 1

Дано. Произвольное дерево решений.
Требуется. Доказать, что существует функционально эквивалентное ему дерево решений, в котором последовательность классификаторов (вопросов) на пути от корня к листу содержит только неповторяющиеся классификаторы.

Зачем это нужно. Повторный вопрос на пути от корня к листу ничего не добавляет, и такие узлы можно удалять, не меняя ответов дерева.

Решение. Пусть на некотором пути классификатор h встречается дважды: в узле u и в лежащем ниже узле v. Все объекты, дошедшие до v, прошли через u по одному и тому же ребру, то есть дали на вопрос h один и тот же ответ a. Ответ h зависит только от объекта, поэтому в v они снова ответят a: из v достижим только потомок, отвечающий ответу a.

Заменим v этим потомком вместе с его поддеревом, а остальные поддеревья v удалим. Маршрут ни одного объекта не изменился, значит дерево эквивалентно прежнему, а число узлов строго уменьшилось. Повторяем замену, пока на путях есть повторы; число узлов конечно, поэтому процесс закончится деревом без повторов. ■

Задание 2

Дано. Произвольное дерево решений.
Требуется. Доказать, что существует эквивалентное ему двоичное дерево решений.

Зачем это нужно. Любое дерево можно заменить двоичным без изменения ответов, поэтому достаточно изучать двоичные деревья.

Решение. Пусть узел u проверяет классификатор h с ответами $a_1, \ldots, a_B$, $B > 2$, и ответу a_j отвечает поддерево T_j. Заменим u цепочкой из $B-1$ двоичных узлов $u_1, \ldots, u_{B-1}$, где узел u_j проверяет, верно ли, что $h(x) = a_j$. При ответе *да* объект идёт в T_j, при ответе *нет* – в u_{j+1}, а из u_{B-1} при ответе *нет* – в T_B. Объект с ответом a_j получит $j-1$ отказов и на j-м вопросе попадёт в то же поддерево T_j, что и раньше, поэтому ответы дерева не меняются. Сделав такую замену во всех узлах с более чем двумя потомками (их конечное число), получаем эквивалентное двоичное дерево. ■

Задание 3

Дано. Дерево с двумя уровнями, в котором корневая вершина смежна с B листьями.
Требуется. Найти нижнюю и верхнюю границы количества уровней в функционально эквивалентном такому дереву двоичном дереве решений как функции от B. Найти количество узлов в таком дереве.

Зачем это нужно. Показывает, сколько уровней и узлов стоит замена одного вопроса с B ответами двоичными вопросами.

Решение. Рассматриваем двоичные деревья без лишних узлов: каждому из B ответов корня отвечает ровно один лист, у каждого внутреннего узла два потомка.

Количество узлов. Дерево из одного узла имеет один лист. Каждый двоичный вопрос заменяет лист внутренним узлом с двумя листьями, то есть добавляет один лист и один внутренний узел. Чтобы получить B листьев, нужно $B-1$ вопросов, поэтому при любой форме дерева

$$B + (B-1) = 2B - 1 \text{ узлов.}$$

Нижняя граница. Двоичное дерево из L уровней имеет не больше 2^{L-1} листьев: у корня два поддерева не более чем из $L-1$ уровней, далее индукция. Из $2^{L-1} \geq B$

$$L_{\min} = \lceil \log_2 B \rceil + 1.$$

Граница достигается, если каждый вопрос вида $h(x) \in A$ делит оставшиеся ответы пополам.

Верхняя граница. Внутренних узлов всего $B-1$, поэтому на пути от корня к листу не больше $B-1$ внутренних узлов и один лист:

$$L_{\max} = B.$$

Граница достигается на цепочке из задания 2. ■

Задание 4

Дано. Монотетичное и политетичное деревья обучаются на одних и тех же данных: в выборке N элементов, по $N/2$ каждого из двух классов, у элемента d атрибутов, каждый принимает одно из k значений. Предполагается, что наилучшее разбиение делит выборку на две равные части.
Требуется. Сравнить вычислительные сложности классификации с помощью монотетичного и политетичного деревьев:

(а) сколько уровней будет в монотетичном и политетичном деревьях;

(б) какова сложность нахождения оптимального разбиения в корнях таких деревьев;

(в) сравнить общую вычислительную сложность обучения таких деревьев.

Зачем это нужно. Показывает, почему на практике используют монотетичные деревья.

Решение. Допущения. Деревья двоичные. Вопрос монотетичного дерева имеет вид $x_i = v$. Вопрос политетичного дерева может опираться на все атрибуты сразу, то есть имеет вид $(x_1, \ldots, x_d) \in A$, где A – множество наборов значений атрибутов. Ветвление продолжается, пока в листе не останется один элемент, как в задании 5 (г).

(а) Уровни. По условию каждое разбиение делит подвыборку пополам, поэтому в узле уровня l находится $N/2^{l-1}$ элементов, и из $N/2^{L-1} = 1$

$$L = \log_2 N + 1$$

у обоих деревьев. Равенство держится только на условии: без него политетичный вопрос мог бы разделить классы уже в корне.

Сложность классификации. Объект проходит путь из $L - 1 = \log_2 N$ вопросов. Монотетичный вопрос читает один атрибут, политетичный – все d:

$$O(\log N) \quad \text{против} \quad O(d \log N).$$

(б) Разбиение в корне. Для каждого кандидата один раз проходим по выборке и считаем элементы каждого класса в двух частях.

Монотетичное дерево: кандидатов dk (атрибут и значение), проверка одного стоит $O(N)$, итого $O(dkN)$.

Политетичное дерево: наборов значений атрибутов k^d, разбиений их множества на две непустые части $2^{k^d-1}-1$, проверка одного кандидата читает d атрибутов каждого элемента и стоит $O(dN)$, итого $O\big(2^{k^d} dN\big)$.

(в) Обучение. На уровне l находится 2^{l-1} узлов по $N/2^{l-1}$ элементов, всего N элементов, а число кандидатов от размера узла не зависит. Поэтому каждый из $\log_2 N$ разбиваемых уровней стоит столько же, сколько корень:

$$T_{\text{мон}} = O(dkN \log N), \qquad T_{\text{пол}} = O\big(2^{k^d} dN \log N\big), \qquad \frac{T_{\text{пол}}}{T_{\text{мон}}} = O\Big(\frac{2^{k^d}}{k}\Big).$$

Отношение растёт дважды экспоненциально по d. ■

Задание 5

Дано. Монотетичное дерево решений, при обучении которого используется какая-либо мера неоднородности. Имеется c классов $w_1, \ldots, w_c$, выборка из n элементов размерности d сбалансирована: содержит по n/c элементов каждого класса.

Требуется. Оценить вычислительную сложность обучения:

(а) сколько может быть разбиений в корневой вершине;

(б) какова вычислительная сложность нахождения разбиения, минимизирующего энтропию;

(в) оценить вычислительную сложность разбиения, минимизирующего энтропию, в корневой вершине;

(г) в каждой вершине подвыборка делится на две подвыборки одинакового размера, подвыборка каждого листа состоит из одного элемента; сколько будет уровней в таком дереве;

(д) на 1-м уровне подвыборка корня содержит элементы всех c классов, в узлах, смежных листьям, – двух классов; оценить количество классов для каждого уровня;

(е) оценить вычислительную сложность построения такого дерева решений вплоть до уровня L;

(ж) дана сбалансированная выборка размера $N = 2^{10}$ из 6-мерных векторов признаков, число классов $c = 16$, одна элементарная операция выполняется за 10^{-10} с; сколько времени потребуется для обучения дерева и прогнозирования с его помощью.

Зачем это нужно. Показывает, из чего складывается стоимость обучения дерева решений и сколько стоит прогноз.

Решение. Из мер неоднородности выбрана энтропия, о ней спрашивают пункты (б) и (в). Вопрос в узле – порог по одному атрибуту, $x_i \le \theta$.

(а) Разные пороги дают разные разбиения, только если порог проходит между соседними различными значениями атрибута; таких промежутков не больше $n-1$. С учётом d атрибутов

$$\text{число разбиений} \le d(n-1) = O(dn).$$

(б) Пусть в узле m элементов. Для одного атрибута сортируем элементы по нему, $O(m \log m)$, и сдвигаем порог слева направо. При переходе элемента через порог меняются два счётчика классов, а энтропии частей пересчитываются за $O(c)$; положений порога $m-1$, проход стоит $O(mc)$. Для всех атрибутов

$$O\big(dm(\log m + c)\big).$$

(в) В корне $m = n$: $O\big(dn(\log n + c)\big)$.

(г) В узле уровня l находится $n_l = n/2^{l-1}$ элементов, в листе один:

$$\frac{n}{2^{L-1}} = 1 \implies L = \log_2 n + 1.$$

(д) В узле уровня l не больше n_l элементов и не больше c классов:

$$c_l = \min\Big(c,\ \frac{n}{2^{l-1}}\Big).$$

Оценка согласована с условием: $c_1 = c$, а в узлах, смежных листьям, $n_{L-1} = 2$ и $c_{L-1} = 2$.

(е) Разбиваются узлы уровней $1, \dots, L-1$, листья не разбиваются. Уровень l содержит 2^{l-1} узлов по n_l элементов и по (б) стоит

$$2^{l-1} \cdot O\big(d\, n_l(\log n_l + c_l)\big) = O\big(dn(\log n_l + c_l)\big).$$

Суммируя,

$$T(L) = O\Big(dn \sum_{l=1}^{L-1} \big(\log n_l + c_l\big)\Big).$$

Для полного дерева $L = \log_2 n + 1$, $\log n_l = \log n - (l-1)$ и

$$\sum_{l=1}^{L-1} \log n_l = \log n + (\log n - 1) + \dots + 1 = \frac{\log n\,(\log n + 1)}{2}.$$

Далее $c_l = c$, пока $n_l \geq c$, то есть на $\log \frac{n}{c} + 1$ уровнях, а затем $c_l = \frac{c}{2}, \frac{c}{4}, \ldots, 2$:

$$\sum_{l=1}^{L-1} c_l = c\Big(\log \frac{n}{c} + 1\Big) + c - 2.$$

Итого

$$T = O\big(dn(\log^2 n + c \log n)\big).$$

(ж) $n = N = 1024$, $d = 6$, $c = 16$, $L = 11$, разбиваются уровни $1, \ldots, 10$ с $n_l = 1024, 512, \ldots, 2$:

$$\sum_{l=1}^{10} \log n_l = 10 + 9 + \cdots + 1 = 55, \qquad \sum_{l=1}^{10} c_l = \underbrace{16 \cdot 7}_{l=1..7} + 8 + 4 + 2 = 126,$$

$$T \approx dn\,(55 + 126) = 6 \cdot 1024 \cdot 181 \approx 1.11 \cdot 10^6 \text{ операций},$$

и время обучения $1.11 \cdot 10^6 \cdot 10^{-10}$ с $\approx 1.1 \cdot 10^{-4}$ с. При прогнозировании объект проходит от корня к листу $L - 1 = 10$ сравнений:

$$10 \cdot 10^{-10} \text{ с} = 10^{-9} \text{ с на объект.} \qquad \blacksquare$$

Задание 6

Дано. Разбиение выборки в i-м узле дерева решений:

$$|S_i| = 100,\ N_i^{(1)} = 90,\ N_i^{(2)} = 10; \qquad |S_{i1}| = 70,\ N_{i1}^{(1)} = 70,\ N_{i1}^{(2)} = 0;$$

$$|S_{i2}| = 30,\ N_{i2}^{(1)} = 20,\ N_{i2}^{(2)} = 10.$$

Требуется. Показать, что если нет разбиений, которые давали бы большинство элементов класса C_2 хотя бы в одном из двух потомков, то вероятность ошибки классификации составляет 0.1 для всех возможных разбиений S_i, и поэтому эта мера неоднородности не позволяет выбрать наилучшее разбиение. Выяснить, позволят ли это сделать энтропия и коэффициент Джини.

Зачем это нужно. Объясняет, почему разбиение выбирают по энтропии или коэффициенту Джини, а не по доле ошибок.

Решение. Пусть разбиение делит S_i на два потомка с долями $q_j = N_{ij}/N_i$, и p_j – доля класса C_1 в j-м потомке. Элементы C_1 узла распределены по потомкам, поэтому

$$q_1 p_1 + q_2 p_2 = 0.9.$$

Ошибка классификации. По условию C_1 составляет большинство в каждом потомке, $p_j \geq 1/2$, и $\mathcal{I}_3(S_{ij}) = 1 - p_j$. Тогда для любого такого разбиения

$$q_1\,\mathcal{I}_3(S_{i1}) + q_2\,\mathcal{I}_3(S_{i2}) = q_1(1 - p_1) + q_2(1 - p_2) = 1 - 0.9 = 0.1,$$

и $\Delta\mathcal{I}_3 = 0.1 - 0.1 = 0$. Для данного разбиения $0.7 \cdot 0 + 0.3 \cdot \frac{1}{3} = 0.1$. Все разбиения получают одну и ту же оценку.

Энтропия и Джини. Для данного разбиения $p_1 = 1$, $p_2 = 2/3$:

$$\Delta H = h(0.9) - 0.3\,h(2/3) = 0.4690 - 0.3 \cdot 0.9183 = 0.1935 \text{ бита},$$

$$\Delta\mathcal{I}_2 = 0.18 - 0.3 \cdot \tfrac{4}{9} = 0.0467.$$

У разбиения на две половины по 45 элементов C_1 и 5 элементов C_2 состав потомков совпадает с составом узла, поэтому $\Delta H = \Delta\mathcal{I}_2 = 0$, а ошибка классификации та же, 0.1. Энтропия и Джини различают эти два разбиения, одинаковые по ошибке классификации, и позволяют выбрать лучшее – данное.

Замечание. В общем случае по (2) при $p_1 \neq p_2$

$$h(q_1 p_1 + q_2 p_2) > q_1 h(p_1) + q_2 h(p_2),$$

то есть $\Delta H > 0$, и так же $\Delta\mathcal{I}_2 > 0$: любое разбиение, меняющее состав потомков, уменьшает энтропию и неоднородность Джини. Для линейной на $[1/2, 1]$ функции $\mathcal{I}_3$ неравенство обращается в равенство. ■

Задание 7

Дано. Двоичное дерево решений.

Требуется. (а) Показать, что уменьшение энтропии, которое даёт один да/нет-классификатор, не может быть больше одного бита; обобщить результат на случай произвольного количества потомков узла. (б) Объяснить, почему возможны ситуации, когда неоднородность в узле меньше, чем в его потомке, и привести пример.

Зачем это нужно. Даёт верхнюю границу того, что может дать один вопрос, и показывает, что уменьшается средняя неоднородность потомков, а не неоднородность каждого из них.

Решение. *(а)* Обозначим через p_{jk} долю элементов S_i, которые попали в потомка j и принадлежат классу C_k. Тогда $q_j = \sum_k p_{jk}$ – доля потомка j, $p_k = \sum_j p_{jk} = \mathsf{P}_k$ – доля класса C_k в узле, а доля класса C_k в потомке j равна p_{jk}/q_j. Средневзвешенная энтропия потомков

$$\sum_j q_j H(S_{ij}) = -\sum_j q_j \sum_k \frac{p_{jk}}{q_j} \log \frac{p_{jk}}{q_j} = -\sum_{j,k} p_{jk} \log p_{jk} + \sum_j q_j \log q_j,$$

так как $\sum_k p_{jk} \log q_j = q_j \log q_j$. Функция $-\log$ убывает, и $p_{jk} \leq p_k$, поэтому

$$-p_{jk} \log p_{jk} \geq -p_{jk} \log p_k, \qquad -\sum_{j,k} p_{jk} \log p_{jk} \geq -\sum_k p_k \log p_k = H(S_i).$$

Подставляя,

$$\Delta H = H(S_i) - \sum_j q_j H(S_{ij}) \leq -\sum_j q_j \log q_j.$$

У да/нет-классификатора два потомка, правая часть равна $h(q_1) \leq 1$ бит. ■

Обобщение на B потомков. Та же выкладка даёт $\Delta H \leq -\sum_{j=1}^{B} q_j \log q_j$, а по неравенству Йенсена для вогнутой функции $\log$

$$\sum_{j=1}^{B} q_j \log \frac{1}{q_j} \leq \log\Big(\sum_{j=1}^{B} q_j \cdot \frac{1}{q_j}\Big) = \log B,$$

то есть $\Delta H \leq \log B$ бит.

(б) Уменьшается средневзвешенная неоднородность потомков (1), а не неоднородность каждого потомка. Один потомок может быть неоднороднее узла, если второй

чище и крупнее. Пример – разбиение из задания 6: $H(S_{i2}) = 0.9183 > 0.4690 = H(S_i)$, при этом $\Delta H = 0.1935 > 0$. ■

Задание 8

Дано. Метод вспомогательных (суррогатных) расщеплений.
Требуется. Показать, что метод использует предположение, что признак, значение которого не задано для элемента выборки, наиболее информативен.

Зачем это нужно. Уточняет, на каком предположении держится обработка пропущенных значений атрибутов.

Решение. Основное разбиение узла выбирается по (1):

$$s = \arg\max_i \Delta\mathcal{I}(x_i),$$

то есть атрибут x_s по построению самый информативный. Если у объекта x_s не задан, суррогат выбирается не по информативности среди заданных атрибутов, а по совпадению с разбиением по x_s:

$$r = \arg\max_{i \neq s} \mathsf{P}\big(\text{разбиения по } x_i \text{ и по } x_s \text{ совпадают}\big).$$

Приближать разбиение по x_s, а не брать лучший из заданных атрибутов, имеет смысл, только если x_s информативнее любого из них. Это и есть предположение, что незаданный признак наиболее информативен. ■

Задание 9

Дано. Задача классификации с двумя классами, элементы выборки с двоичными атрибутами a, b, c, d (слева направо):

w_1	w_2
0110	1011
1010	0000
0011	0100
1111	1110

Требуется. (а) Построить дерево решений, используя энтропию в качестве функции неоднородности. (б) С помощью формул булевой алгебры выразить каждый класс простейшим логическим выражением, то есть логическим выражением с наименьшим количеством операций OR и AND.

Зачем это нужно. На маленькой выборке дерево строится вручную и переводится в логическую формулу.

Решение. *(а)* В корне по 4 элемента каждого класса, $H = 1$ бит. Приросты информации по атрибутам (в скобках число элементов w_1 и w_2 в частях):

- a: при $a = 0$ и при $a = 1$ части $(2, 2)$, $\Delta H = 0$; так же для b;
- c: $c = 0$ даёт $(0, 2)$, $c = 1$ даёт $(4, 2)$, $\Delta H = 1 - \frac{6}{8}\, h(\frac{2}{3}) = 1 - 0.6887 = 0.3113$;
- d: $d = 0$ даёт $(2, 3)$, $d = 1$ даёт $(2, 1)$, $\Delta H = 1 - \frac{5}{8}\, h(\frac{2}{5}) - \frac{3}{8}\, h(\frac{2}{3}) = 1 - 0.9512 = 0.0488$.

Корень – c. Ветвь $c = 0$: $\{0000, 0100\}$, лист w_2.

Ветвь $c = 1$: $\{0110, 1010, 0011, 1111\}$ из w_1 и $\{1011, 1110\}$ из w_2, $H = h(\frac{2}{3}) = 0.9183$. Атрибут a даёт части $(2, 0)$ и $(2, 2)$, $\Delta H = 0.9183 - \frac{4}{6} \cdot 1 = 0.2516$; атрибуты b и d дают части $(2, 1)$ и $(2, 1)$, $\Delta H = 0$. Выбираем a. Ветвь $a = 0$: лист w_1.

Ветвь $c = 1$, $a = 1$: $\{1010, 1111\}$ из w_1 и $\{1011, 1110\}$ из w_2. Атрибуты b и d по отдельности дают части $(1, 1)$, а класс w_1 ровно тогда, когда $b = d$. Разбиваем по b, затем по d.

Путь	Класс
$c = 0$	w_2
$c = 1$, $a = 0$	w_1
$c = 1$, $a = 1$, $b = 0$, $d = 0$	w_1
$c = 1$, $a = 1$, $b = 0$, $d = 1$	w_2
$c = 1$, $a = 1$, $b = 1$, $d = 0$	w_2
$c = 1$, $a = 1$, $b = 1$, $d = 1$	w_1

(б) По дереву w_1, если $c = 1$ и либо $a = 0$, либо $b = d$. Записывая $b = d$ как $(b \wedge d) \vee (\neg b \wedge \neg d)$,

$$w_1 = c \wedge \big(\neg a \vee (b \wedge d) \vee (\neg b \wedge \neg d)\big),$$

три операции AND и две OR. Для w_2 берём отрицание и применяем правила де Моргана:

$$w_2 = \neg c \vee \Big(a \wedge \big((b \wedge \neg d) \vee (\neg b \wedge d)\big)\Big),$$

тоже три AND и две OR. ■