

## Задача 5. Деревья решений

Нейронные сети и машинное обучение

Задания 1–9

### 1 Что нужно знать

#### 1.1 Обозначения

|                       |                                                  |
|-----------------------|--------------------------------------------------|
| $S, S_i$              | выборка и подвыборка $i$ -го узла                |
| $N, N_i$              | их размеры                                       |
| $c$ (или $K$ )        | число классов                                    |
| $d$                   | число атрибутов (размерность вектора признаков)  |
| $P_k = N_i^{(k)}/N_i$ | доля элементов $k$ -го класса в подвыборке       |
| $\mathcal{I}(S)$      | мера неоднородности выборки                      |
| $H(S)$                | энтропия                                         |
| $\Delta\mathcal{I}$   | уменьшение неоднородности при разбиении          |
| $\log$                | логарифм по основанию 2, единица измерения – бит |

#### 1.2 Дерево решений

Дерево решений классифицирует объект последовательностью вопросов. Каждому внутреннему узлу сопоставлен классификатор (вопрос об атрибутах объекта), рёбрам – возможные ответы, листьям – метки классов. Объект спускается от корня к листу, и метка листа объявляется ответом.

Узлу  $i$  отвечает подвыборка  $S_i$  – множество элементов обучающей выборки, попадающих в этот узел. Разбиение узла делит  $S_i$  на непересекающиеся подвыборки  $S_{ij}$  по числу ответов на вопрос.

Классификаторы в узлах бывают двух типов:

- *покоординатные*, проверяющие один атрибут (например  $x_i \leq \theta$ ). Дерево из таких узлов называется *монотетичным*;
- *не покоординатные*, использующие сразу несколько атрибутов (например  $w^\top x > \theta$ ). Дерево называется *политетичным*.

#### 1.3 Меры неоднородности

Разбиение выбирают так, чтобы подвыборки становились однороднее, то есть содержали преимущественно элементы одного класса. Однородность измеряют одной из функций неоднородности:

$$\text{энтропия} \quad H(S_i) = - \sum_{k=1}^c P_k \log P_k, \quad \text{Джини} \quad \mathcal{I}_2(S_i) = 1 - \sum_{k=1}^c P_k^2,$$

$$\text{ошибка классификации} \quad \mathcal{I}_3(S_i) = 1 - \max_k P_k.$$

Здесь  $0 \log 0 = 0$ . Все три обращаются в нуль на однородной выборке и максимальны при равных долях классов.

Качество разбиения оценивают уменьшением неоднородности:

$$\Delta \mathcal{I} = \mathcal{I}(S_i) - \sum_j \frac{N_{ij}}{N_i} \mathcal{I}(S_{ij}) \longrightarrow \max. \quad (1)$$

Вычитается средневзвешенная неоднородность потомков, веса – доли попавших в них элементов.

## 1.4 Энтропия как мера информации

Для задания 7 понадобится вероятностная запись. Пусть  $Y$  – случайная метка класса элемента, выбранного из  $S_i$  равномерно, а  $Z$  – ответ проверяемого в узле вопроса для этого элемента. Тогда  $H(S_i) = H(Y)$ , а средневзвешенная энтропия потомков есть в точности условная энтропия:

$$\sum_j \frac{N_{ij}}{N_i} H(S_{ij}) = \sum_j P(Z = j) H(Y | Z = j) = H(Y | Z).$$

Поэтому (1) для энтропии – это взаимная информация

$$\Delta H = H(Y) - H(Y | Z) = I(Y; Z), \quad (2)$$

для которой известны свойства

$$I(Y; Z) = I(Z; Y) \leq H(Z), \quad H(Z) \leq \log(\text{число значений } Z).$$

## 1.5 Суррогатные расщепления

Метод, о котором идёт речь в задании 8.

Пусть в узле выбрано основное разбиение по атрибуту  $x_s$  (то, что даёт максимум (1)), но у некоторого объекта значение  $x_s$  не задано. Тогда поступают так: среди остальных атрибутов ищут тот, разбиение по которому максимально совпадает с основным на элементах обучающей выборки, у которых задано и то и другое. Такое разбиение называют *суррогатным* и применяют к объекту вместо основного. Строится обычно несколько суррогатов, упорядоченных по степени совпадения с основным.

# 2 Задания

### Задание 1

**Дано.** Произвольное дерево решений.

**Требуется.** Доказать, что существует функционально эквивалентное ему дерево решений, в котором последовательность классификаторов на пути от корня к листу содержит только неповторяющиеся классификаторы.

*Зачем это нужно.* Показывает, что повторный вопрос на пути от корня к листу лишний, и такие узлы можно удалять, не меняя ответов дерева.

**Решение.** Функциональная эквивалентность означает, что деревья дают одинаковые ответы на всех возможных объектах.

Пусть на некотором пути от корня к листу один и тот же классификатор  $h$  встречается дважды: в узле  $u$  и в лежащем ниже узле  $v$ . Все объекты, доходящие до  $v$ , прошли через  $u$  и свернули в конкретного потомка, то есть все они дали на вопрос  $h$  один и тот же ответ  $a$ . Классификатор  $h$  детерминирован и зависит только от объекта, поэтому в узле  $v$  те же объекты дадут тот же ответ  $a$ . Значит из  $v$  достигим ровно один потомок – тот, что отвечает ответу  $a$ ; в остальные не попадает ни один объект.

Заменяем узел  $v$  на этого единственного достижимого потомка вместе с его поддеревом, а остальные поддеревья удалим. Ни один объект при этом не изменит своего маршрута, значит функция, вычисляемая деревом, не изменилась. При этом число узлов строго уменьшилось.

Повторяем операцию, пока на путях остаются повторы. Так как число узлов конечно и на каждом шаге строго убывает, процесс закончится. Полученное дерево эквивалентно исходному, и ни на одном пути от корня к листу классификатор не повторяется. ■

## Задание 2

**Дано.** Произвольное дерево решений, в узлах которого возможны классификаторы с любым конечным числом ответов.

**Требуется.** Доказать, что существует эквивалентное ему двоичное дерево решений. *Зачем это нужно.* Позволяет рассматривать только двоичные деревья: любое дерево приводится к двоичному без изменения ответов.

**Решение.** Достаточно показать, как заменить один узел с  $B > 2$  потомками, а затем применить замену ко всем таким узлам.

Пусть узел  $u$  проверяет классификатор  $h$  с возможными ответами  $a_1, \dots, a_B$ , и потомок  $T_j$  отвечает ответу  $a_j$ . Заменяем  $u$  цепочкой из  $B - 1$  двоичных узлов  $u_1, \dots, u_{B-1}$ , где узел  $u_j$  проверяет вопрос

$$h_j(x) = [h(x) = a_j],$$

то есть «верно ли, что ответ равен  $a_j$ ». Это допустимый классификатор: он вычислим по объекту и имеет два ответа. При ответе «да» переходим в поддерево  $T_j$ , при ответе «нет» – в узел  $u_{j+1}$ . Последний узел  $u_{B-1}$  при ответе «нет» ведёт в  $T_B$ , так как остальные варианты уже исключены.

Объект, дававший в исходном дереве ответ  $a_j$ , пройдёт по цепочке  $j - 1$  отказов и на  $j$ -м вопросе свернёт в  $T_j$  – то же самое поддерево, что и раньше. Значит функция не изменилась.

Применяя замену ко всем узлам с более чем двумя потомками (их конечное число), получаем двоичное дерево, эквивалентное исходному. ■

## Задание 3

**Дано.** Дерево с двумя уровнями: корневая вершина смежна с  $B$  листьями.

**Требуется.** Найти нижнюю и верхнюю границы количества уровней в функционально эквивалентном двоичном дереве как функции от  $B$ , а также количество узлов в таком дереве.

*Зачем это нужно.* Показывает, во что обходится замена вопроса с многими ответами двоичными вопросами: по глубине дерева и по числу узлов.

**Решение.** Эквивалентное двоичное дерево должно различать те же  $B$  исходов. Рассматриваем деревья без лишних узлов: листьев ровно  $B$ , по одному на исход, и у

каждого внутреннего узла два потомка (узел с одним потомком можно убрать, не меняя ответов).

*Количество узлов.* В каждый узел, кроме корня, входит ровно одно ребро, а из каждого внутреннего узла выходят два. Считая рёбра двумя способами,

$$2 \cdot \#внутр = \#всего - 1 = \#внутр + B - 1,$$

откуда

$$\#листьев = B, \quad \#внутренних = B - 1, \quad \#всего = 2B - 1.$$

Это количество не зависит от формы дерева.

*Нижняя граница.* Двоичное дерево глубины  $D$  (то есть с  $D$  уровнями внутренних узлов) имеет не более  $2^D$  листьев. Из  $2^D \geq B$  получаем  $D \geq \lceil \log_2 B \rceil$ . Всего уровней, считая уровень листьев,

$$L_{\min} = \lceil \log_2 B \rceil + 1.$$

Граница достигается на сбалансированном дереве, в котором каждый вопрос вида «ответ входит в множество  $A$ ?» делит оставшиеся варианты пополам.

*Верхняя граница.* На пути от корня к листу все внутренние узлы различны, а их всего  $B - 1$ . Поэтому глубина не больше  $B - 1$ , и

$$L_{\max} = B.$$

Граница достигается на цепочке из задания 2, где  $B - 1$  вопросов «ответ равен  $a_j$ ?» идут подряд. ■

#### Задание 4

**Дано.** Выборка из  $N$  элементов, по  $N/2$  каждого из двух классов. Элемент имеет  $d$  атрибутов, каждый принимает одно из  $k$  значений. Наилучшее разбиение делит выборку на две равные части. Сравниваются монотетичное дерево (вопрос по одному атрибуту) и политетичное (вопрос по совокупности атрибутов).

**Требуется.** (а) Сколько уровней будет в каждом дереве? (б) Какова сложность нахождения оптимального разбиения в корне? (в) Сравнить общую вычислительную сложность обучения.

*Зачем это нужно.* Объясняет, почему на практике используют монотетичные деревья.

**Решение.**

(а) *Уровни.* По условию каждое разбиение делит подвыборку пополам, причём одинаково для обоих типов деревьев. Размер подвыборки на уровне  $l$  равен  $N/2^{l-1}$ , ветвление прекращается при размере 1, откуда

$$\frac{N}{2^{L-1}} = 1 \implies L = \log_2 N + 1.$$

Число уровней одинаково у обоих деревьев: предположение о делении пополам уравнивает их по глубине. Поэтому классификация объекта в обоих деревьях требует  $\log_2 N$  вопросов, но вопрос монотетичного дерева читает один атрибут, а политетичного все  $d$ . Основная разница окажется в стоимости выбора разбиения.

(б) *Сложность выбора разбиения в корне.* Оценим число кандидатов и цену проверки одного кандидата. Проверка любого разбиения требует один раз пройти по выборке и посчитать классовые частоты в частях, то есть  $O(N)$  операций.

Монотетичное дерево. Вопрос задаётся выбором атрибута ( $d$  вариантов) и разбиением множества его  $k$  значений на две группы ( $2^{k-1} - 1$  вариантов). Кандидатов

$$d(2^{k-1} - 1),$$

и полная стоимость перебора в корне  $O(d2^k N)$ . Если ограничиться вопросами вида «атрибут равен  $v$ », кандидатов всего  $dk$ , а стоимость  $O(dkN)$ .

Политетичное дерево. Вопрос может опираться на все атрибуты сразу, то есть разбивает множество всех возможных комбинаций значений, которых  $k^d$ . Число разбиений этого множества на две группы равно

$$2^{k^d-1} - 1,$$

и полная стоимость перебора  $O(2^{k^d} N)$ .

(в) *Общая сложность обучения.* На уровне  $l$  находится  $2^{l-1}$  узлов, в каждом по  $N/2^{l-1}$  элементов, суммарно на уровень приходится  $N$  элементов. Значит стоимость одного уровня равна стоимости обработки  $N$  элементов при том же числе кандидатов, а всего уровней  $\log_2 N + 1$ :

$$T_{\text{мон}} = O(d2^k N \log N), \quad T_{\text{пол}} = O(2^{k^d} N \log N).$$

Отношение

$$\frac{T_{\text{пол}}}{T_{\text{мон}}} = O\left(\frac{2^{k^d}}{d2^k}\right)$$

растёт дважды экспоненциально по  $d$ . Уже при  $k = 2$  и  $d = 6$  множитель  $2^{k^d}$  равен  $2^{64}$ , а  $d2^k = 24$ . Именно поэтому на практике полный перебор политетичных разбиений не используется: вместо него в узле обучают параметрический классификатор (логистическую регрессию), сводя перебор к оптимизации. ■

## Задание 5

**Дано.** Монотетичное дерево решений, обучаемое с использованием энтропии. с классов, сбалансированная выборка из  $n$  элементов ( $n/c$  на класс), элементы  $d$ -мерные.

**Требуется.** Оценить вычислительную сложность обучения по пунктам: (а) число разбиений в корне; (б) сложность нахождения разбиения, минимизирующего энтропию; (в) сложность этого разбиения в корне; (г) число уровней при делении подвыборок пополам до листьев из одного элемента; (д) число классов на каждом уровне; (е) сложность построения дерева до  $L$ -го уровня; (ж) время обучения и прогнозирования при  $n = 2^{10}$ ,  $d = 6$ ,  $c = 16$  и  $10^{-10}$  с на операцию.

*Зачем это нужно.* Показывает, из чего складывается стоимость обучения дерева и насколько она больше стоимости прогноза.

**Решение.**

(а) *Число разбиений в корне.* Покоординатный вопрос имеет вид  $x_i \leq \theta$ . Различные  $\theta$  дают различные разбиения только когда порог проходит между соседними значениями  $i$ -й координаты, а таких промежутков не больше  $n - 1$ . Умножая на число атрибутов,

$$\#\text{разбиений} \leq d(n - 1) = O(dn).$$

(б) *Сложность выбора наилучшего разбиения.* Пусть в узле  $m$  элементов. Разберём один атрибут. Отсортируем по нему элементы:  $O(m \log m)$ . Далее ведём порог

слева направо. При переносе одного элемента через порог меняются два классовых счётчика, а пересчёт энтропий обеих частей стоит  $O(c)$ . Всего  $m - 1$  положений порога, поэтому проход стоит  $O(mc)$ . Для одного атрибута  $O(m \log m + mc)$ , для всех

$$O(dm(\log m + c)).$$

Наивная реализация, пересчитывающая частоты заново для каждого порога, стоила бы  $O(dm(m + c))$ ; выигрыш даёт именно пересчёт счётчиков при сдвиге порога.

(в) *В корне.* Подставляем  $m = n$ : сложность равна  $O(dn(\log n + c))$ .

(г) *Число уровней.* Размер подвыборки на уровне  $l$  равен  $n/2^{l-1}$ , лист достигается при размере 1:

$$\frac{n}{2^{L-1}} = 1 \implies L = \log_2 n + 1.$$

(д) *Число классов на уровне.* В узле уровня  $l$  содержится  $n_l = n/2^{l-1}$  элементов, значит различных классов там не больше  $n_l$ ; с другой стороны их не больше  $c$ . Отсюда оценка

$$c_l = \min\left(c, \frac{n}{2^{l-1}}\right).$$

Проверим по условию: на первом уровне  $c_1 = \min(c, n) = c$  — все классы; в узлах, смежных листьям, подвыборка состоит из двух элементов, и  $c_l = \min(c, 2) = 2$  — два класса. Пока  $n_l > c$ , число классов остаётся равным  $c$ , а затем убывает вдвое на каждом уровне.

(е) *Сложность до  $L$ -го уровня.* На уровне  $l$  находится  $2^{l-1}$  узлов, в каждом  $n_l = n/2^{l-1}$  элементов. Стоимость уровня

$$2^{l-1} \cdot O(d n_l (\log n_l + c_l)) = O(d n (\log n_l + c_l)),$$

то есть множитель  $2^{l-1}$  сокращается с размером подвыборки: на каждом уровне обрабатывается вся выборка целиком. Суммируя по уровням,

$$T(L) = O\left(d n \sum_{l=1}^L (\log n_l + c_l)\right), \quad \sum_{l=1}^L \log n_l = \sum_{l=1}^L (\log n - (l-1)) = L \log n - \frac{L(L-1)}{2}.$$

Для полного дерева ( $L = \log_2 n + 1$ ) первая сумма равна  $\frac{1}{2} \log_2 n (\log_2 n + 1)$ , а вторая приближённо  $c \log_2(n/c) + 2c$ . Итого

$$T = O\left(d n (\log^2 n + c \log n)\right).$$

(ж) *Числовая оценка.* При  $n = 2^{10} = 1024$ ,  $d = 6$ ,  $c = 16$  имеем  $\log_2 n = 10$  и  $L = 11$  уровней. Считаем обе суммы точно:

$$\sum_{l=1}^{11} \log n_l = 10 + 9 + \dots + 1 + 0 = 55,$$

$$\sum_{l=1}^{11} c_l = \underbrace{16 + 16 + 16 + 16 + 16 + 16 + 16}_{l=1..7} + 8 + 4 + 2 + 1 = 112 + 15 = 127.$$

Число операций

$$T \approx d n (55 + 127) = 6 \cdot 1024 \cdot 182 \approx 1.12 \cdot 10^6,$$

и время обучения

$$1.12 \cdot 10^6 \cdot 10^{-10} \text{ с} \approx 1.1 \cdot 10^{-4} \text{ с.}$$

Прогнозирование устроено гораздо дешевле. Объект спускается от корня к листу, на каждом уровне выполняется одно сравнение, глубина равна  $L - 1 = 10$ :

$$10 \cdot 10^{-10} \text{ с} = 10^{-9} \text{ с на объект,}$$

для всей выборки из 1024 объектов около  $10^{-6}$  с. Обучение дороже прогнозирования примерно в сто раз, и эта асимметрия – общее свойство деревьев решений. ■

### Задание 6

**Дано.** Разбиение выборки в  $i$ -м узле:

$$|S_i| = 100, N_i^{(1)} = 90, N_i^{(2)} = 10; \quad |S_{i1}| = 70, N_{i1}^{(1)} = 70, N_{i1}^{(2)} = 0;$$

$$|S_{i2}| = 30, N_{i2}^{(1)} = 20, N_{i2}^{(2)} = 10.$$

**Требуется.** Показать, что если нет разбиений, дающих большинство элементов класса  $C_2$  хотя бы в одном потомке, то неоднородность ошибки классификации равна 0.1 для всех возможных разбиений  $S_i$ , и потому не позволяет выбрать наилучшее. Выяснить, позволяют ли это энтропия и коэффициент Джини.

*Зачем это нужно.* Объясняет, почему для выбора разбиения используют энтропию или коэффициент Джини, а не долю ошибок.

### Решение.

*Ошибка классификации.* Мера  $\mathcal{I}_3 = 1 - \max_k P_k$  – это доля элементов, которые будут отнесены неверно, если весь узел пометить его преобладающим классом. Если класс  $C_1$  преобладает в обоих потомках, то неверно классифицированными в каждом потомке оказываются ровно все элементы  $C_2$ , попавшие туда. Значит абсолютное число ошибок равно общему числу элементов  $C_2$  в узле, то есть 10, независимо от разбиения. Отсюда средневзвешенная неоднородность

$$\sum_j \frac{N_{ij}}{N_i} \mathcal{I}_3(S_{ij}) = \frac{\text{число ошибок}}{N_i} = \frac{10}{100} = 0.1$$

для любого такого разбиения. Неоднородность самого узла тоже  $\mathcal{I}_3(S_i) = 1 - 0.9 = 0.1$ , поэтому

$$\Delta \mathcal{I}_3 = 0.1 - 0.1 = 0$$

всегда. Все разбиения выглядят одинаково хорошими, выбрать среди них по этому критерию нельзя. Проверим на данных задачи:  $\mathcal{I}_3(S_{i1}) = 1 - 70/70 = 0$ ,  $\mathcal{I}_3(S_{i2}) = 1 - 20/30 = 1/3$ , и  $0.7 \cdot 0 + 0.3 \cdot \frac{1}{3} = 0.1$ .

*Энтропия.* Считаем в битах.

$$H(S_i) = -0.9 \log 0.9 - 0.1 \log 0.1 = 0.1368 + 0.3322 = 0.4690.$$

Потомки:  $S_{i1}$  однороден,  $H = 0$ . Для  $S_{i2}$  доли  $2/3$  и  $1/3$ :

$$H(S_{i2}) = -\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3} = 0.3900 + 0.5283 = 0.9183.$$

Средневзвешенная:  $0.7 \cdot 0 + 0.3 \cdot 0.9183 = 0.2755$ , откуда

$$\Delta H = 0.4690 - 0.2755 = 0.1935 \text{ бита} > 0.$$

*Джини.*

$$\mathcal{I}_2(S_i) = 1 - (0.9^2 + 0.1^2) = 0.18, \quad \mathcal{I}_2(S_{i1}) = 0, \quad \mathcal{I}_2(S_{i2}) = 1 - \left(\frac{4}{9} + \frac{1}{9}\right) = \frac{4}{9} = 0.4444.$$

Средневзвешенная:  $0.7 \cdot 0 + 0.3 \cdot 0.4444 = 0.1333$ , откуда

$$\Delta \mathcal{I}_2 = 0.18 - 0.1333 = 0.0467 > 0.$$

Обе меры дают строго положительный прирост и, в отличие от ошибки классификации, различают разбиения. Причина в том, что  $\mathcal{I}_3$  кусочно линейна по  $P_k$  и зависит только от преобладающего класса, тогда как энтропия и Джини строго вогнуты и реагируют на любое изменение долей, в том числе на появление полностью чистого потомка  $S_{i1}$ . ■

### Задание 7

**Дано.** Двоичное дерево решений, мера неоднородности – энтропия.

**Требуется.** (а) Показать, что уменьшение энтропии, которое даёт один да/нет классификатор, не больше одного бита; обобщить на произвольное число потомков. (б) Объяснить, почему возможны ситуации, когда неоднородность в узле меньше, чем в его потомке, и привести пример.

*Зачем это нужно.* Даёт предел того, что может дать один вопрос, и объясняет, почему отдельный потомок бывает неоднороднее родителя.

**Решение.**

(а) По (2) уменьшение энтропии есть взаимная информация  $\Delta H = I(Y; Z)$ , где  $Z$  – ответ классификатора. Взаимная информация симметрична и не превосходит энтропии каждого из аргументов:

$$I(Y; Z) = H(Z) - H(Z | Y) \leq H(Z),$$

поскольку условная энтропия неотрицательна. Для да/нет классификатора  $Z$  принимает два значения, а энтропия величины с двумя исходами не больше  $\log_2 2 = 1$  бита. Значит

$$\Delta H \leq 1 \text{ бит.} \quad \blacksquare$$

Равенство достигается, когда  $H(Z) = 1$  и  $H(Z | Y) = 0$ : потомки равны по размеру, и каждый класс целиком попадает в одного из них.

Для классификатора с  $B$  ответами тем же рассуждением  $H(Z) \leq \log_2 B$ , то есть

$$\Delta H \leq \log_2 B \text{ бит.}$$

Поэтому прирост информации сам по себе предпочитает вопросы с большим числом ответов, и на практике его нормируют.

(б) Уменьшается не неоднородность каждого потомка, а её *средневзвешенное* значение, см. (1). Отдельный потомок вполне может оказаться неоднороднее родителя, если это компенсируется вторым, более чистым и более крупным потомком.

Пример. Узел содержит 100 элементов: 90 класса  $C_1$  и 10 класса  $C_2$ ,

$$H(S) = -0.9 \log 0.9 - 0.1 \log 0.1 = 0.4690 \text{ бита.}$$

Разбиение:  $S_1$  – 80 элементов, все из  $C_1$ ;  $S_2$  – 20 элементов, 10 из  $C_1$  и 10 из  $C_2$ . Тогда

$$H(S_1) = 0, \quad H(S_2) = 1 \text{ бит,}$$

и потомок  $S_2$  неоднороднее родителя:  $1 > 0.4690$ . Тем не менее

$$\Delta H = 0.4690 - \left( \frac{80}{100} \cdot 0 + \frac{20}{100} \cdot 1 \right) = 0.4690 - 0.2 = 0.2690 > 0,$$

то есть разбиение полезно. ■

### Задание 8

**Дано.** Метод суррогатных (вспомогательных) расщеплений для случая, когда у объекта не задано значение атрибута.

**Требуется.** Показать, что метод использует предположение, что признак, значение которого не задано, наиболее информативен.

*Зачем это нужно.* Уточняет, на каком предположении держится обработка пропущенных значений атрибутов.

**Решение.** Разберём, что именно делает метод, и какой выбор при этом не делается.

Основное разбиение узла выбирается как максимизирующее (1) по всем атрибутам:

$$s = \arg \max_i \Delta \mathcal{I}(x_i).$$

То есть уже самым построением атрибут  $x_s$  объявлен самым информативным в этом узле среди всех атрибутов.

Пусть теперь у объекта значение  $x_s$  не задано. Метод суррогатных расщеплений ищет атрибут  $x_r$ , разбиение по которому максимально *совпадает* с разбиением по  $x_s$ , и применяет его. Ключевое здесь – критерий выбора  $x_r$ : максимизируется не прирост информации  $\Delta \mathcal{I}(x_r)$ , а согласие с основным разбиением

$$r = \arg \max_{i \neq s} P(\text{разбиение по } x_i \text{ совпадает с разбиением по } x_s).$$

Иными словами, метод не переспрашивает, какой вопрос лучше задать по имеющимся данным, а пытается *угадать ответ на недоступный вопрос*. Разбиение по  $x_s$  выступает эталоном, к которому подгоняется суррогат.

Такая постановка осмысленна ровно при одном предположении: ответ на вопрос про  $x_s$  ценнее любого другого доступного ответа, поэтому приближение к нему лучше, чем точный ответ на другой вопрос. Если бы это было не так, разумнее было бы среди атрибутов с заданными значениями выбрать тот, что даёт наибольший  $\Delta \mathcal{I}$ , и разбить по нему – получилось бы разбиение, оптимальное по наблюдаемым данным, но не имитирующее  $x_s$ .

Значит метод суррогатных расщеплений опирается на предположение о наибольшей информативности отсутствующего признака. Заметим, что предположение это не безобидно: атрибут выбран лучшим по обучающей выборке, где его значения были заданы, и переносится на объекты, у которых он не задан, хотя сама пропущенность значения может быть связана с классом. ■

### Задание 9

**Дано.** Задача классификации с двумя классами и двоичными атрибутами. Обозначим атрибуты слева направо  $a, b, c, d$ . Выборка:

| $w_1$ | $w_2$ |
|-------|-------|
| 0110  | 1011  |
| 1010  | 0000  |
| 0011  | 0100  |
| 1111  | 1110  |

**Требуется.** (а) Построить дерево решений, используя энтропию в качестве функции неоднородности. (б) Выразить каждый класс простейшим логическим выражением, то есть выражением с наименьшим количеством операций OR и AND.

*Зачем это нужно.* На маленькой выборке дерево строится вручную, и видно, как дерево записывается логической формулой.

**Решение.**

(а) *Построение дерева.* Выборка сбалансирована: по 4 элемента в классе,  $H = 1$  бит. Считаем прирост информации для каждого атрибута в корне.

Атрибут  $a$ : при  $a = 0$  это  $\{0110, 0011, 0000, 0100\}$  – два элемента  $w_1$  и два  $w_2$ ; при  $a = 1$  то же самое. Обе половины имеют  $H = 1$ , значит  $\Delta H = 0$ . Атрибут  $b$  даёт ту же картину,  $\Delta H = 0$ .

Атрибут  $c$ : при  $c = 0$  остаются  $\{0000, 0100\}$  – оба из  $w_2$ ,  $H = 0$ ; при  $c = 1$  остаются шесть элементов, четыре из  $w_1$  и два из  $w_2$ ,

$$H = -\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6} = 0.9183.$$

Средневзвешенная  $\frac{2}{8} \cdot 0 + \frac{6}{8} \cdot 0.9183 = 0.6887$ , откуда  $\Delta H = 1 - 0.6887 = 0.3113$  бита.

Атрибут  $d$ : при  $d = 0$  пять элементов (два  $w_1$ , три  $w_2$ ),  $H = 0.9710$ ; при  $d = 1$  три элемента (два  $w_1$ , один  $w_2$ ),  $H = 0.9183$ . Средневзвешенная 0.9513, откуда  $\Delta H = 0.0487$  бита.

Максимум даёт  $c$ , он и становится корнем.

Ветвь  $c = 0$ : остались  $\{0000, 0100\}$ , оба из  $w_2$ . Лист с меткой  $w_2$ .

Ветвь  $c = 1$ : остались  $\{0110, 1010, 0011, 1111\}$  из  $w_1$  и  $\{1011, 1110\}$  из  $w_2$ ,  $H = 0.9183$ . Считаем прирост по оставшимся атрибутам.

Атрибут  $a$ : при  $a = 0$  это  $\{0110, 0011\}$ , оба  $w_1$ ,  $H = 0$ . При  $a = 1$  это  $\{1010, 1111\}$  из  $w_1$  и  $\{1011, 1110\}$  из  $w_2$ ,  $H = 1$ . Средневзвешенная  $\frac{2}{6} \cdot 0 + \frac{4}{6} \cdot 1 = 0.6667$ , прирост  $0.9183 - 0.6667 = 0.2516$  бита. Атрибуты  $b$  и  $d$  делят эти шесть элементов на части с составом 2 : 1 каждая, обе с  $H = 0.9183$ , поэтому прирост нулевой. Выбираем  $a$ .

Ветвь  $c = 1$ ,  $a = 0$ : остались  $\{0110, 0011\}$ , оба из  $w_1$ . Лист  $w_1$ .

Ветвь  $c = 1$ ,  $a = 1$ : остались  $\{1010, 1111\}$  из  $w_1$  и  $\{1011, 1110\}$  из  $w_2$ . Здесь ни  $b$ , ни  $d$  по отдельности не дают прироста: любое из них делит четвёрку на две пары состава 1 : 1. Это не тупик, а характерная ситуация: класс определяется *сочетанием*  $b$  и  $d$ . Выпишем:

| $b$ | $d$ | вектор | класс |
|-----|-----|--------|-------|
| 0   | 0   | 1010   | $w_1$ |
| 0   | 1   | 1011   | $w_2$ |
| 1   | 0   | 1110   | $w_2$ |
| 1   | 1   | 1111   | $w_1$ |

то есть  $w_1$  ровно тогда, когда  $b = d$  – это задача XOR, которую один по координатный вопрос решить не может, а два подряд решают. Берём  $b$ , затем в каждой ветви  $d$ .

Итоговое дерево:

| Путь                         | Класс |
|------------------------------|-------|
| $c = 0$                      | $w_2$ |
| $c = 1, a = 0$               | $w_1$ |
| $c = 1, a = 1, b = 0, d = 0$ | $w_1$ |
| $c = 1, a = 1, b = 0, d = 1$ | $w_2$ |
| $c = 1, a = 1, b = 1, d = 0$ | $w_2$ |
| $c = 1, a = 1, b = 1, d = 1$ | $w_1$ |

(б) *Логические выражения.* Прочитаем дерево. Элемент относится к  $w_1$ , если  $c = 1$  и при этом либо  $a = 0$ , либо  $b$  совпадает с  $d$ :

$$w_1 = c \wedge (\neg a \vee (b \leftrightarrow d)).$$

Раскроем эквивалентность через AND и OR:

$$w_1 = c \wedge (\neg a \vee (b \wedge d) \vee (\neg b \wedge \neg d))$$

Здесь три операции AND и две OR, всего пять. Для второго класса берём отрицание и раскрываем по правилу де Моргана:

$$w_2 = \neg c \vee (a \wedge ((b \wedge \neg d) \vee (\neg b \wedge d)))$$

тоже пять операций.

Проверка по всем восьми элементам:

| вектор | $a b c d$ | $c$ | $\neg a \vee (b \leftrightarrow d)$ | $w_1$ | класс |
|--------|-----------|-----|-------------------------------------|-------|-------|
| 0110   | 0 1 1 0   | 1   | $\neg a = 1$                        | да    | $w_1$ |
| 1010   | 1 0 1 0   | 1   | $b = d = 0$                         | да    | $w_1$ |
| 0011   | 0 0 1 1   | 1   | $\neg a = 1$                        | да    | $w_1$ |
| 1111   | 1 1 1 1   | 1   | $b = d = 1$                         | да    | $w_1$ |
| 1011   | 1 0 1 1   | 1   | $a = 1, b \neq d$                   | нет   | $w_2$ |
| 0000   | 0 0 0 0   | 0   | —                                   | нет   | $w_2$ |
| 0100   | 0 1 0 0   | 0   | —                                   | нет   | $w_2$ |
| 1110   | 1 1 1 0   | 1   | $a = 1, b \neq d$                   | нет   | $w_2$ |

Все восемь элементов классифицированы верно. ■

Заметим, что на этой выборке верна и более короткая по виду формула  $w_1 = c \wedge (a \oplus b \oplus d)$ , но операция XOR в постановке не разрешена, а через AND и OR выражение  $a \oplus b \oplus d$  длиннее: в дизъюнктивной нормальной форме это четыре конъюнкции по три литерала, то есть одиннадцать операций.